

因果推断模型与机器学习方法



郑老师团队



时间:2026


“因果推断模型与机器学习方法”训练营-理论篇

欢迎关注

中介分析：从传统方法到因果推断

论文与统计分析公众号


公众号



中介分析 (Mediation Analysis)

欢迎关注

「分析」公众号



中介变量 混杂变量 碰撞变量核心区别总结表

特征	中介变量 (M)	混杂变量 (C)	碰撞变量 (Collider)
因果方向	$X \rightarrow M \rightarrow Y$	$C \rightarrow X$ 且 $C \rightarrow Y$	$X \rightarrow \text{Collider} \leftarrow Y$
在X与Y关系中的角色	解释机制	制造虚假关联	控制它会产生虚假关联
处理方式	根据研究目的决定是否控制	必须控制以消除偏倚混杂偏移	切勿控制（除非有特定原因），控制后会导致碰撞偏移/伯克森悖论

什么是中介分析？ $X \rightarrow M \rightarrow Y$

间接 / 中介效应 (Indirect / Mediated Effect):


X 通过中介变量 M 影响 Y

直接效应 (Direct Effect):

X 对 Y 的效应，不通过中介变量 M

总效应 (Total Effect):


$TE = \text{Indirect Effect} + \text{Direct Effect}$



传统中介分析

(Traditional mediation analysis)

传统中介分析路径模型与理论



1. 路径 a: 暴露 → 中介

$$M = \alpha + aX + \epsilon_M$$

2. 路径 c: 暴露 → 结局 (总效应)

$$Y = \beta + cX + \epsilon_Y$$

3. 路径 b + c': 加入中介后的模型

$$Y = \beta' + c'X + bM + \epsilon_Y$$

- 间接效应 (Indirect) = $a \times b$
- 直接效应 (Direct) = c'
- 总效应 (Total) = $c = a \times b + c'$

传统中介分析统计检验方法

逐步回归法, Baron & Kenny (1986)

首先检验 c ，然后检验 a ，最后检验 b 和 c' 。一般要求 c 显著， a 、 b 均显著性。
 c' 不显著是完全中介效应； c' 仍显著， $|c'| < |c|$ 小，是部分中介效应。

系数乘积检验法, Sobel Test

构建 z ，直接检验 $a \times b$ 的显著性，更直接。

Bootstrap法

通过重复抽样建构 $a \times b$ 的经验分布，提供置信区间，结果更稳健

传统中介分析弊端

因果假设模糊，易导致“虚假中介” 传统中介分析方法本质上是一系列统计关联检验，而不是因果识别

模型僵化，适用性窄 传统方法严重依赖于线性、无交互、连续变量的模型框架，因此间接效应 = $a \times b$ 未必成立。

估计目标不明确，因果解释薄弱 传统方法的目标是检验一个“中介效应”是否“显著”，但这个效应缺乏清晰的定义



因果中介分析 (Causal Mediation Analysis)

因果中介分析在以下方面进行了重要改进

明确的因果假设 基于反事实框架，明确界定直接效应和间接效应

严格的混淆控制 $X \rightarrow Y$ 的混杂变量， $M \rightarrow Y$ 的混杂变量（在控制 X 后）， $X \rightarrow M$ 的混杂变量，可以做敏感性分析

灵活的处理方式 可以兼容线性和非线性模型（如逻辑回归、生存分析），并能处理暴露-中介交互。

效
应
分
解

在反事实框架中，一个个体可能具有多个潜在结果

结局的潜在值 (Potential Outcome)

$Y(x)$: 暴露取值为 x 时的结局

中介的潜在值 (Potential Mediator)

$M(x)$: 暴露取值为 x 时的中介

联合反事实 (Joint Potential Outcome)

$Y(x, m)$: 暴露为 x , 中介人为设为 m 时的结局

现代因果中介分析（基于反事实框架）

自然直接效应 (NDE)：暴露X改变，中介M=0

$$NDE = E[Y(1, M(0))] - E[Y(0, M(0))]$$

自然间接效应 (NIE)：暴露X=1不变，中介M改变


$$NIE = E[Y(1, M(1))] - E[Y(1, M(0))]$$

总效应 (TE)： $TE = E[Y(1, M(1))] - E[Y(0, M(0))]$ $TE = NDE + NIE$

在无交互作用的线性模型中，NDE 和传统直接效应一致，NIE 和传统间接效应一致；但在有交互或非线性模型中，它们不同。

常用的建模与估计方法

欢迎关注“P



统计分析'公众号

参数化G公式（广义结果模型）

核心思想与操作：

1. 模型拟合：为中介(M)和结果(Y)建立参数模型（如回归、Cox模型）。
2. 使用蒙特卡洛模拟：依次生成反事实分布、预测反事实的结果、计算效应估计值，进行蒙特卡洛重复计算效应值的置信区间。

- 优点：**
1. 直观易懂，易于实现。
 2. 能处理多种变量类型（连续、分类、生存时间）。
 3. 方便纳入暴露-中介交互项

缺点与关

半参数/非参数方法(如基于机器学习)

核心思想与操作:

对模型的一部分（通常是Y对X, M, C的关系）进行非参数或灵活估计（如使用机器学习算法），中介模型还是用参数模拟的方法，反事实定义、蒙特卡罗模拟和G公式是一样的

- 优点:**
1. 模型假设更弱，对复杂关系（非线性、高维）更稳健。
 2. 减少模型误设风险。

缺点与关

中介逆概率加权

核心思想与操作:

构建两套权重（暴露权重 + 中介权重），相乘后创建一个“无混杂”的伪总体，直接计算效应。

优点：对Y模型稳健：不依赖Y的模型设定，
概念清晰（模仿随机化实验）。

缺点与关

双重稳健估计（如TMLE for Mediation）

核心思想与操作：

同时结合结果模型与权重模型，只要二者之一正确，即可得到无偏估计

优点：双重保险：兼具G公式的效率和IPW的稳健性，是目前观测性研究的首选推荐方法。

缺点与

时依性暴露与中介（如时依MSM）

核心思想与操作：

使用时依权重处理随时间变化的暴露、中介和混杂，构建反事实。

优点：能处理现实世界中更复杂的纵向因果结构

缺点与关

中介工具变量法

核心思想与操作：

为M到Y的路径寻找一个合格的工具变量，识别局部效应。

优点：能处理M→Y路径的未测混杂。

缺点与关

潜变量模型（如SEM框架）

核心思想与操作：

将测量模型（潜变量）与结构模型（因果路径）结合

优点：直接处理不可直接观测的中介变量（如压力、社会资本）。

缺点与关

如何选择方法？

场景/需求	推荐方法	关键考虑
初步探索、模型关系明确	参数化G- 公式(如mediation包)	简单快捷，结果易于解释。必须进行敏感性分析。
追求稳健性，担心模型误设	双重稳健估计(如medoutcon包)	当前最佳实践，推荐作为观测性研究的主要方法。
处理高维数据或复杂关系	结合机器学习ML 的G-公式或半参数方法	利用机器学习捕捉复杂模式，再用因果框架解读。
Y的模型难以指定，但X和M的生成机制相对明确。	中介逆概率加权法(如 medflex包)	重点关注并确保暴露和中介的模型尽可能准确。
处理纵向/时依性数据	基于MSM或SNM的时依性方法	需要深厚的因果推断专业知识，建议寻求合作。
中介变量有测量误差	潜变量结构方程模型	在心理学、教育等领域常用。

谢 谢

欢迎关注“医学论文与统计分析”公众号

欢迎关注“医学论文与统计分析”公众号