

因果推断模型与机器学习方法



郑老师团队



时间：2026

“因果推断模型与机器学习方法”训练营--理论篇

第一讲 机器学习与因果推断 概念与优势

“统计分析与统计推断”公众号

本讲内容

- 区分预测问题与因果问题
- 机器学习的概念、优势
- 因果推断的概念、优势
- 机器学习 × 因果推断的优势

现实研究环境的变化

- ★数据规模不断扩大，样本来源更加多样
- ★协变量数量显著增加，变量维度越来越高
- ★数据关系更加复杂，非线性与交互效应普遍存在
- ★研究目标逐渐从描述现象转向支持实际决策
- ★传统低维、线性建模方法面临越来越多挑战

统计分析中两类不同的问题

预测问题(Prediction)

- 关注在给定信息条件下结果是否会发生
- 预测强调相关性结构与预测准确性

VS

因果问题(Causation)

- 关注当主动改变某个变量时结果是否会改变
- 因果强调干预效应与反事实比较

两类问题的研究目标和评价标准并不相同

预测问题的典型形式

- 预测问题表示为：在给定协变量 X 的情况下预测结果 Y
- 研究目标是学习条件分布 $P(Y|X)$ 或条件期望 $E(Y|X)$
- 模型的优劣主要通过预测误差进行评估
- 常见评价指标包括 MSE、AUC、对数损失等
- 模型结构本身不要求反映真实的数据生成机制

因果问题的典型形式

- 因果问题关注：干预变量 A 对结果 Y 的影响
- 研究者希望比较同一对象在不同干预状态下的结果
- 典型问题：如果接受处理，与不接受处理相比结果是否不同
- 因果问题关注的是结果差异，而非单一结果的预测
- 该类问题天然涉及反事实结果

相关性 $\neq$ 因果关系

- 高预测准确性并不保证因果判断正确
- 预测模型学习的是变量之间的统计关联
- 相关性可能来自混杂、选择偏差或反向因果
- 在没有因果结构约束的情况下，模型无法区分因果方向
- 因果问题回答“如果我干预，会发生什么变化”

例子：冰淇淋销量与溺水

- 冰淇淋销量 $\uparrow$ ，溺水人数 $\uparrow$ (相关)

- 错误推断：冰淇淋导致溺水 (因果)

- 真相：温度/季节是共同原因 (混杂)

- 启示：

- 预测模型可以利用相关性

- 因果推断必须处理混杂结构

人工智能、机器学习与深度学习



人工智能(AI)

让机器表现出“智能行为”的总称

机器学习(ML)

实现人工智能的一类数据驱动方法

深度学习(DL)

机器学习中的一类模型方法

什么是机器学习

●●● 机器学习(Machine Learning)
是一类从数据中自动学习规律的方法

- 给定输入变量 X , 学习预测输出 Y
- 研究目标是在未知数据上最小化预测误差
- 模型不要求反映真实的数据生成机制
- 强调预测性能与泛化能力, 而非因果解释



机器学习

传统统计方法与机器学习的区别

维度	传统统计	机器学习
假设前提	有严格假设(正态、独立性)	基于数据学习, 无需前提假设
目标	参数估计 因果推断	预测准确率、泛化能力
应用关注	模型解释为主	模型效果为主
输出	P值、置信区间	准确率、AUC、F1值等

机器学习的形式化目标

- 通过最小化损失函数来学习模型参数或结构
- 回归问题常使用平方误差作为损失函数
- 分类问题常使用对数损失或交叉熵
- 模型训练过程中通常加入正则化以控制复杂度
- 模型优劣通过样本外预测性能进行评估

机器学习一般建模流程



整个流程关注的是预测效果而非因果解释

机器学习优势

✓ 高维与自动化

- 可处理高维协变量（变量多、交互多）
- 内置变量选择/特征筛选（正则化、树分裂、嵌入式选择），降低过拟合风险
- 自动捕捉非线性与复杂交互（树/boosting/NN 等）
- 可扩展性强（大样本、并行、分布式）

机器学习优势

✓ 减少模型设定负担

- 传统回归常依赖：线性假设、函数形式指定、交互项手工加入
- ML 更像“函数逼近器”，对形式错设更鲁棒（在预测意义上）
- 对复杂数据结构（文本、图像、序列）有天然优势
- 在工程应用中可快速迭代：数据更新 → 模型更新 → 性能更新

机器学习的局限性

- 机器学习主要学习的是统计相关性
- 无法区分混杂因素与真实因果效应
- 干预后数据分布可能发生变化，预测模型可能失效
- 高预测能力的变量不一定是可干预变量
- 复杂模型往往缺乏可解释性

高预测 $\neq$ 好决策

- 强预测因子不一定是可干预因素
- 准确识别高风险人群 $\neq$ 有效降低风险
- 决策关心的是：改变可控变量是否改变结果(可干预性)
- 因果推断是决策语言，机器学习是建模工具

因果推断定义

- 研究干预对结果的因果影响
- 基于反事实 (counterfactual) 思想来定义因果效应
- 比较不同处理状态下的潜在结果
- 输出是因果效应而非预测值
- 广泛应用于政策评估、医疗决策和社会科学研究

潜在结果框架

- 每个个体有两个潜在结果
 - $Y(1)$ 表示接受处理 $A = 1$ 时的结果,
 - $Y(0)$ 表示未接受处理 $A = 0$ 时的结果
- 个体因果效应: $\tau_i = Y(1) - Y(0)$
- 平均因果效应: $ATE = E[Y(1) - Y(0)]$
- 同一时间只能观察到一个潜在结果
- 反事实不可观测是因果推断的根本难点

因果推断要“识别”

因果推断不是“拟合一个模型”，而是要确保效应可被识别

- 常见识别思路：

- 随机试验（RCT）：靠随机化消除混杂

- 观察数据：依赖假设/设计（可交换性等）

- 识别与估计区分：

- 识别：理论上能否得到因果效应

- 估计：用什么方法把它算出来（回归、IPW、G 方法等）

因果推断的优势

- 能回答“干预是否有效”而不是“是否相关”
- 支持政策/治疗/产品策略的效果评估
- 可解释性强：效应大小、方向、对哪些人有效
- 可用于反事实推演与资源配置（成本—收益、优先级排序）
- 强调稳健性：敏感性分析、识别假设讨论

因果推断的挑战

观察性数据中普遍
存在混杂变量

非线性与交互关系
使简单模型易错设



实际问题往往涉及
高维协变量 X

因果效应估计高度
依赖模型设定

结合因果推断×机器学习

机器学习不是直接用来“算因果效应”，先估计一些“中间量”

➤ 机器学习估计中间量：

- 倾向性评分 $P(A|X)$ （谁更可能接受处理）
- 结果模型 $E(Y|A,X)$ （结果如何由 A,X 决定）

➤ 因果推断作用：

- 定义目标因果效应（ATE / ATT）
- 因果假设保证可识别性
- 用因果估计量整合，得到因果效应

因果推断×机器学习优势

减少模型错设偏差：

ML 自动捕捉非线性与交互

提升稳健性：

双重稳健估计量(AIPW、TMLE)天然兼容

应对高维混杂变量：

在假设无混杂成立的前提下，
提高对高维混杂的建模能力，
从而降低模型错设偏倚

支持异质性效应分析：

为个性化干预与精准决策提供基础

机器学习不引入新的因果信息，不修复未观测混杂、测量误差或选择偏差

小结

机器学习在预测与建模方面具有优势

因果推断在干预与决策问题中不可替代

预测与因果问题在目标上根本不同



现代因果分析需要借助机器学习

“因果推断模型与机器学习方法”训练营--理论篇

第二讲 机器学习的分类、用途与 Super Learner

文与统计分析公众号


本讲内容

- 机器学习分类
- 常用机器学习模型介绍
- Super Learner原理及优势

为什么要对机器学习进行分类

- 机器学习并不是单一方法，而是方法族
- 不同算法解决的问题类型不同
- 不同任务对应不同的目标函数
- 在因果推断中，算法选择会直接影响偏差与稳定性

机器学习的基本分类方式



监督学习与无监督学习

01

监督学习

- 训练数据同时包含输入X和输出 Y
- 学习目标是建立 $X \rightarrow Y$ 的映射关系
- 核心是最小化预测误差
- 是因果推断中最常用的机器学习范式
- 倾向性评分和结果模型本质上都是有监督学习问题

02

无监督学习

- 训练数据只有输入X，没有输出标签
- 学习目标是发现数据结构或模式
- 常见任务包括聚类、降维、表示学习
- 不直接用于因果效应估计
- 有时可用于探索异质性或辅助特征构建

回归与分类

回归任务:

- 输出变量为连续型
- 例如: $E(Y | A, X)$

分类任务:

- 输出变量为离散或二分类
- 例如: $P(A=1 | X)$

机器学习在因果推断中用途

01

估计倾向性评分


$$P(A=1 | X)$$

02

估计结果回归

$$E(Y | A, X)$$

- 二者都是建模问题而非因果问题
- 目标是减少模型错设带来的偏差





常见机器学习算法


- 线性模型：线性回归、逻辑回归、岭回归、LASSO、弹性网络
- 决策树
- 随机森林
- 梯度提升树：XGBoost、LightGBM
- 支持向量机
- 神经网络
- K近邻法

线性模型

- 线性模型结构简单、计算稳定
- 在低维或近线性关系下表现良好
- 正则化方法可缓解高维过拟合问题
- 参数具有一定可解释性
- 常作为因果分析中的基线模型



树模型基本思想



- 基于递归划分协变量空间
- 在不同区域内拟合简单模型
- 可自然处理非线性与交互
- 对变量尺度和分布要求较低
- 是因果推断中常用的灵活建模工具

决策树示意图


集成学习的核心思想

- 单一模型往往存在偏差或不稳定性
- 集成学习通过组合多个模型提高性能
- 核心思想是利用模型之间的差异性
- 常见形式包括：Bagging与Boosting
- Super Learner 属于系统化的集成学习框架




集成学习的核心思想


Single decision tree iteration: All samples



Bagging: Parallel tree growing with subsamples




Boosting: Sequential tree growing with weighted samples



随机森林

- 基于 **Bagging思想** 的树模型集成
- 自助采样和随机特征选择降低相关性
- 预测性能稳定，调参相对简单
- 在高维和非线性场景中表现良好
- 常用于估计倾向性评分和结果模型



极限梯度提升 (XGBoost)

- 基于**梯度提升 (Gradient Boosting)** 决策树的集成学习算法。
- 引入**正则化项和二阶导数**信息，提高模型性能和泛化能力。
- 将多个弱分类器（决策树）组合成一个强分类器。每个决策树都在前一棵树的残差基础上进行训练，通过不断迭代优化损失函数来逐步减小残差。
- 通过**控制树的复杂度和正则化项**来减少过拟合风险。

光梯度提升机 (LightGBM)

- 基于决策树算法，通过逐步构建加法模型来优化目标函数，适用于处理大规模数据集和高维特征的任务。




$$\text{LightGBM} = \text{XGBoost} + \text{GOSS} + \text{EFB} + \text{Histogram}$$

支持向量机 (SVM)


- 旨在从训练样本中找到一个最优超平面，最大化分类边界之间的间隔

特点	描述
🔍 边界最大化	提升模型泛化能力，防止过拟合
🔄 可扩展到非线性	使用核函数（如 RBF、多项式）映射到高维空间
📊 适合小样本	在小数据集上表现良好，鲁棒性强
⌚ 计算成本	对大数据集训练时间较长，需调参




神经网络 (NN)

- 由大量的简单处理单元（**神经元**）按照某种方式连接在一起构成，单元分为**输入层**、**隐藏层**、**输出层**。
- 通过调整各层之间的连接权重，神经网络可以学习复杂的函数映射，从输入数据中提取特征并做出预测。



神经元生理结构



输入层

隐藏层

输出层


- ✓ 输入层：接收外部数据
- ✓ 隐藏层：进行特征提取和变换，可能有多层
- ✓ 输出层：输出结果

k近邻法 (kNN)

计算样本与训练数据集中所有样本的**距离**，选取距离最近的K个邻居，根据邻居的标签来进行预测。

➤ 距离度量对**模型性能**有较大影响，不同任务中选择不同的度量方法。

- 欧氏：连续数值特征
- 曼哈顿：高维稀疏特征
- 闵可夫斯基距离：文本或向量表示



机器学习模型比较

模型名称	优势
Logistic	解释性强，可输出OR值；训练快，适合线性问题
决策树	逻辑清晰，可视化；可自动选特征；能处理非线性关系
随机森林	鲁棒性强，抗过拟合；评估特征重要性；适合高维复杂数据
XGBoost	精度高、训练快；抗噪声能力强；支持缺失值处理
LightGBM	速度快、内存占用少；支持大规模数据；适合稀疏特征
KNN	简单直观、无训练过程；不依赖数据分布假设
SVM	边界明确、适合小样本/非线性问题
NN	学习能力强，支持复杂非线性；可扩展为深度学习

算法选择的注意事项

- 高预测精度 $\neq$ 低因果偏差
- 过拟合可能导致极端倾向性评分
- 稳定性往往比极限预测更重要
- 简单模型有时更利于因果估计
- 实际中通常结合多种模型

为什么需要模型集成

- 1 不同模型对数据结构的假设不同
- 2 单一模型容易因错设而产生偏差
- 3 难以事先判断哪种模型最优
- 4 集成方法可降低模型选择风险

Super Learner基本思想

- **Super Learner 是一种加权集成学习方法**
- 不预设“最优模型”，而是从候选模型中学习
- 通过交叉验证评估各模型预测性能
- 根据性能为不同模型分配权重
- 目标是在理论上接近最优预测器

Super Learner理论优势

- 在样本量足够大时，性能不劣于候选模型中最优者
- 避免人为选择模型带来的风险
- 对模型错设具有更强鲁棒性
- 非常适合高维、复杂数据环境

Super Learner在因果推断中的作用

01 用于估计倾向性评分

02 用于估计结果回归

03 可同时结合多类机器学习
算法

04 有助于减少单一模型错设
带来的偏差

05 双稳健估计重要组成部分

小结



“因果推断模型与机器学习方法”训练营--理论篇

第三讲 G 计算与倾向性评分 ——基于机器学习的方法与应用

文与统计分析”公众号

本讲内容

- 观察数据中的因果估计问题
- G 计算
- 倾向性评分模型
- 机器学习(super learner)在两类模型中的角色

观察数据中的因果问题

为什么不能直接比较处理组与对照组

- 治疗或干预并非随机分配
- 协变量同时影响处理与结果
- 处理组与对照组在协变量分布上不同
- 直接比较结果会产生混杂偏差
- 需要方法控制混杂变量的影响

因果问题的基本设定

- A : 处理/干预 (如用药 vs 不用药)
- Y : 结局 (死亡、再入院、生存时间等)
- X : 基线协变量 (潜在混杂因素)
- 潜在结果:
 - $Y(1)$: 接受处理时的结局
 - $Y(0)$: 未接受处理时的结局

因果推断的目标量 (Estimand)

- 潜在结果：
 - $Y(1)$: 接受处理时的结果
 - $Y(0)$: 未接受处理时的结果
- 平均因果效应: $ATE = E[Y(1) - Y(0)]$
- 所有方法的目标都在估计该量或其变体

目标量 (Estimand)

- **ATE:** 整个研究总体的平均因果效应

$$ATE = E[Y(1) - Y(0)]$$



总体干预策略评估

- **ATT:** 已接受处理个体的平均效应

$$ATT = E[Y(1) - Y(0) \mid A=1]$$



真实接受治疗人群
中的疗效评估

因果效应识别的基本假设

01

一致性

观察结果等于
对应潜在结果

02

可交换性/无混杂

$$Y(a) \perp A | X$$

03

正则性/重叠性

每个X下接受与不接受
处理都有正概率

- 这些是假设，而不是模型输出
- 机器学习无法替代这些假设

G 方法统一思想

- ▶ 目标：估计不同干预水平下的潜在结果期望
- ▶ 核心操作：在控制混杂后，构造反事实分布
- ▶ G 方法不是单一算法，而是一类因果估计策略

G 方法主要实现路径

✓ 从观测数据到因果效应

01

路径一：

基于结局模型
建模结果 Y
构造反事实结果

G 计算

02

路径二：

基于治疗模型
建模处理分配 A
构造平衡后的样本

倾向性评分

G 计算估计目标

- G 计算关注潜在结果的均值:

$$E[Y(1)], E[Y(0)]$$

- 不关注回归系数
- 直接估计因果效应的组成部分
- 属于基于结果模型的方法

G 计算成立的关键等式

在无混杂条件下，有：

$$E[Y(a)] = E\{E(Y | A=a, X)\}$$

- 左侧：潜在结果的期望（所有人都接受处理 a 的平均结果）
- 右侧：从观测数据中分两步估计的统计量
 - ✓ 第一步：在协变量 X 的每一层内，估计接受处理 a 的群体的平均结果 $E(Y|A=a, X)$ 。
 - ✓ 第二步：将这个条件期望按总体中协变量 X 的分布 $P(X)$ 进行加权平均（即“标准化”）。

G 计算通过估计右侧来获得左侧

G 计算的计算步骤

步骤 1: 拟合结果模型

- 使用观测数据拟合结果模型 $E(Y | A=a, X=x)$
- 模型形式是回归模型或机器学习模型

步骤 2: 构造反事实处理状态

- 设定所有个体 $A = 1$
- 设定所有个体 $A = 0$

步骤 3: 计算反事实结果的预测值

步骤 4: 在总体中进行标准化并计算因果效应ATE 或 ATT

G 计算的优势与局限

✓ 优势:

- 形式直观
- 易推广至连续或多水平处理

✓ 局限:

- 强依赖结局模型的正确性
- 高维协变量下模型错设风险高

G 计算中的建模问题

- 结局模型在因果推断中属于辅助模型
- 模型错设将直接引入系统性偏倚
- 传统回归：线性、加性假设较强
- 在复杂医学数据中往往不够灵活

医学数据中常见：

- 非线性关系
- 高阶交互
- 高维协变量

机器学习在 G 计算中的作用

• 估计结局模型 $E(Y | A, X) \approx f_{ML}(A, X)$

• 目标:

◦ 减少模型错设

◦ 提高反事实预测的稳定性

• 注意:

◦ 机器学习不改变因果假设

◦ 仅作为建模工具使用

有监督回归问题

常用算法:

• Random Forest

• Gradient Boosting

• Neural Networks

• Super Learner

为什么需要倾向性评分

- ✓ G 计算路径对结局模型依赖较强
- ✓ 在结局稀有或高维场景下不稳定
- ✓ 需要一条不直接依赖结局模型的估计路径

倾向性评分定义

➤ 定义为:

$$e(X) = P(A=1 | X)$$

- 是处理分配模型的预测概率
- 每个个体都有一个倾向性评分
- 是协变量 X 的函数

倾向性评分解决的问题

- 原始问题：
 - 协变量维度高
 - 处理与协变量相关
- 倾向性评分将高维信息压缩为一维
- 在给定倾向性评分后：协变量在处理组和对照组中分布相似

倾向性评分方法基本步骤

步骤 1:选择协变量 X

包含所有潜在混杂变量
不包括结果变量

步骤 2:估计倾向性评分

建模 $P(A=1 | X)$
可使用逻辑回归或机器学习方法

步骤 3:构造权重或匹配方案

根据研究目标(ATE/ATT)选择权重形式

步骤 4:检查协变量平衡

比较加权前后处理组与对照组
评估是否实现平衡

步骤 5:估计因果效应

在加权样本中比较结果

基于PS的主要方法

- 匹配 (Matching)
- 分层 (Stratification)
- **加权 (IPTW)**
- 协变量调整 (PS-adjusted regression)

IPTW的基本思想

$$w_i = \frac{A_i}{e(X_i)} + \frac{1 - A_i}{1 - e(X_i)}$$

- 为每个个体分配权重，构造新的“伪总体”
- 通过重构样本权重，打破处理分配与协变量间的关联
- 在加权后的伪总体中：
 - 处理分配在协变量分布上近似随机
 - 可直接估计平均处理效应（ATE）

倾向性评分估计的关键性

✓ PS 未知，需通过模型估计

✓ 传统方法：Logistic 回归

局限：

- 线性与加性假设
- 交互需人工指定
- 高维下不稳定

机器学习在倾向性评分中的作用

- 倾向性评分估计本质是一个预测问题（预测A）
- 机器学习擅长处理：
 - 高维协变量
 - 非线性关系
 - 复杂交互
- ML估计倾向性评分，提高协变量平衡效果
- 需防止极端概率

常用算法：

- LASSO / Elastic Net
- Random Forest
- Gradient Boosting
- Super Learner

倾向性评分方法的诊断要求

- 必须检查：

- 协变量平衡：标准化差异（SMD）

- 重叠性（overlap）

- 常用标准：

- $|SMD| < 0.1$

- 未达平衡 → 因果估计不可信

预测准 $\neq$ 倾向性评分好

- 倾向性评分的目标不是分类准确率
- 关键诊断是协变量是否平衡
- 过度追求预测性能
 - 可能导致极端概率
 - 引发权重不稳定
- 因果分析与预测分析目标不同

Super Learner在G方法中的角色

- G 方法依赖多个辅助模型：
 - 结局模型 $E(Y | A, X)$
 - 治疗模型 $P(A=1 | X)$
- 单一模型选择存在错设风险
- Super Learner:
 - 基于交叉验证
 - 对多个候选算法进行加权组合
 - 降低对单一模型形式的依赖
 - 提高估计的稳健性

不建议“只选一个最优模型”

- 在真实数据中：

- 很难事先判断哪一种模型是“正确的”
- 不同模型在不同样本下表现不稳定

- 在因果推断中：

- 模型的作用是控制混杂
- 而不是单纯提高预测准确率

- 选择单一模型：一旦模型错设，因果效应估计将产生偏倚

G计算与倾向性评分的对比

方面	G 方法	倾向性评分方法
建模对象	结局模型 $E(Y A, X)$	处理模型 $P(A X)$
核心思想	标准化	平衡 / 加权
控制混杂方式	条件建模 + 标准化	样本加权
主要风险	结局模型错设	权重不稳定
机器学习用途	估计结局模型	估计倾向性评分

“双稳健”思想

G 计算：依赖结局模型

- 若结局模型正确 $\rightarrow$ 一致

PS 加权：依赖PS 模型

- 若倾向性评分模型正确 $\rightarrow$ 一致

但二者都可能错设

同时使用两类模型
有机会提高稳健性

AIPW、TMLE 的理论起点

小结

- G 计算基于结果模型估计因果效应
- 倾向性评分通过加权实现协变量平衡
- 两种方法对应不同的建模路径
- Super Learner 通过模型集成提高因果效应估计的可靠性



谢 谢!

欢迎关注“医学论文与统计分析”公众号

欢迎关注“医学论文与统计分析”公众号