

因果推断模型与机器学习方法

郑老师团队

时间：2026

“因果推断模型与机器学习方法”训练营--理论篇

双重稳健估计方法与双重机器学习

1. 因果推断与双重稳健估计背景

因果推断的核心解决方案

- 反事实潜在结果与因果结构模型的结合 (DAG)
- 统计学家James Robins引入**潜在结果框架**来形式化因果推断。
- 对于每个单元 i 和处理状态 t ，我们定义潜在结果 $Y_i(t)$ 。
- 通过随机化或者“事后随机化”的方式创造“事实”与反事实

潜在结果定义

- 1 $Y_i(1)$: 单元 i 接受治疗时的潜在结果
- 0 $Y_i(0)$: 单元 i 未接受治疗时的潜在结果

平均处理效应 (ATE)

$$ATE = E[Y(1) - Y(0)]$$

因果效应定义为同一群体在两种处理状态下的平均结果差异，即“如果所有人都接受治疗”与“如果所有人都不接受治疗”的平均结果之差。

两种ATE的估计方法

结果回归模型: 直接建模路径

- 直接对结果Y建模, 将处理D和混淆变量X作为自变量, 通过回归系数 β_1 来估计因果效应。

模型设定

$$Y = \beta_0 + \beta_1 A + \beta_2 X + \varepsilon$$

Y: 结果变量(如血压下降幅度)

A: 处理变量(是否服药)

X: 协变量(年龄、性别等)

估计方法

系数 β_1 即为控制X后, A对Y的平均效应, 为条件效应

$$\beta_1 = E[Y|A=1, X] - E[Y|A=0, X]$$

⚠ 关键要求

需要正确指定Y与X、A的关系, 如线性关系、无交互作用等

如果真实关系非线性:

- 错误使用线性模型 → 模型设定偏误
- β_1 估计的是关联而非因果
- 偏误不会随样本量增大而消失

两种ATE的估计方法

倾向得分模型:间接平衡路径

- 不直接建模Y，而是对接受处理D的概率(倾向得分)建模，再用得分去"平衡"数据，使得处理组和对照组在协变量分布上相似。

倾向得分定义

$$e(X) = P(A=1|X)$$

给定协变量X的条件下，个体接受处理A的概率

实现方法

1. 匹配 (Matching)

为每个处理组个体找一个倾向得分相近的对照组"双胞胎"

2. 加权 (Weighting)

对对照组个体赋予更高权重，使其在倾向得分分布上与处理组相似

关键要求

需要正确指定A与X的关系，通常使用Logistic回归模型

如果倾向模型错误：

- 倾向得分估计不准确
- 匹配/加权无法有效平衡协变量
- 因果估计仍然存在偏误

传统单一模型错误指定的系统性风险

📈 结果回归方法

依赖：结果模型 $Y = \beta_0 + \beta_1 A + \beta_2 X + \varepsilon$

风险：必须正确指定Y与X、A的关系

✖ 模型设定错误 → 估计有偏

⚖️ IPTW方法

依赖：倾向评分模型 $P(A=1|X)$

风险：必须正确指定A与X的关系

✖ 倾向模型错误 → 权重失衡 → 估计有偏

在医学真实世界数据中，两个模型都很难完全正确设定。我们永远无法知道真实的Y与X、A的关系是否线性，也无法确定Logistic模型是否完美捕捉了处理分配机制。这种对模型正确设定的强依赖性，使得传统方法在复杂场景下风险极高。

🛡️ 双重稳健的承诺

问题：有没有一种方法，只要求两个模型其中一个正确就能得到正确估计？

答案：双重稳健估计方法应运而生！只要结果模型或倾向模型任一正确，估计就能保持一致性，实现真正的“双保险”机制。

双重稳健估计:更安全的路径

破解单模型依赖困境的优雅思想



双重稳健的承诺

- ✓ 我不再需要二选一
- ✓ 我可以同时使用两个模型
- ✓ 只要其中一个正确，估计就是无偏的！

"双保险"机制

如同有两把锁，只要其中一把是好的，宝藏就是安全的。

结果模型

正确 → 估计正确

倾向模型

正确 → 估计正确

"安全网"比喻

- 一张由两个模型编织的2张网，只要一边牢固，就能接住无偏的估计值
- 任一牢固 → 估计值不会"坠落"

双重稳健估计量：通过特定的数学形式将两个模型的估计量组合，使得最终估计量对任一模型的错误设定都具有稳健性。

2. 双重稳健估计的思想与主流方法

双 双重 (Doubly)

结果模型

估计给定协变量X下，处理对结果Y的期望影响

暴露模型/倾向性评分模型

估计协变量给定的处理概率，用于控制混杂

传统方法：只依赖其中一个

稳 稳健 (Robust)

双保险机制

只要其中一个模型是正确的，估计结果就可以是一致的

互补而非依赖

两个模型互补，即使一个不完美，另一个能“兜底”

? 结果模型 + 暴露模型 = 双重稳健模型?

并不是分别估计两个模型再简单平均或相加，而是将两个模型通过**特定的数学形式组合成一种新的估计量**。双重稳健估计方法通过残差校正项提高稳健性，降低模型错误指定的风险。

因果估计方法演进对比

方法	主要依赖模型	优势	缺点
G-计算	结果模型(Outcome Model)	计算直观; 易于解释; 适用于正确建模情境	高度依赖模型设定; 不适用于非线性或高维数据
IPTW	倾向评分模型 (Propensity Score)	平衡协变量; 避免建模结果变量; 适用于观察研究	权重不稳定; 易受极端值影响; 需满足正性假设
AIPTW	倾向评分 + 结果模型	任一模型正确即可; 估计效率优于IPTW	结构复杂; 需要两个模型建模; 难以在高维下调参
TMLE	倾向评分 + 结果模型 + Target更新	最佳渐近效率; 支持机器学习拟合	实现复杂; 需掌握Targeting步骤; 结果依赖初始估计
DML	倾向评分 + 结果模型 + 交叉拟合	正交残差; 偏差控制; 适合高维数据	实现复杂; 需要理解正交化原理; 计算成本较高

增强逆概率加权法 (AIPTW)

Augmented Inverse Probability Weighting

+ 核心思想

在传统逆概率加权的基础上，引入结果模型对逆概率加权的估计进行残差校正，从而实现双重稳健。估计器形式中同时包含处理概率与结果预测值。

</> R包实现

drtmle包

双重稳健目标最大似然估计

AIPW包

简洁易用的AIPTW实现

AIPTW估计量

$$\widehat{ATE}_{AIPTW} = \frac{1}{n} \sum_{i=1}^n \left[\underbrace{\hat{m}_1(X_i) - \hat{m}_0(X_i)}_{\text{(A) 结果模型部分}} + \underbrace{\frac{A_i}{\hat{e}(X_i)} (Y_i - \hat{m}_1(X_i)) - \frac{1 - A_i}{1 - \hat{e}(X_i)} (Y_i - \hat{m}_0(X_i))}_{\text{(B) 暴露模型 (PS) } \times \text{ 残差校正项}} \right]$$

$\hat{e}(X)$: 倾向得分估计

$\hat{m}(X)$: 结果模型预测

增强项的作用

情况1: 倾向模型正确

增强项期望为0，AIPTW退化为IPTW，估计一致

情况2: 结果模型正确

增强项校正IPTW的偏误，估计一致

情况3: 两个都错

估计有偏(但在某些情况下仍优于单一模型)

目标最大似然估计 (TMLE)

Targeted Maximum Likelihood Estimation

核心思想

先拟合初始结果模型，再通过“聪明变量”(clever covariate)对其进行目标化更新，使估计器满足参数模型的最优性，同时保持双重稳健性质。

R包实现

tmle包

标准TMLE实现

ltmle包

纵向数据TMLE

TMLE的两步机制

Step 1: 初始估计

拟合结果模型 $m(X) = E[Y|D,X]$ ，得到初始预测

Step 2: 目标化更新

用聪明变量更新初始估计，使估计量满足影响函数的最优性

聪明变量(H(A,W))

$$H(A,W) = A/e(A|W) - (1-A)/(1-e(A|W))$$

聪明变量巧妙地结合了倾向得分和处理指示变量，通过 fluctuation model 对初始结果模型进行“微调”，使得最终的估计量既保持双重稳健性，又达到半参数有效边界。

双重机器学习 (DML) 概览

Double Machine Learning

机器学习拟合

采用机器学习方法分别拟合处理模型和结果模型

支持随机森林、Lasso、神经网络等灵活模型

交叉拟合

结合交叉拟合技术，构造样本外预测

避免过拟合误差，保证统计一致性

正交残差

构造正交残差实现偏差控制与一致性估计

强调正交性与数据驱动建模

R包实现

DoubleML包

功能完整的DML实现框架

- 支持多种DML模型(部分线性、交互式等)
- 内置多种机器学习算法
- 提供自助法推断工具

方法对比

AIPTW: 最直观的"加权+回归"方法

TMLE: 通过聪明变量修正结果模型，更精确

DML: 用机器学习建模并交叉拟合，适合高维数据

共同原则：只要有一个模型正确，估计就不偏！

3. 增强逆概率加权法 (AIPTW)与机器学习结合

$$\widehat{ATE}_{AIPTW} = \frac{1}{n} \sum_{i=1}^n \left[\underbrace{\hat{m}_1(X_i) - \hat{m}_0(X_i)}_{\text{(A) 结果模型部分}} + \underbrace{\frac{A_i}{\hat{e}(X_i)} (Y_i - \hat{m}_1(X_i)) - \frac{1 - A_i}{1 - \hat{e}(X_i)} (Y_i - \hat{m}_0(X_i))}_{\text{(B) 暴露模型 (PS) } \times \text{ 残差矫正项}} \right]$$

- 通过数学公式整合 结果模型和暴露模型，形成一个统一的估计量；
- 双重稳健是两个模型有一个正确，结果就正确。难道不会出现两个都错的情况？
- 双重稳健估计方法通过残差矫正项提高稳健性，降低模型错误指定的风险
- **并不是分别估计“结果模型”和“暴露模型”后再做一个简单平均或相加**，而是将这两个模型通过特定的数学形式组合成一种新的估计量

3. 增强逆概率加权法 (AIPTW)与机器学习结合

➤ 核心优势

- 双重稳健性：只要结果模型或倾向评分模型任一正确，即可得到一致的因果估计；
- 比 IPTW 更稳定：残差矫正项可减少极端权重影响，显著提高估计稳定性；
- 效率最优：在满足条件下可达到理论上最小方差，比AIPW更高效；
- 兼容机器学习，模型灵活：可与 **Super Learner**、随机森林、XGBoost 等结合，减少模型设定错误；
- 输出医学友好的因果效应，如ATE。

3. 增强逆概率加权法 (AIPTW)与机器学习结合

- **关键技术**

- 超级学习者

- 采用SL构建结果模型与倾向得分模型

- 交叉拟合

- 拆分数据为训练集与验证集防止过拟合

3. 增强逆概率加权法 (AIPW)与机器学习结合

```
AIPW$new(Y = NULL,  
         A = NULL,  
         W = NULL,  
         W.Q = NULL,  
         W.g = NULL,  
         Q.SL.library = NULL,  
         g.SL.library = NULL,  
         k_split = 10,  
         verbose = TRUE,  
         save.sl.fit = FALSE)
```

用于拟合结局模型的机器学习算法

用于拟合暴露模型的机器学习算法

数据分割的折数 (默认 = 10)

机器学习模型的过拟合困境

同一批数据训练与评估带来的致命偏误

⚠ 致命问题

如果用同一批数据既训练机器学习模型，又用这些模型的预测值去计算AIPW估计量，会导致严重的“过拟合偏误”。

为什么会产生偏误？

过拟合的模型在训练数据上的预测误差($Y - \hat{m}(X)$)和($A - \hat{e}(X)$)会被人为地压缩得很小。

这个“小”不是真的准，而是模型“记住”了噪声。当这个被低估的误差项被代入AIPW的影响函数进行估计时，会产生一个不随样本量增大而消失的偏误，破坏了估计量的一致性。

"弹性软尺"比喻

传统统计模型

刚性尺子，测量时自身变形小

机器学习模型

弹性软尺，完美贴合数据起伏

问题：软尺告诉你“一切都刚刚好”(残差很小)，但这只是因为它记住了数据！

交叉拟合的优势

通过样本分割实现训练与评估的统计独立性

✂ 核心思想

将样本随机分成K部分，对于每一折k，用其他K-1折作为训练集拟合模型，然后将训练好的模型应用于第k折得到预测值。最后将所有K折的预测结果拼接起来，得到全样本的交叉预测值。

5折交叉拟合流程

迭代1: 训练集(折2-5) → 训练模型 → 预测[折1]

迭代2: 训练集(折1,3-5) → 训练模型 → 预测[折2]

...

迭代5: 训练集(折1-4) → 训练模型 → 预测[折5]

最终: 将所有预测拼成完整数据集

算法步骤

- 1 将样本随机分为K个互斥子集
- 2 对于每一折k，用训练集拟合ML模型
- 3 将模型应用于验证集，得到预测值
- 4 重复K次，拼接所有预测得到全样本预测
- 5 用交叉预测值计算因果估计量

关键优势

- 训练集和验证集完全分离
- 预测误差与模型训练统计独立
- 允许使用复杂灵活的ML模型
- 保证估计量的统计一致性

AIPW结合交叉拟合的R代码实现

方法1: 传统GLM

```
library(AIPW)
library(SuperLearner)
aipw_simple <- AIPW$new(
  Y = Y, A = A, W = W,
  Q.SL.library = c("SL.mean", "SL.glm"),
  g.SL.library = c("SL.mean", "SL.glm"),
  k_split = 1, # 不交叉拟合
  verbose = FALSE
)$fit()
summary(aipw_simple)
```

缺点：使用简单GLM模型，可能无法捕捉复杂关系，存在模型误设风险

方法2: 超级学习器+交叉拟合

```
library(AIPW)
library(SuperLearner)
aipw_advanced <- AIPW$new(
  Y = Y, A = A, W = W,
  Q.SL.library = c("SL.glm", "SL.glmnet", "SL.ranger"),
  g.SL.library = c("SL.glm", "SL.glmnet", "SL.ranger"),
  k_split = 5, # 启用5折交叉拟合
  verbose = FALSE
)$fit()
summary(aipw_advanced)
```

优势：使用丰富模型库+交叉拟合，避免过拟合偏误，双重稳健保证

4. 双重机器学习DML

- Chernozhukov等人在2018年，系统性地提出
- 双重机器学习 (Double Machine Learning, DML) 是近十年来因果推断与机器学习交叉领域最具影响力的进展之一。
- 如何在高维、复杂的现实数据中，安全地使用强大的机器学习模型进行无偏的统计推断。
- 其思想核心是Neyman正交化与交叉拟合，
- 这确保了即使机器学习模型存在正则化偏差，核心参数的估计依然是无偏且有效的

4. 双重机器学习DML

- **将回归思想一般化**：用任意的机器学习模型（如随机森林、神经网络）来代替线性回归，以拟合高维、非线性的混淆关系。
- **引入了“正交化”**：通过数学变换，使估计方程对两个机器学习模型的误差不敏感，从而允许这些模型的收敛速度慢于传统的参数模型。
- **设计了“交叉拟合”流程**：通过样本分割，确保了模型预测与参数估计步骤的独立性，最终保障了统计推断的可靠性。

4. 双重机器学习DML

案例：研究新降压药(处理A)对血压下降(结果Y)的影响

传统回归结果模型的问题：

可能遗漏重要协变量(如遗传、饮食)

协变量与暴露相关

医生更可能给重症患者开药

机器学习直接建模: 会有过拟合偏差

DML的数学模型

两个关键方程

$$Y = \theta \cdot A + g(X) + U$$

结果方程

$$A = m(X) + V$$

暴露方程

θ (theta)

我们关心的因果效应(如降压药效果)

$g(X)$

协变量对结果的直接影响
(年龄、基础病对血压的影响)

$m(X)$

协变量对处理的选择影响
(哪些患者更容易拿到药)

U, V

误差项, 包含未被观测的因素

4. 双重机器学习DML

将因果效应估计分为两步的突破性思想

1 去除协变量影响

用机器学习分别建模A和Y与协变量X的关系，捕捉X对A和Y的非线性、高维复杂影响。

2 残差分析

在"净化"后的残差上估计因果效应，此时X的影响已被扣除，残差之间的关系更接近真实的因果效应。

DML使用去除混杂的核心

→ 暴露模型

用回归或者机器学习建模得到预测值 $E[A|X]$

从A中减去预测值, $A - E[A|X] = A_{\text{resid}}$
得到与X无关的暴露残差V

→ 结果模型

用回归或者机器学习建立暴露模型得到预测值 $E[Y|X]$

从Y中减去预测值, $Y - E[Y|X] = Y_{\text{resid}}$
得到去除X直接影响的结局残差

直观理解

- $E[A|X]$: 预测谁会自然服药
用所有协变量X建模处理概率 $E[A|X]$
- A_{resid} :
预测概率结果与实际结果的差别

- $E[Y|X]$: 预测降压效果
用所有协变量X建模处理概率 $E[Y|X]$
- Y_{resid} :
预测结果与实际结果的差别

DML使用去除混杂的核心

理解残差如何剥离混杂因素的直接影响

混杂因素的纠缠

年龄、糖尿病、基础病情等因素同时影响了"医生是否开药"(暴露变量D)和"血压能降多少"(结果变量Y)。这种纠缠就是偏差的来源。

服药残差 (A_resid)

$$A_resid = \text{实际服药} - \text{预测服药概率}$$

剥离了混杂因素对"服药"决策的影响

只保留了"出于其他未知或随机原因"导致的服药行为。这个残差在数学上与X是正交(不相关)的。

血压残差 (Y_resid)

$$Y_resid = \text{实际血压变化} - \text{预测血压变化}$$

剥离了混杂因素对"血压"的直接影响

只保留了"超出预期的"血压变化。这个残差也滤除了X的直接效应。

DML使用去除混杂的核心

处理残差计算

患者A

- 预测服药概率: 0.8
- 实际服药: 1
- 处理残差: $1 - 0.8 = +0.2$ ("治疗")

患者B

- 预测服药概率: 0.8
- 实际服药: 0
- 处理残差: $0 - 0.8 = -0.8$ ("未治疗")

结果残差计算

患者A

- 预测血压下降: 10mmHg
- 实际下降: 15mmHg
- 结果残差: $15 - 10 = +5\text{mmHg}$ ("超预期下降")

患者B

- 预测血压下降: 10mmHg
- 实际下降: 8mmHg
- 结果残差: $8 - 10 = -2\text{mmHg}$ ("低于预期下降")

DML使用去除混杂的核心

现在，有两列纯净的数据：

- 服药意外度 (A_{resid}): +0.2, -0.8, +0.1, -0.3.....
- 血压变化意外度 (Y_{resid}): +10mmHg, -5mmHg, +8mmHg, -2mmHg.....

可建立回归方程

$$Y_{\text{resid}} = \theta \times A_{\text{resid}}$$

$$\text{血压意外} = -15 \times \text{服药意外}$$

$$\theta = -15$$

θ 是剥离了所有混杂X影响的、“服药对血压的因果效应”!

残差回归的推导过程

1 原始模型

$$Y = \theta A + g(X) + U$$

包含处理效应和协变量影响

2 取条件期望

$$E[Y|X] = \theta E[A|X] + g(X)$$

对两边取X的条件期望

3 两式相减

$$Y - E[Y|X] = \theta (A - E[A|X]) + U$$

消去g(X)项

残差回归方程

$$Y_{\text{resid}} = \theta \cdot A_{\text{resid}} + U$$

其中 $Y_{\text{resid}} = Y - E[Y|X]$

$A_{\text{resid}} = A - E[A|X]$

关键步骤解释


- 相减后，方程中不再有X的显式项
- 在残差回归中，X的影响已被扣除

最终估计

$$\theta = \text{Cov}(Y_{\text{resid}}, A_{\text{resid}}) / \text{Var}(A_{\text{resid}})$$

用最小二乘回归估计残差方程，得到 θ 的无偏估计

DML过程示意图



“医学论文与统计分析”公众号

欢迎关注“医学论文与统

双重稳健的数学保证

偏差分解公式

$$\text{偏差} \propto (\hat{g} - g) \times (\hat{m} - m)$$

DML估计量的偏差与结果模型误差和暴露模型误差的乘积成正比。只要其中一个模型正确，乘积项就为零！

✔ 情况1

结果模型正确

$$\hat{g} = g \rightarrow \text{偏差} = 0 \times (\hat{m} - m) = 0$$

✔ 情况2

暴露模型正确

$$\hat{m} = m \rightarrow \text{偏差} = (\hat{g} - g) \times 0 = 0$$

✘ 情况3

两个都错

$$\hat{g} \neq g, \hat{m} \neq m \rightarrow \text{偏差} \neq 0$$

DML核心技术

- 机器学习
 - 解决高维、非线性、复杂数据
- Neyman正交化
 - 控制混杂
- 交叉拟合技术
 - 解决过拟合

欢迎关注“医学论文与统计分析”公众号

Neyman正交化：数学含义

三维空间想象

X轴 (混杂平面)

代表所有已知混杂因素(年龄、病情等)张成的平面

原始向量

A和Y向量都严重倾斜在X平面上(因为都严重依赖X)

正交化操作

投影操作

把A向量和Y向量垂直于X平面的分量投影出来 $\rightarrow$ A_resid和Y_resid

正交结果

A_resid和Y_resid都与X平面垂直(正交)

最终洞察

现在，分析两个都与混杂平面正交的干净向量之间关系，这个关系天然屏蔽了来自X平面的所有干扰。

通过机器学习预测"常规"，聚焦分析"意外"，从而在统计学上创造出一个"近似随机对照试验"的环境。

这是双重机器学习(DML)拥有强大去偏能力的核心秘密。

Neyman正交化: 数学含义

数学含义

在数学上, "正交"意味着两个向量垂直, 互不干扰。在这里, "正交化"意味着我们构造的估计量对于冗余参数的微小变化是"不敏感"或"垂直"的。

冗余参数的扰动, 不会(在一阶意义上)影响核心参数的估计。

数学表达

$$E[\psi(Y,A,X;\theta,\eta)|\eta] = 0$$

其中 ψ 是影响函数, η 是冗余参数。正交性意味着 ψ 对 η 的导数在真值处为0。

统计意义

- 估计量对冗余参数不敏感
- 即使 η 估计有偏, θ 估计仍可无偏
- 降低了对 nuisance 参数的估计要求
- 实现了半参数有效估计

★ 核心洞察

Neyman正交化通过构造一个对冗余参数不敏感的估计方程, 使得我们能够使用灵活的机器学习方法来估计 nuisance 函数, 而不用担心这些函数的估计误差会影响到我们关心的因果参数的估计。这正是DML能够使用机器学习并保持一致性的核心秘密。

DML的交叉拟合

从数据分割到最终估计的完整流程

1

数据分割

将样本随机分为K部分 $\{I_1, I_2, \dots, I_K\}$

2

模型训练

使用 I_{-k} 数据，将Y和A分别作为标签，X作为输入，训练ML模型

3

残差计算

将模型带入 I_k 中，得到残差Y和A的残差

4

重复迭代

重复以上步骤K次，得到每份数据的样本外残差

5

OLS回归

将Y残差作为被解释变量，A残差作为解释变量，回归得 θ 估计

算法优势

样本外预测

每个样本的预测都来自未见过该样本的模型，保证统计独立性

避免过拟合

交叉拟合消除了机器学习模型的过拟合偏差，保证一致性

灵活建模

允许使用任意复杂的机器学习模型，无需担心模型误设偏差

DML关键技术总结

- 将问题分解为两个预测任务
- 用ML捕捉X的复杂影响
- 在"干净"空间估计因果效应
- 交叉拟合避免过拟合偏误

双重机器学习通过Neyman正交化和交叉拟合，实现了在复杂高维数据中的稳健因果推断。它允许我们放心地使用复杂的机器学习模型，而不用担心因此引入统计偏误，为观察性研究提供了更可靠的因果推断工具。



谢谢!

双重稳健估计为观察性研究提供了更可靠的因果推断工具，
使得研究者能够从复杂数据中提取有效的因果结论。



双重稳健

双保险机制保证估计稳健性



机器学习

灵活建模捕捉复杂关系



因果推断

从数据到决策的桥梁