

缺失数据分析模式下因果推断

主要内容

- 1.因果推断中的缺失数据
- 2.缺失数据的分析及R语言操作
- 3.缺失数据的插补及R语言操作
- 4.缺失数据插补后的因果推断分析

缺失数据对因果推断的影响

- 少量比例缺失数据对结果影响不大
- 但当多数变量都少量缺失时，对回归分析影响较大
- 影响多因素回归的效能的是存在着缺失个案的数量


Id	A1	A2	A3	A4
患者1	1	1		1
患者2	1		1	1
患者3	1	1	1	

上方3个案的数据集，总缺失个案数是3

缺失数据对因果推断的影响

- 因果效应估计偏倚
- 数据不具代性
- 样本量减少，效应的置信区间变宽

缺失值忽略



若较大个案比例缺失，样本量变小，抽样误差变大，检验效能降低。

缺失产生机制

• Little和Rubin针对缺失数据，探讨缺失数据与目标变量是否有关，定义了3种不同的缺失机制。

MCAR

MAR

MNAR

完全随机缺失
(Missing Completely
At Random)：数据
的缺失与任何其它
变量无关

随机缺失(Missing
At Random)：数
据的缺失仅仅依
赖于已测变量。

非随机缺失(Not
Missing At Random)：
不完全变量中数据
的缺失，还与未测
变量或缺失值本身
有关。

缺失处理

- 若缺失个案总数不超过5%，不处理缺失现象
- 若一个变量缺失比较较高，达20-30%以上，则该变量后续不考虑纳入分析
- 若缺失个案总数超过5%或某变量缺失比例低于20%，则建议填补

缺失填补

- 观察性研究差异性分析不进行数据填补
- 回归分析之前需要进行填补
 - 单一填补
 - 多重填补

单一填补

- 方法:

- 平均值填补、中位数填补法、末次随访转结法、最差值法、基线转结法、随机森林等

- 缺点:

- 单次填补没有考虑缺失值的不确定性与关联性, 低估或高估数据的变异

MCAR


多重插补

- 多重插补 (Multiple Imputation) 是一种基于重复模拟的处理缺失值的方法。
- 它从一个包含缺失值的数据集中生成多组完整的数据集，然后对多个数据集进行合并分析

MAR

多重插补

多重填补为每个缺失值提供 m 个填补值，产生 m 个完整数据集，分别分析后再合并效应，该方法考虑缺失值的不确定性，提供无偏倚有效的估计，已成为处理缺失值的标准。




案例实操

- 运动与肺病之间的因果关系，数据集包含 18 个特征的数据（暴露：运动；结局：肺病；协变量：抑郁、性别、身高、体重）

列名	类型	代表含义
PA	连续变量	身体活动指数, 1-9分
lungfun	分类变量	0: 未患慢性肺病; 1: 患有慢性肺病
CESD	连续型变量	抑郁CESD总分, 0-30分
CESD_CAT	分类变量	0: 未抑郁; 1: 抑郁
sex	分类变量	0: 女性; 1: 男性
height	连续型变量	身高
weight	连续型变量	体重
hypertension	分类变量	0: 未患高血压; 1: 患有高血压
diabetes	分类变量	0: 未患糖尿病; 1: 患有糖尿病
heart_disease	分类变量	0: 未患心脏病; 1: 患有心脏病
residence	分类变量	0: 城市; 1: 农村
smoking	分类变量	0: 否; 1: 是
age	连续变量	年龄
education_level	分类变量	1: 低于初中学历; 2: 高中和职业培训; 3: 高等教育
cardio_metabolic	分类变量	0: 未患心脏代谢性共病; 1: 患心脏代谢性共病
alcohol	分类变量	0: 否; 1: 是
height	连续型变量	身高
weight	连续型变量	体重

数据缺失一览

id	sex	hypertension	diabetes	heart_disease	residence	marital	smoking	age	education_level	cardio_metabolic	alcohol
1	0	0	1	0	1	1	0	33	1	0	0
2	1	1	0	0	1	1	1	35	1	0	0
3	0	0	0	0	1	1	0	64	1	0	1
4	1	1	0	0	1	1	1	67	1	0	1
5	1	1	0	0	1	1	1	35	1	0	1
6	0	0	0	1	1	1	0	55	2	0	0
7	1	1	0	0	1	1	1	47	1	0	0
8	0	0	0	0	1	1	0	60	1	0	1
9	0	0	0	1	1	1	0	73	1	0	0
10	1	1	0	0	1	1	1	75	1	0	0
11	0	0	0	0	1	1	0	62	1	0	0
12	1	0	0	0	1	1	1	66	1	0	0
13	1	0	0	0	1	1	1	52	2	0	0
14	0	0	0	0	1	1	0	52	1	0	0
15	0	1	0	0	1	1	0	64	1	0	0
16	1	1	0	0	1	1	1	70	1	0	0
17	1	1	0	1	1	1	1	56	1	1	0
18	0	1	0	0	1	1	0	61	1	0	0






缺失数据分析-R操作

- 首先了解缺失数据状况




A screenshot of a data table with columns: sex, agegroup, disease, heart_disease, cholesterol, blood_sugar, smoking, age, cholesterol_level, heart_disease_level, and disease. The 'disease' column has two red boxes highlighting missing values.



缺失数据分析-R操作

- 缺失模式

```
# mice包  
library(mice)  
md.pattern(datana1)
```



缺失数据分析-R操作

- 各变量缺失比例

#各变量缺失的比例

```
var <- names(datana1)
```

```
tab <- list()
```

```
total <- nrow(datana1)
```

```
for (i in 1:length(var)){
```

```
  tab[i]=data.frame(Variables=var[i],
```

```
    Total=total,
```

```
    Freq=total-sum(is.na(datana1[,var[i]])),
```

```
    Missing=sum(is.na(datana1[,var[i]])),
```

```
    miss_p=sprintf("%0.2f",sum(is.na(datana1[,var[i]]))/total*100)) %>% list() }
```

```
#缺失值合并
```

```
na<-do.call(rbind, tab)
```


Variables	Total	Freq	Missing	miss_p
age	11342	11340	2	0.02
education_level	11342	11342	0	0.00
cardio_metabolic	11342	11042	300	2.65
alcohol	11342	10865	477	4.21
height	11342	11320	22	0.19
weight	11342	11326	16	0.14

缺失数据分析-R操作

- 各变量缺失比例可视化

#缺失比例可视化

```
mice_plot <- aggr(datana1, col=c('navyblue','yellow'),  
  numbers=TRUE, sortVars=TRUE,  
  labels=names(datana1), cex.axis=.7,  
  gap=5, ylab=c("Missing data", "Pattern"),)
```



缺失数据填补

填补方法

- 删除法
- 单一数值插补
- 基于机器学习填补（随机森林、KNN）
- 多重插补

多重插补注意事项

- 多重插补利用线性回归（包括PMM法）、logistic回归，多分类logistic回归对不同类型数据进行插补。
- 插补之前，需要在变量视图里定义数据类型。不然分类变量会插补连续型数据。
- 线性回归插补时可能会出现错误数据，建议用PMM插补法。

回归分析中的协变量

- 协变量是指研究前，研究者预计的、会对主要变量分析产生重要影响的因素。

- ✓ 这类变量可以是定性，也可以是定量的，抑或是等级资料。
- ✓ 其可以是人口统计学指标如年龄、体重、种族/民族等；
- ✓ 也可以是一些疾病预后因素如疾病分型、病程或病情严重程度；
- ✓ 当然还有一些其它因素如研究中心或研究者等

协变量与混杂偏倚

- 协变量对主要变量分析最重要的影响，是它往往会造成实验性研究干预措施疗效评价的偏倚。
- 协变量，往往成为混杂变量。



因果推断的研究

- 聚焦于关键1-2个变量（比如治疗措施、关键身体指标）对预后的影响
- 去分析年龄、性别对影响没有价值！
- 年龄、性别可能是协变量、混杂变量、是需要排除于它的干扰的。

多因素回归分析

单因素回归: $Y = \alpha + \beta X_1 + \epsilon$

多因素回归: $Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$




实际上, 多因素回归的吸烟效应就从单因素的 β 变为多因素的 β_1 。
年龄造成的偏倚被剔除, 最后得到了 β_1 更准确地估计了吸烟对死亡的影响。

R语言操作

- 缺失数据因果推断的回归分析

缺失数据的倾向性得分



如何实现以上倾向得分匹配的过程？

MatchIt包 

MatchThem包 

MatchThem:: Matching and Weighting after Multiple Imputation

by Farhad Pishgar, Noah Greifer, Clémence Leyrat and Elizabeth Stuart

MatchThem包

- MatchThem包
联合MICE包
 - ✓ 缺失数据填补
 - ✓ 匹配/加权
 - ✓ 汇总分析

Function	Input	Output	Extends	Description
matchthem()	mids object	mimids object	MatchIt::matchit()	Performs the requested form of matching on the imputed datasets
weightthem()	mids object	wimids object	WeightIt::weightit()	Performs the requested form of weighting on the imputed datasets
complete()	mimids or wimids object	data.frame ¹	mice::complete()	Extracts one or more imputed datasets from the supplied input along with the outputs of the matching or weighting procedure
with()	mimids or wimids object	mimira object	mice::with()	Runs the supplied analysis model on each imputed dataset, incorporating the outputs of the matching or weighting procedure
pool()	mimira object	mimipo object ²	mice::pool()	Pools the coefficients and standard errors estimated across the imputed datasets to a single set of coefficient and standard error estimates


案例：运动与肺病之间的因果关系

欢迎关注“因果推断与机器学习”公众号


- 数据集包含 18 个特征的数据（暴露：运动；结局：肺病；协变量：抑郁、性别、身高、体重）
- 该数据集的变量存在缺失数据。

id	PA	lungfun	CESD	CESD_CAT	sex	hypertension	diabetes	heart_disease	asthma	smoking	age	education_level	cardio_metabolic	alcohol	height	weight
1	1	0	4	0	0	0	1	0	1	0	35	1	0	0	168.2	81.6
2	2	1	4	0	1	1	0	0	1	1	35	1	0	1	151.2	46.6
3	1	0	8	0	0	0	0	0	1	0	64	1	0	0	163.0	59.2
4	3	0	4	0	1	1	0	0	0	1	67	1	0	1	173.0	88.8
5	1	0	4	0	1	1	0	0	1	1	35	1	0	1	159.6	74.4
6	1	0	8	0	0	0	0	1	1	0	33	1	0	0	175.0	90.2
7	0	1	12	1	1	1	0	0	0	1	67	1	0	1	156.2	84.2
8	2	0	8	0	0	0	0	0	0	0	65	1	0	1	162.6	80.8
9	4	0	21	1	0	0	0	1	1	0	73	1	0	0	147.0	50.0
10	2	0	16	1	1	1	0	0	1	1	75	1	0	0	156.0	69.7
11	1	0	NA	NA	0	0	0	0	1	0	31	1	0	0	152.7	43.8
12	0	0	NA	NA	1	1	0	0	1	1	66	1	0	1	142.1	40.0
13	2	0	10	1	0	0	0	0	1	0	62	1	0	0	165.0	83.0
14	1	0	0	0	1	0	0	0	1	1	66	1	0	0	153.0	50.8
15	0	0	3	0	1	0	0	0	0	1	32	1	0	0	151.8	36.3
16	3	0	12	1	0	NA	NA	NA	NA	0	32	1	0	0	173.0	83.2
17	0	0	11	1	0	1	0	0	1	0	64	1	0	0	167.0	77.0
18	3	0	16	1	1	1	0	0	0	1	72	1	0	1	157.6	49.7
19	0	0	NA	NA	1	0	0	0	0	1	64	1	0	1	NA	NA
20	2	0	12	1	1	1	0	1	1	1	68	1	1	0	157.0	39.6
21	1	0	19	1	0	1	0	0	1	0	61	1	0	0	176.2	72.6

案例：运动与肺病之间的因果关系



缺失数据倾向得分匹配分析过程



R语言方法基本过程

1. R语言数据导入整理
2. 填补缺失数据
3. 倾向得分匹配
4. 匹配后的数据分析
5. 倾向得分加权
6. 加权后的数据分析

欢迎关注“医学论文与统计分析”公众号

欢迎关注“医学论文与统计分析”公众号

1. R语言数据导入整理

加载MatchThem包

library(MatchThem)

导入肺病数据

导入数据

datana <- read.csv("data_missing.csv")

查看数据

summary(datana)

查看数据类型

str(datana)

3. 填补缺失数据

#使用 mice 包对肺炎数据集进行多重填补

library(mice)

multi_imputed<-mice(datana, m=5, seed = 123) #生成 5 个填补数据集

```
> imputed.datasets <- mice(osteoarthritis, m = 5)
```

```
iter imp variable
1 1 BMI RAC SMK KOA
1 2 BMI RAC SMK KOA
1 3 BMI RAC SMK KOA
1 4 BMI RAC SMK KOA
1 5 BMI RAC SMK KOA
2 1 BMI RAC SMK KOA
2 2 BMI RAC SMK KOA
2 3 BMI RAC SMK KOA
2 4 BMI RAC SMK KOA
2 5 BMI RAC SMK KOA
3 1 BMI RAC SMK KOA
3 2 BMI RAC SMK KOA
3 3 BMI RAC SMK KOA
3 4 BMI RAC SMK KOA
3 5 BMI RAC SMK KOA
4 1 BMI RAC SMK KOA
4 2 BMI RAC SMK KOA
4 3 BMI RAC SMK KOA
4 4 BMI RAC SMK KOA
4 5 BMI RAC SMK KOA
5 1 BMI RAC SMK KOA
5 2 BMI RAC SMK KOA
5 3 BMI RAC SMK KOA
5 4 BMI RAC SMK KOA
5 5 BMI RAC SMK KOA
```

- 上面的代码生成 5 个填补数据集并将它们保存在 `multi_imputed` 对象中。
- 该对象将提供给 `MatchThem` 函数，以在填补数据集中执行匹配。

倾向得分匹配

```
# 使用matchthem()来匹配多个填补数据集
matched.datasets <- matchthem(
  lungfun ~
  CESD_CAT+sex+age+hypertension+diabetes+heart_disease+smoking,
  datasets = multi_imputed,
  approach = 'within', #内部匹配
  method = 'nearest', #邻近匹配
  caliper = 0.2, #倾向得分标准差 5%
  ratio = 2) #2:1 的匹配比
```

参数说明:

- **formula**: 这个参数采用了R公式 $z \sim x1 + x2$ 的常用语法, 其中 z 是一个二进制曝光指示器, $x1$ 和 $x2$ 是潜在的混淆因子。
- **datasets**: 此参数指定包含曝光指示器和公式中调用的潜在混杂因素的数据集。
- **approach**: 此参数指定匹配方法。有“within”和“across”两种方法。
- **method**: 此参数指定匹配方法。例如“nearest”、“exact”、“full”等。
- **distance**: 此参数指定了用于估计距离度量的方法, 默认值是logistic回归。
- **caliper**: 对于允许的方法, 匹配时使用的卡钳宽度。
- **ratio**: 对于允许的方法, 有多少个控制单元应与每个治疗单元以 $k:1$ 匹配。对于 $1:1$ 匹配, 默认值为1。
- **discard**: 此参数指定是否在匹配前丢弃不在距离分数支持度范围内的观察值, 并且不允许在匹配过程中使用这些观察值。默认值为“none”

approach参数说明

- **within法**: 使用观察到的和插补的协变量值在**每个插补数据集中**进行匹配或加权, 并且将m个匹配或加权数据集中的每个数据集中估计的暴露效应合并在一起。
- **across法**: 对插补数据集的倾向评分**取平均值**, 并使用该平均测量值在插补数据集中进行匹配或加权。最后, 将通过分析匹配或加权数据集获得的估计暴露效应汇总在一起。
- 在许多常见场景中, **与within法相比, across法的统计性能较差**。

• method参数说明

允许使用的方法有：最近匹配的“nearest”（默认情况下使用倾向得分）、最优配对匹配的“optimal”、最优全匹配的“full”、遗传匹配的“genetic”、粗略精确匹配的“cem”、精确匹配的“exact”、心量和模板匹配的“cardinality”和子分类匹配的“subclass”。

• caliper参数说明

卡钳值越大，匹配成功的数量越多，但是组间均衡性会变弱。卡钳值的设置，R语言卡钳值一般设为**0.2个标准差**；SPSS卡钳值一般设为**0.02**

4. 倾向得分匹配

评价匹配效果

library(cobalt)

bal.tab(matched.datasets, stats = c("m", "ks"), imp.fun = "max") #m: 绝对标准化均值差, ks: Kolmogorov-Smirnov (KS) 统计量

Balance summary across all imputations

	Type	Max. Diff.	Adj	Max. KS	Adj
distance	Distance	0.0019		0.0075	
CESD_CAT	Binary	0.0080		0.0080	
sex	Binary	0.0090		0.0090	
age	Contin.	0.0204		0.0130	
hypertension	Binary	0.0228		0.0228	
diabetes	Binary	0.0090		0.0090	
heart_disease	Binary	0.0055		0.0055	
smoking	Binary	0.0090		0.0090	

Average sample sizes across imputations


	0	1
All	9438.	2009
Matched (ESS)	3786.81	1994
Matched (Unweighted)	3882.	1994
Unmatched	5556.	15

在匹配的所有填补数据集中的每个协变量后生成最大的绝对标准化均值差 (ASMD) 和 Kolmogorov-Smirnov (KS) 统计量, 表明数据集中的最差平衡。

4. 倾向得分匹配

匹配效果可视化

```
love.plot(bal.tab(matched.datasets, m.threshold=0.1),  
stat = "mean.diffs", grid=TRUE, stars="raw", abs = F)
```



5. 匹配后数据分析

```
# 对每一份匹配后的填补数据集进行二元logistic回归分析  
install.packages("survey")  
library(survey)  
matched.models <- with(matched.datasets,  
                        svyglm(lungfun ~ PA, family = quasibinomial()),  
                        cluster = TRUE)
```

5. 匹配后数据分析

利用MICE包将每份填补数据集估计的效应值进行综合

```
match.results <- pool(matched.models)
```

```
summary(match.results)
```

	term	estimate	std.error	statistic	df	p.value	2.5 %	97.5 %
1	(Intercept)	-0.1909297	0.08568358	-2.2283112	57.40984	0.0297918	-0.3624815	-0.01937781
2	OSP1	-0.1193530	0.13677398	-0.8726292	63.78518	0.3861384	-0.3926081	0.15390219

两大核心函数

- **1. Matchthem**

缺失数据填补+倾向得分匹配

- **2. Weightthem**

缺失数据填补+倾向得分加权

5. 倾向得分加权

使用 `weightthem()` 来加权多个填补数据集

```
weighted.datasets <- weightthem(OSP ~ AGE + SEX + BMI + RAC + SMK,  
                                datasets = imputed.datasets,  
                                approach = 'across',  
                                method = 'ps',  
                                estimand = 'ATE')
```

#估计值样本的平均治疗效果 (ATE)

5. 倾向得分加权

参数说明:

- **formula**: 这个参数采用了R公式 $z \sim x1 + x2$ 的常用语法, 其中 z 是一个二进制曝光指示器, $x1$ 和 $x2$ 是潜在的混淆因子。
- **datasets**: 此参数指定包含曝光指示器和公式中调用的潜在混杂因素的数据集。
- **approach**: 此参数指定匹配方法。有 “within” 和 “across” 两种方法。
- **method**: 倾向得分计算方法。
- **estimand**: 目标人群

5. 倾向得分加权

approach参数说明

- **within法**: 使用观察到的和插补的协变量值在**每个插补数据集中**进行匹配或加权, 并且将m个匹配或加权数据集中的每个数据集中估计的暴露效应合并在一起。
- **across法**: 对插补数据集的倾向评分**取平均值**, 并使用该平均测量值在插补数据集中进行匹配或加权。最后, 将通过分析匹配或加权数据集获得的估计暴露效应汇总在一起。
- 在许多常见场景中, **与within法相比, across法的统计性能较差。**

5. 倾向得分加权

- **method参数说明**

计算倾向得分方法，如 “ps” , “gbm” , “cbps” , “super” , and “bart” 等，默认是ps，即logistic回归计算

- **estimand 参数说明**

目标人群，包括ATT、ATE、ATM、ATC等

5. 倾向得分加权

评价加权效果

```
library(cobalt)
```

```
bal.tab(weighted.datasets, stats = c('m', 'ks'), imp.fun = 'max') #m: 绝对标准化均值差, ks: Kolmogorov-Smirnov (KS) 统计量
```

Balance summary across all imputations

	Type	Max.Diff.Adj	Max.KS.Adj
prop.score	Distance	0.0662	0.1112
AGE	Contin.	0.0116	0.0487
SEX_2	Binary	0.0323	0.0323
BMI	Contin.	0.1405	0.1072
RAC	Contin.	0.1700	0.0539
SMK	Binary	0.0860	0.0860

Average effective sample sizes across imputations


	0	1
Unadjusted	2106.	479.
Adjusted	2021.76	110.47

在加权的所有填补数据集中的每个协变量后生成最大的绝对标准化均值差 (ASMD) 和 Kolmogorov-Smirnov (KS) 统计量, 表明数据集中的最差平衡。

5. 倾向得分加权

加权效果可视化

```
love.plot(bal.tab(weighted.datasets, m.threshold=0.1),  
stat = "mean.diffs", grid=TRUE, stars="raw", abs = F)
```



6. 加权后数据分析

对每一份加权后的填补数据集进行二元logistic回归分析

library(survey)

weighted.models <- with(weighted.datasets,
 svyglm(lungfun ~ PA, family = quasibinomial()))

6. 加权后数据分析

将每份填补数据集估计的效应值进行综合

```
weighted.results <- pool(weighted.models)
```

```
summary(weighted.results, conf.int = TRUE)
```

	term	estimate	std.error	statistic	df	p.value	2.5 %	97.5 %	conf.low	conf.high
1	(Intercept)	-0.3223914	0.04503120	-7.159289	11441.53	8.606379e-13	-0.4106603	-0.2341225	-0.4106603	-0.2341225
2	PA	0.1771709	0.01877628	9.435885	11441.53	4.624009e-21	0.1403661	0.2139756	0.1403661	0.2139756

缺失数据双重稳健估计方法——靶向最大似然估计法TMLE

TMLE

➤ 潜在结果模型 (Potential Outcomes Framework, 即反事实模型)

- $Y(1)$: 个体在接受处理时的结果
- $Y(0)$: 个体在不接受处理时的结果

➤ 因果推断的核心任务是估计因果效应，使用双重稳健估计方法可以估计多种因果效应指标，包括：

- 因果风险差 (RD)、因果风险比 (RR)、因果优势比 (OR)、条件平均处理效应 (CATE)、处理组\未处理组的平均处理效应 (ATT\ATC)
- 其中平均因果效应 (Average Treatment Effect) 是最常用的估计指标

$$ATE = E[Y(1) - Y(0)]$$

在整个人群中，每个人都接受处理和每个人都不接受处理的平均结果会相差多少？

tmle 包

- tmle 包是单时间点 (point treatment) 因果推断中最经典的 TMLE 实现，专注于估计平均治疗效果 (ATE) 或其他边际参数 (如风险差、相对风险、优势比)，在观测数据中控制基线混杂 (baseline confounding)。
- 它提供双重稳健估计，同时输出 IPTW (逆概率加权) 和 G-computation (参数化 G-公式) 作为对比。
- 适用数据类型
 - 观测数据 (observational data)，非随机化。
 - 二元治疗 A (0/1)。基线协变量 W (无时间依赖)。
 - 结局 Y ：二元、连续 (支持 bounded continuous)。

多重插补的TMLE分析

