

# 因果推断模型与机器学习方法



郑老师团队



时间：2026

“因果推断模型与机器学习方法”训练营--理论篇

# 第一讲 因果推断概述

医学论文与统计分析”公众号

# 因果推断与R语言入门



郑老师团队



时间：2025

“因果推断模型入门”

欢迎关注“医

# 第一讲 因果推断基本理论与方法

医学论文与统计分析”公众号

# 本讲内容

- 流行病学任务与统计方法
- 混杂偏倚及其控制
- 因果推断基本理论与常见方法



## 第1节 流行病学任务与统计方法



# 1.1 流行病学在做什么？

## • 设计

- 流行病学研究设计是研究的基石
- 研究者需根据研究目的选择最合适的设计类型（队列研究、病例对照研究、横断面研究，或随机对照试验）

## • 测量

- 核心在于对研究变量（特别是暴露因素和结局事件）进行准确、可靠的定义和量化。
- 明确操作定义（如“高血压”的标准、“吸烟”的定义）、选择测量工具（问卷、实验室检测、影像学检查）
- 精确测量发病率、患病率、死亡率、暴露水平等指标

## • 评价

- 评估暴露与结局的关联强度（如相对危险度RR、比值比OR），并识别和控制潜在的混杂偏倚。
- 评价研究结果的真实性和可推广性（内部效度：研究本身结论是否可靠）和可推广性（外部效度：结果能否外推到其他人群）。

# 流行病学研究设计的基本原则

- 科学医学研究，一定的原则非常关键

- 观察的人群是从总体随机抽样获得：**随机**

- 需要一个群体作为比较组：**对照**

- 对照组和目标组可比的（人群特征相似）：**均衡**

- 需要一定的样本量并能重复试验：**重复**

## 1.2 流行病学的任务与统计应用

- 流行病学的任务

- 描述：揭示疾病分布（时间、地点、人群）
- 预测：估计未来疾病负担与传播趋势
- 因果推断：验证干预措施（如疫苗）的效果与机制

# (1) 描述

- **描述：**描述性流行病学


- 描述群体的特征、估计总体
- 分析群体的差异性
- 进行群体归类与聚类
- 分析指标的关联性

# 统计学过程

- 统计描述
- 总体均数、总体率95%置信区间估计
- t检验、方差分析、卡方检验、相关分析
- 可用回归来进行标准化或者探索关联性
- 可用机器学习来开展聚类分析

## (2) 预测模型

- 预测模型包括诊断模型和预后模型。
  - **诊断模型**关注的是基于研究对象的临床症状和特征，诊断当前患有某种疾病的概率
  - **预后模型**关注的是在当下的状态下，未来某段时间**个体或者群体**疾病发生、死亡，伤残以及出现并发症等结局的概率。




# 诊断模型

## 诊断模型 (Diagnostic Model)

- 1、定义：用来预测个体患者患有某种疾病的概率；
  - 1) 特定群体：表现出某种症状的患者；
  - 2) 结局变量：患者当前状态（是否患病）
- 2、诊断模型是诊断试验准确性研究的延伸

# 诊断模型




# 预后模型

## 预后模型 (Prognostic Model)

pro: before; gnostic: to know (预后, 预知以后) :  
用来预测个体或者群体在未来某一时刻发生某件事的概率。

- 1) 患者处于同样起始状态 (如确诊为某疾病)
- 2) 结局变量: 患者将来是否发生某一事件 (如: 死亡)
- 3) 基线时间点: 有时间维度 (1, 3, 5年生存率)

# 预后模型




# 群体模型方法

- 传染病动力学模型
- 时间序列分析
- BAPC模型
- ....

表 9 2022、2023 年云南省各月戊肝病例数的预测结果<sup>①</sup>

| 日期 <sup>②</sup>      | 预测值 <sup>③</sup> | 实际值 <sup>④</sup> | 绝对误差 <sup>⑤</sup> | 相对误差 <sup>⑥</sup>   | 95%置信区间 <sup>⑦</sup> |                 |
|----------------------|------------------|------------------|-------------------|---------------------|----------------------|-----------------|
|                      |                  |                  |                   |                     | 上限 <sup>⑧</sup>      | 下限 <sup>⑨</sup> |
| 2022-01 <sup>⑩</sup> | 94 <sup>⑪</sup>  | 89 <sup>⑫</sup>  | 5 <sup>⑬</sup>    | 0.056 <sup>⑭</sup>  | 130 <sup>⑮</sup>     | 58 <sup>⑯</sup> |
| 2022-02 <sup>⑩</sup> | 80 <sup>⑪</sup>  | 104 <sup>⑫</sup> | -24 <sup>⑬</sup>  | -0.231 <sup>⑭</sup> | 118 <sup>⑮</sup>     | 43 <sup>⑯</sup> |
| 2022-03 <sup>⑩</sup> | 120 <sup>⑪</sup> | 123 <sup>⑫</sup> | -3 <sup>⑬</sup>   | -0.024 <sup>⑭</sup> | 159 <sup>⑮</sup>     | 81 <sup>⑯</sup> |
| 2022-04 <sup>⑩</sup> | 107 <sup>⑪</sup> | 120 <sup>⑫</sup> | -13 <sup>⑬</sup>  | -0.108 <sup>⑭</sup> | 150 <sup>⑮</sup>     | 64 <sup>⑯</sup> |
| 2022-05 <sup>⑩</sup> | 115 <sup>⑪</sup> | 139 <sup>⑫</sup> | -24 <sup>⑬</sup>  | -0.173 <sup>⑭</sup> | 159 <sup>⑮</sup>     | 72 <sup>⑯</sup> |
| 2022-06 <sup>⑩</sup> | 109 <sup>⑪</sup> | 149 <sup>⑫</sup> | -40 <sup>⑬</sup>  | -0.268 <sup>⑭</sup> | 154 <sup>⑮</sup>     | 65 <sup>⑯</sup> |
| 2022-07 <sup>⑩</sup> | 119 <sup>⑪</sup> | 139 <sup>⑫</sup> | -20 <sup>⑬</sup>  | -0.144 <sup>⑭</sup> | 164 <sup>⑮</sup>     | 73 <sup>⑯</sup> |
| 2022-08 <sup>⑩</sup> | 120 <sup>⑪</sup> | 126 <sup>⑫</sup> | -6 <sup>⑬</sup>   | -0.048 <sup>⑭</sup> | 166 <sup>⑮</sup>     | 74 <sup>⑯</sup> |
| 2022-09 <sup>⑩</sup> | 95 <sup>⑪</sup>  | 119 <sup>⑫</sup> | -24 <sup>⑬</sup>  | -0.202 <sup>⑭</sup> | 142 <sup>⑮</sup>     | 47 <sup>⑯</sup> |



## 个体预测模型

- 个体预测模型统计过程包括以下几个步骤：
  - 数据拆分（必要时）
  - 构建模型（logistic、Cox回归、机器学习方法）
  - 模型评价：AUC，校准度、DCA等
  - 模型验证：内、外部验证

# 个体化预测模型方程

- 定量结局（线性回归）

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots \cdots + \beta_m X_m + e$$

- 二分类结局（logistic回归）

$$P = \frac{1}{1 + e^{-(\alpha + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_m x_m)}}$$

- 若群体实际发生阳性实际数与预测阳性事件数(NP)越接近，则预测模型越逼真。

# 预测模型的案例

## 儿童百日咳发病的危险因素分析及列线图预测模型构建

史倩倩, 刘静静

(南京医科大学附属儿童医院/南京市儿童医院 感染科, 江苏 南京, 210019)

**摘要:** **目的** 探讨儿童百日咳发病的危险因素, 构建儿童百日咳发病风险的列线图预测模型。 **方法** 选取2024年2—6月收治的175例迁延性咳嗽患儿作为建模组, 根据是否确诊百日咳, 将其分成百日咳组和对照组。比较2组患儿的一般情况、临床特征及实验室检查指标水平, 采用Logistic回归模型筛选儿童百日咳的危险因素, 构建列线图预测模型, 并进行内部验证。另选取2024年7—8月收治的53例迁延性咳嗽患儿作为验证组, 对列线图模型进行外部验证。 **结果** 建模组175例患儿中, 52例(29.71%)确诊百日咳。百日咳组室内通风差者占比、发病前3周与咳嗽患者接触者占比、发病前3周被动吸烟者占比、未接种百日咳疫苗者占比及血小板水平均高于对照组, 差异有统计学意义( $P < 0.05$ )。多因素Logistic回归分析结果显示, 室内通风差、发病前3周与咳嗽患者接触、发病前3周被动吸烟、未接种百日咳疫苗为儿童百日咳发病的独立危险因素( $OR = 2.983, 4.943, 3.998, 5.943, P < 0.05$ )。据此构建预测儿童百日咳发病的列线图模型。内部验证结果显示, 该列线图模型预测儿童百日咳发病的曲线下面积(AUC)为0.824, 灵敏度为82.70%, 特异度为74.80%, 拟合优度Hosmer-Lemeshow检验示 $\chi^2 = 7.591, P = 0.425$ ; 外部验证结果显示, AUC为0.799, 灵敏度为80.80%, 特异度为63.40%, 拟合优度Hosmer-Lemeshow检验示 $\chi^2 = 10.369, P = 0.169$ 。 **结论** 室内通风差、发病前3周与咳嗽患者接触、发病前3周被动吸烟、未接种百日咳疫苗为儿童百日咳发病的独立危险因素, 据此构建的列线图预测模型能够有效预测儿童百日咳发病风险。

**关键词:** 儿童; 百日咳; 影响因素; 列线图模型; 被动吸烟; 百日咳疫苗; 迁延性咳嗽; 预测效能

**中图分类号:** R 725.1; R 473.72; R 319 **文献标志码:** A **文章编号:** 1672-2353(2025)06-056-06 **DOI:** 10.7619/jcmp.20244333

# 预测模型的案例

- 流行病学

- 选取2024年2-6月在本院就诊的175例迁延性咳嗽（咳嗽持续时间>2周）患儿作为建模组，构建预测儿童百日咳发病的列线图模型。另选取2024年7-8月本院收治的53例迁延性咳嗽患儿作为验证组，对模型进行外部验证。

- 统计学

- 应用spss25.0软件对数据进行统计学处理。符合正态分布的计量资料以( $\bar{x} \pm s$ )描述，比较采用t检验；计数资料以[n(%)]描述，比较采用卡方检验。通过logistic回归模型确定儿童百日咳发病的影响因素，并利用R软件中的rms包构建儿童百日咳发病的列线图预测模型。预测模型的区分度和一致性分别采用受试者工作特征。

# 影响因素分析

- 建模组175 例患儿中， 52例被诊断为百日咳（百日咳组），百日咳检出率为29.7%。
- 室内通风差、发病前3周与咳嗽患者接触、发病前3周被动吸烟、未接种百日咳疫苗为儿童百日咳发病的独立危险因素（OR=2.98、4.94、4.00、5.94， $P<0.05$ ）。

表3 儿童百日咳发病的多因素 Logistic 回归分析

| 变量           | B      | SE    | Wald $\chi^2$ | P      | OR    | 95% CI         |
|--------------|--------|-------|---------------|--------|-------|----------------|
| 室内通风差        | 1.093  | 0.402 | 7.398         | 0.007  | 2.983 | 1.357 ~ 6.557  |
| 发病前3周与咳嗽患者接触 | 1.598  | 0.442 | 13.064        | <0.001 | 4.943 | 2.078 ~ 11.756 |
| 发病前3周被动吸烟    | 1.386  | 0.401 | 11.919        | 0.001  | 3.998 | 1.820 ~ 8.780  |
| 未接种百日咳疫苗     | 1.782  | 0.441 | 16.366        | <0.001 | 5.943 | 2.506 ~ 14.093 |
| 常数           | -3.856 | 0.633 | 37.153        | <0.001 | 0.021 | —              |

# 预测模型列线图






图1 儿童百日咳发病的列线图预测模型

# AUC面积与校准度分析

- ROC 曲线显示，预测模型儿童百日咳发病的曲线下面积（AUC）为0.83（95%CI: 0.75-0.89），拟合优度Hosmer-Lemshow检验结果显示 $\chi^2 = 7.59$ ， $P=0.425$ ，提示该列线图模型对儿童百日咳发病的预测效果较好



A




B

A: ROC 曲线; B: 校准曲线。

# 外部验证分析

外部数据验证分析显示，预测模型儿童百日咳发病的曲线下面积（AUC）为 0.80（95%CI: 0.73-0.87），拟合优度Hosmer-Lemshow检验结果显示 $\chi^2 = 1037$ ， $P=0.169$ ，提示外部数据证明对儿童百日咳发病的预测效果较好



# (3) 因果推断

## ➤ 什么是“因果推断”？

- 流行病学研究的核心任务
- 因果推断的核心问题是：“如果实施某个干预，会不会带来不同的结果？”
- 与预测不同，预测只估计某个结果是否发生，因果推断要**估计干预与未干预的潜在结果差异**

## ➤ 统计方法在“因果推断”任务中的主要应用：

- 在观察性研究中，由于分组不均衡，导致干扰性因素存在，从而引起混杂偏倚 (confounding bias)，需要**对混杂进行校正**，从而得到准确的因果效应

# 因果推断的流行病学研究类型

- 因果推断两类流行病学方法

- 实验性研究

- RCT: 实验组 vs 安慰剂组 → 发生率差异

- 分析性流行病学研究

- 队列研究: 暴露组 vs 对照组的长期癌变风险
    - 病例对照: 宫颈癌患者 vs 健康对照 的性行为历史



# RCT研究的统计方法

- t检验
- F检验
- 卡方检验
- 秩和检验
- logRank检验

实验组vs 对照组  
比较均数、有效率、发病率

RCT方案分组均衡，  
无需复杂方法即可证明因果关系

# 案例分析

- 1. 实验性研究

欢迎关注“医学论文与统计”公众号

## 加味逍遥胶囊治疗轻中度抑郁症的随机对照临床研究

周杰<sup>1</sup>, 苏芮<sup>2</sup>, 李涛<sup>3</sup>, 曹欣冬<sup>4</sup>, 韩振蕴<sup>5</sup>, 林彬<sup>5</sup>, 郭荣娟<sup>5</sup>, 范吉平<sup>2</sup>

「统计分析」公众号

# 本研究PI0CS

- **Study design:** 本研究为多中心、随机、双盲、安慰剂双模拟、平行对照临床研究
- **Patient:** 中度抑郁症患者
- **Intervention:** 中药组 加味道遥胶囊
- **Outcome:** 采用 汉密尔顿抑郁量表(HAMD)
- **Control:** 西药组
- 样本量1:1 共计 127例

# 统计学方法

- 采用Epidata 3.1数据库软件，采取两次录入的方式；
- 盲态审核及揭盲后由北京调元大济科技有限责任公司统计师进行分析；
- 用SAS 9.1软件包，计数资料用检验分析，计量资料用t检验分析，等级资料则采用z检验（秩和）分析
- 以 $P < 0.05$ 为差异有统计学意义。

# 第一个结果：基线比较

- 两组人口学资料、量表各因子和中医证候等基线资料比较，均无统计学差异（ $P>0.05$ ），具有可比性。

## 第二个结果 差异性比较（定量）

欢迎关注“医学

表1 不同时点两组HAMD量表总分组内比较( $\bar{x} \pm s$ , 分)

| 组别  | 例数 | 时间(周) | HAMD总分     | t值    | P值   |
|-----|----|-------|------------|-------|------|
| 中药组 | 65 | 0     | 25.08±4.16 |       |      |
| 西药组 | 62 |       | 25.10±5.20 |       |      |
| 中药组 | 62 | 2     | 18.87±5.05 | 10.06 | 0.00 |
| 西药组 | 57 |       | 19.23±5.09 | 9.49  | 0.00 |
| 中药组 | 60 | 4     | 15.00±5.72 | 13.19 | 0.00 |
| 西药组 | 52 |       | 15.17±5.45 | 14.79 | 0.00 |
| 中药组 | 60 | 8     | 11.12±5.31 | 17.34 | 0.00 |
| 西药组 | 52 |       | 10.63±5.51 | 18.65 | 0.00 |

表2 不同时点两组HAMD量表组间差值比较( $\bar{x} \pm s$ , 分)

| 组别  | 例数 | 时间(周) | HAMD总分差值(分) | t值   | P值   |
|-----|----|-------|-------------|------|------|
| 中药组 | 62 | 2     | 5.97±4.67   | 0.00 | 1.00 |
| 西药组 | 57 |       | 5.95±4.73   |      |      |
| 中药组 | 60 | 4     | 9.93±5.83   | 0.00 | 1.00 |
| 西药组 | 52 |       | 10.23±4.99  |      |      |
| 中药组 | 60 | 8     | 13.82±6.17  | 0.00 | 1.00 |
| 西药组 | 52 |       | 14.77±5.71  |      |      |

## 第三个结果 差异性比较（等级）

欢迎来

表3 不同时间两组HAMD量表疗效评定比较 [例(%)]

| 组别  | 例数 | 时间(周) | 临床治愈     | 显效         | 有效         | 无效         | Z值   | P值   |
|-----|----|-------|----------|------------|------------|------------|------|------|
| 中药组 | 62 | 2     | 5 (8.06) | 0 (0.00)   | 16 (25.81) | 41 (66.13) | 0.37 | 0.80 |
| 西药组 | 57 |       | 3 (5.26) | 0 (0.00)   | 15 (26.32) | 39 (68.42) |      |      |
| 中药组 | 60 | 4     | 1 (1.67) | 0 (0.00)   | 43 (71.67) | 16 (26.67) | 1.73 | 0.63 |
| 西药组 | 52 |       | 2 (3.85) | 1 (1.92)   | 35 (67.31) | 14 (26.92) |      |      |
| 中药组 | 60 | 8     | 0 (0.00) | 18 (30.00) | 33 (55.00) | 9 (15.00)  | 3.86 | 0.28 |
| 西药组 | 52 |       | 2 (3.85) | 13 (25.00) | 33 (63.46) | 4 (7.69)   |      |      |

“统计分析”公众号

## (2) 观察性研究的因果推断

- 因果推断的统计学方法演变
  - 差异性分析(国内2000年之前)
  - 回归分析(国内2000之后)
  - 倾向得分方法(国内2015之后)
  - 机器学习方法(国内2025之后)

# (1) 差异性分析方法

- 直接比较暴露组与非暴露组的结局均值/率差异，未控制任何混杂因素。
  - 仅计算两组的粗结局差异（如率差RD=暴露组率-非暴露组率）。
  - 对组间基线变量进行标准化（如年龄标准化死亡率），但仍不控制混杂的交互作用。
- 优点：
  - 计算简单，易于理解，适合初步探索性分析。
- 缺点：
  - 严重依赖组间基线可比性（若暴露组与非暴露组混杂分布不均衡，如用药组更年轻、病情更轻，则差异反映的是混杂而非干预效应）；
  - 无法区分相关性与因果性，结论易被反向因果或混杂因素扭曲。

# 常见错误

## 观察性研究只做简单差异性比较下统计结论

一项回顾性队列研究，常规治疗组(对照组)与中药治疗组(治疗组)。比较中、西医治疗的效果。

两组患者的有效率情况采用卡方检验，差异有统计学意义 ( $P < 0.01$ )，该论文认为中医药治疗效果较好。

表3 两组治愈率比较(例%)

| 组别  | 例数 | 治愈        | 好转        | 无效        | $\chi^2$ | $P$   |
|-----|----|-----------|-----------|-----------|----------|-------|
| 治疗组 | 91 | 59(64.8%) | 20(21.9%) | 12(13.2%) | 15.013   | <0.01 |
| 对照组 | 89 | 32(35.9%) | 42(47.2%) | 15(16.9%) |          |       |

## (2) 回归方法

➤ 通过统计模型调整混杂因素，在混杂变量的每个水平上平衡暴露与结局。

➤ 优点：

➤ 直接控制已知混杂因素，调整后结果更接近因果效应；

➤ 回归法可量化混杂效应大小（如回归系数 $\beta_2$ 表示混杂变量对结局的影响）；

➤ 计算透明，结果易于解释（如OR/HR/RD的临床意义明确）。

➤ 缺点：

➤ 依赖模型正确设定；

➤ 回归法需满足线性假设（如结局与暴露为线性关系，实际可能非线性）。

## (2) 回归方法

➤ 根据结局类型的不同可以讲回归分为逻辑回归、线性回归和Cox回归。

### 老年膝骨关节炎患者社会衰弱现状及影响因素分析

北大中文核心

CSCD 扩展库

孙启会<sup>1</sup> 刘玉娜<sup>1</sup> 施姜华<sup>1</sup> 唐胜斌<sup>1</sup> 刘宁<sup>2</sup> 闫静<sup>2</sup>✉

1.泰安八十八医院骨科 2.中国人民解放军第九六〇医院

**摘要:** [目的]分析影响老年膝骨关节炎(knee osteoarthritis, KOA)患者社会衰弱(social frailty, SF)的相关因素。[方法]收集2024年3月—2025年3月在中国人民解放军联勤保障部队第九六〇医院骨科门诊就诊的KOA患者202例为研究对象,根据HALFT量表得分将患者分为无SF组和SF组,采用单因素分析和二元多因素逻辑回归分析探讨患者发生SF的危险因素。[结果]202例患者中,无SF(HALFT 0分)75例,占37.1%;SF前期(HALFT 1~2分)67例,占33.2%;SF期(HALFT 3~5分)60例,占29.7%。SF组的年龄 $[(72.2\pm 6.3)\text{岁} \text{vs} (67.8\pm 5.8)\text{岁}, P<0.001]$ 、K-L分期[I/II/III/IV,(7/46/48/26) vs (19/31/20/5),  $P<0.001]$ 、居住方式[独居/与他人居住,(2/73) vs (21/106),  $P=0.010]$ 、屈服应对方式评分 $[(13.7\pm 2.3) \text{vs} (11.4\pm 2.1), P<0.001]$ 、回避应对方式评分 $[(18.8\pm 2.7) \text{vs} (16.5\pm 2.8), P<0.001]$ 均显著高于非SF组,但是,SF组运动频率[从不/偶尔/经常,(50/52/25) vs (19/26/30),  $P=0.006]$ 、双向社会支持评分 $[(38.1\pm 7.7) \text{vs} (44.7\pm 7.0), P<0.001]$ 、积极心理资本评分 $[(101.7\pm 19.1) \text{vs} (119.6\pm 20.7), P<0.001]$ 、面对应对方式评分 $[(19.0\pm 3.6) \text{vs} (22.4\pm 4.3), P<0.001]$ 均显著低于非SF组。二元多因素逻辑回归分析显示:与他人一同居住( $OR=0.105, P<0.05$ )、双向社会支持评分高( $OR=0.881, P<0.05$ )、积极心理资本评分高( $OR=0.952, P<0.05$ )是老年KOA患者发生SF的保护因素;而高龄( $OR=1.104, P<0.05$ )、K-L分期高( $OR=7.685, P<0.05$ )、屈服应对方式评分高( $OR=1.398, P<0.05$ )是老年KOA患者发生SF的危险因素。[结论]高龄、独居、高KOA分期、低社会支持、低心理资本、屈服应对的患者发生SF的风险较高,临床应采取有针对性的干预措施来降低老年KOA患者SF水平。

## (2) 回归分析方法

- 早期临床分析主要针对小规模数据

### Efficacy and Safety of Bevacizumab in Chinese Patients with Metastatic Colorectal Cancer

- Asian Pac J Cancer Prev*, **15 (16)**, 6559-6564

Univariate analysis was conducted using Cox proportional hazards model, and based on the results of this analysis, variables with a statistical significance level of  $P < 0.2$  were chosen for the multivariate model in which the influence of various factors on PFS and OS was analyzed using a backward stepwise regression multivariate Cox proportional hazards model. Differences were considered statistically significant when  $P < 0.05$ .

Table 4. Multivariate Analysis of Clinical Factors

| Factor                                                          | PFS                 |         |
|-----------------------------------------------------------------|---------------------|---------|
|                                                                 | HR (95% CI)         | P-value |
| Bevacizumab application time >3.4 months                        | 0.303 (0.178~0.516) | 0.000   |
| Chemotherapy not continued after discontinuation of bevacizumab | 1.685 (1.015~2.797) | 0.044   |
| Nature of treatment:                                            |                     |         |
| Second-line                                                     | 1.603 (0.923~2.782) | 0.094   |
| Third- or fourth-line                                           | 2.141 (1.086~4.221) | 0.028   |
| Number of organs with metastases $\geq 2$                       | 2.114 (1.218~3.670) | 0.008   |
| Primary lesion unresected                                       | -                   | -       |

# 回归无法应对复杂的真实场景

- 电子病历库、医保索赔数据库、成百上千的自变量
- 回归可能无法处理比如缺失值、多重共线性、多混杂因素、中间变量等等带来的不可知性
- 更多更复杂的方法
  - 倾向得分及其改进
  - 工具变量
  - 敏感性分析



### (3) 倾向得分方法

- 基本原理：降维

- 多个自变量浓缩成一个自变量

- $$Y = b_0 + b_1x_1 + b_2x_2 + b_3x_3 + \dots + b_kx_k$$

$$Y = b_0 + b_1x_1$$

- 典型的方式

- 倾向匹配：通过挑选得分相似的配成分组均衡两组

- 应用场合

- 解决回归无法克服小样本建模的问题
  - 解决复杂大样本的处理难题

面对生存率不足5%的“癌王”，邵医专家团队竟将平均生存时间延长了一倍！

2017-10-24 16:02

2017年10月10日，浙江大学医学院附属邵逸夫医院胆胰癌多学科诊治团队（MDT）一篇题为《胆胰癌根治性切除术后同步放化疗：一项倾向性评分分析》的论文，发表于国际顶级医学期刊《International journal of radiation oncology biology physics》。IJROBP在放射肿瘤学领域称为“红皮杂志”，是美国放射治疗及肿瘤学会（ASTRO）官方杂志，为国际肿瘤放疗领域权威的、影响力最大的杂志。



Concurrent Chemoradiotherapy in Curatively Resected Gallbladder



International Journal of Radiation  
Oncology\* Biology\* Physics

Volume 100, Issue 1, 1 January 2018, Pages 138-145

Clinical Investigation

Concurrent Chemoradiotherapy in Curatively Resected Gallbladder Carcinoma: A Propensity Score-Matched Analysis

回顾性研究 94例患者匹配为78例  
进行分析

## (4) 机器学习因果推断

- 机器学习方法是一类通过算法自动从高维数据中学习特征与结局关联规律，并用于因果效应估计的工具。与传统统计方法（如回归）依赖人工指定变量关系不同，机器学习通过数据驱动的方式识别复杂模式（如非线性、交互作用），尤其适用于电子病历、基因组学等“大数据”场景。

### ■ 常见方法

- 双重稳健估计：分别用倾向得分方法（如Lasso、随机森林）预测暴露（处理模型）和结局；只要倾向得分模型或结果模型中有一个被正确建模，就可以得到一致的因果效应估计。
- 因果森林（Causal Forest）：基于随机森林的扩展，通过分裂规则识别异质性处理效应（如“哪些亚组患者从干预中获益更多？”）；
- 深度学习模型（如DAG-GNN）：构建有向无环图（DAG）识别混杂结构，适用于非线性关系（如基因-环境交互作用）。



## 第2节 混杂偏倚及其控制



# 流行病学数据需要统计方法控制偏倚

- 医学研究中误差的来源可以分为两类，
  - 随机误差(random error);
  - 系统误差(systematic error)。
- 随机误差是由于抽样误差所引起的，其大小可用统计学方法进行估计
- 系统误差即**偏倚(bias)**，是指研究结果系统地偏离了真实情况。

## 流行病学数据需要统计方法控制偏倚

- 选择偏倚

## 选择样本无法代表总体

- ## • 信息偏倚

## 获得的资料不正确

- ### • 混杂偏倚

## 由其它干扰因素造成，数据分组呈现出不均衡状态

## 2.1 观察性研究与混杂因素


### 观察性研究的特点:

- ✓ 不干预暴露分配 → 暴露组和非暴露组在基线存在系统性差异
- ✓ 这些系统差异可能扭曲暴露与结局的真实因果关系



混杂偏倚

混杂偏倚是指暴露因素与疾病发生或者疾病结局的相关（关联）程度受到其他因素（混杂因素）的**混淆**。



混杂因素在因果关系上**同时**  
**与暴露、与结局发生相关**

# 某药物与肿瘤患者生存率的关系

- 一项队列研究评价某药物的治疗肿瘤的效果。患者可自主选择药物进行治疗，研究者根据选择情况将患者分为两组：新药组 and 传统药物组。
- 研究发现
  - 选择新药的群体中，70%是60岁以下中青年患者；
  - 选择传统药物的群体中，40%是60岁以下中青年患者；
- 新药组3年生存率30%；传统药物组3年生存率10%，能否说明 新药效果好于传统药物？

# 效应存在着混杂偏倚



生存率的差异性，有可能是暴露因素造成、也可能是年龄造成、也可能是两者共同的作用

# 观察性研究统计结果存在混杂偏倚

- 现况调查的不同组别某项指标比较
- 现况调查研究的两变量相关分析
- 病例对照研究--OR值（卡方检验）
  - 病例对照分组不均衡
- 队列研究-RR值（卡方检验）
  - 暴露和不暴露分组不均衡、治疗组和对照组分组不均衡
- 生存时间的logRank差异性分析

# 常见错误

## 观察性研究只做简单差异性比较下统计结论

- 一项回顾性队列研究，常规治疗组(对照组)与中药治疗组(治疗组)。比较中、西医治疗的效果。
- 两组患者的有效率情况采用卡方检验，差异有统计学意义( $P < 0.01$ )，该论文认为中医药治疗效果较好。

表3 两组治愈率比较(例%)


| 组别  | 例数 | 治愈        | 好转        | 无效        | $\chi^2$ | $P$   |
|-----|----|-----------|-----------|-----------|----------|-------|
| 治疗组 | 91 | 59(64.8%) | 20(21.9%) | 12(13.2%) | 15.013   | <0.01 |
| 对照组 | 89 | 32(35.9%) | 42(47.2%) | 15(16.9%) |          |       |

# 什么因素(变量) 是混杂因素?

- 成为混杂因素的三大要素

- ✓ 与研究因素存在着相关或因果关系
- ✓ 与结局存在因果关系
- ✓ 不在研究因素与结局因果关系链之间(不是中介变量)

# 药物治疗与死亡关系



## 如何判断某个变量为混杂因素

## • 混杂因素

- ✓ 与研究因素存在着相关或因果关系

☆采用单因素关联性方法：t、卡方、方差、秩和

- ✓ 与结局存在因果关系

☆采用单因素关联性方法：线性（t检验）、logistic（卡方）、Cox  
回归

- ✓ 不在研究因素与结局因果链上的之间

### ☆主要是专业判断

# 如何判断混杂因素

- 举例：**分析接种疫苗对住院率的影响，判断年龄是否是混杂因素。

| 接种疫苗 | 年龄分组 | 住院(例) | 未住院(例) |
|------|------|-------|--------|
| 接种组  | 老年人  | 34    | 246    |
|      | 非老年人 | 6     | 114    |
| 不接种组 | 老年人  | 208   | 592    |
|      | 非老年人 | 194   | 1006   |

| 肺炎疫苗 | 是否老年人 | 住院情况 | 频数      |
|------|-------|------|---------|
| 接种   | 是     | 住院   | 34.00   |
| 接种   | 是     | 未住院  | 116.00  |
| 接种   | 否     | 住院   | 6.00    |
| 接种   | 否     | 未住院  | 114.00  |
| 不接种  | 是     | 住院   | 208.00  |
| 不接种  | 是     | 未住院  | 592.00  |
| 不接种  | 否     | 住院   | 194.00  |
| 不接种  | 否     | 未住院  | 1006.00 |

# 混杂因素第1条件

(1) 判断不同接种状态中年龄分布是否不同：卡方检验， $P < 0.05$

- 接种人群，老年人中比例更高；不接种人群中，中年人比例更高；

卡方检验

|                    | 值                    | 自由度 | 渐进显著性<br>(双侧) | 精确显著性<br>(双侧) | 精确显著性<br>(单侧) |
|--------------------|----------------------|-----|---------------|---------------|---------------|
| 皮尔逊卡方              | 121.212 <sup>a</sup> | 1   | .000          |               |               |
| 连续性修正 <sup>b</sup> | 120.003              | 1   | .000          |               |               |
| 似然比                | 122.328              | 1   | .000          |               |               |
| 费希尔精确检验            |                      |     |               | .000          | .000          |
| 线性关联               | 121.162              | 1   | .000          |               |               |
| 有效个案数              | 2400                 |     |               |               |               |

# 混杂因素第2条件

## (2) 判断年龄对住院率有影响：单因素logistic回归

— 老年人住院率更高

方程中的变量

|                   |       | B    | 标准误差 | 瓦尔德    | 自由度 | 显著性  | Exp(B) |
|-------------------|-------|------|------|--------|-----|------|--------|
| 步骤 1 <sup>a</sup> | 是否老年人 | .481 | .106 | 20.596 | 1   | .000 | 1.617  |
|                   | 常量    | .761 | .165 | 21.317 | 1   | .000 | 2.141  |

a. 在步骤 1 输入的变量：是否老年人。

# 如何诊断某个变量为混杂因素

- 混杂因素

- ✓ 与研究因素存在着相关或因果关系：成立

- ✓ 与结局存在因果关系：成立

- ✓ 不在研究因素与结局因果链上的之间：专业判断成立

**结论：年龄是混杂因素**

## 2.2 分组均衡性与混杂因素

- **RCT研究**，研究对象随机分为试验组和对照组，往往试验组和对照组两组人群基线特征信息相似，称之为**分组均衡可比**。
- **观察性研究**，研究对象根据暴露情况或结局情况，自然分为2组或者多组，不随机化，人群的特征往往不相似，**分组不均衡**。

# 观察性研究分组不均衡性

- 病例对照研究，病例组和对照组，除了暴露因素之外，其它因素分组不均衡的。
  - 例如：研究食道癌和饮酒的关系，食道癌患者和健康者，年龄分布是不均衡、不可比的。
- 队列研究，暴露组和对照组，其它因素分组不均衡的。
  - 例如：研究疫苗和住院的关系，接种组和不接种组者，年龄分布是不均衡、不可比的。

# 分组不均衡意味着什么？

- 分组不均衡

➡ 意味着组间的均数、率、构成比存在着统计学差异

- 差异即相关

➡ 分组不均衡意味着变量与变量存在着相关

➡ 相关意味着混杂变量第1条件或者第2条件成立

# 除了混杂因素，还有潜在混杂因素的概念

- 造成分组不均衡的因素，并不意味着它肯定是混杂因素，但是它可以被认为是潜在混杂因素
- 潜在混杂因素：
  - 条件（1）、（3）成立或条件（2）、（3）成立

造成分组不均衡的因素是潜在混杂因素

# 分组不均衡到底意味着什么？

对于接种组和对照组，年龄构成分布不同的

卡方检验， $P < 0.05$

分组不均衡

接种组和对照组存在着差异

接种状态与年龄有关（条件1满足）

年龄是潜在混杂

# 如何鉴定潜在混杂因素

- 鉴定潜在混杂因素的方法 (1)

- ✓ 与研究因素存在着相关或因果关系

- ☆采用单因素关联性方法：t、卡方、方差、秩和

- ✓ 不在研究因素与结局因果链上的之间

- ☆主要是专业判断

# 如何鉴定潜在混杂因素

- 鉴定潜在混杂因素 (2)

- ✓ 与结局存在因果关系

- ☆采用单因素关联性方法：线性（t检验）、logistic（卡方）、

- Cox回归

- ✓ 不在研究因素与结局因果链上的之间

- ☆专业判断

# 统计学常见的分析思路

- 通常不会严格鉴定是否混杂，而挑选出潜在混杂因素，或从专业知识上直接判断。
- 随机对照研究
  - 干预组与对照组基线数据分组均衡性比较可证明无混杂偏倚
- 观察性研究
  - 通过简单关联性分析发现潜在混杂因素

表 1 基本特征

| 项目       | 不吸烟者(n=1471)       | 吸烟者(n=1093)      | P 值    |
|----------|--------------------|------------------|--------|
| 年龄,岁     | 64.6±11.73         | 55.0±10.4        | <0.001 |
| 男性       | 76.1 (1,120/1,471) | 80.4 (879/1,093) | 0.009  |
| 糖尿病      | 19.9 (291/1,464)   | 12.7 (138/1,090) | <0.001 |
| 高血压      | 56.8 (834/1,468)   | 43.4 (474/1,092) | <0.001 |
| 高脂血症     | 25.7 (332/1,293)   | 20.1 (193/960)   | 0.01   |
| 陈旧性心肌梗死  | 7.2 (105/1,469)    | 5.3 (58/1,091)   | 0.043  |
| 冠状动脉搭桥术史 | 1.6 (24/1,471)     | 0.8 (9/1,092)    | 0.07   |

## 2.3 应对（潜在）混杂因素的策略

- 事先：设计阶段控制：
  - 随机分组
  - 限制
  - 配对
- 事后：资料分析阶段的控制：
  - 分层分析
  - 多因素分析
  - 倾向得分方法
  - 工具变量

# 常见事后的的统计学方法

- 已测混杂的控制方法

- 回归
- 分层
- 倾向得分方法

- 未测混杂的控制方法

- 工具变量法
- 阴性对照法
- 敏感性分析

# 案例分析

- 吸烟是心血管系统疾病危险因素，能增加一般人群冠状动脉疾病发生风险，不利于患者长期预后。
- 然而，吸烟与ST段抬高型心肌梗死(ST-segmentelevation myocardial infarction, STEMI)的死亡风险关系仍存在争议。1968年，Weinblatt E 等人首次报道急性心梗患者中吸烟者住院期间的死亡率低于不吸烟者，即“**吸烟悖论**”现象。
- 一些研究认为，“**吸烟悖论**”由**混杂因素导致**：与不吸烟者相比，吸烟者年龄更低，合并病更少。

# 举例

- 2020年4月在著名的心血管病顶尖期刊JACC的论文，分析了“吸烟悖论”，研究混杂因素的影响

## Effect of Smoking on Outcomes of Primary PCI in Patients With STEMI



Björn Redfors, MD, PhD,<sup>a,b,c,\*</sup> Ariel Furer, MD,<sup>a,d,e,\*</sup> Harry P. Selker, MD, MSPH,<sup>f</sup> Holger Thiele, MD,<sup>g</sup> Manesh R. Patel, MD,<sup>h</sup> Shmuel Chen, MD, PhD,<sup>a,b</sup> James E. Udelson, MD,<sup>i</sup> E. Magnus Ohman, MD,<sup>h</sup> Ingo Eitel, MD,<sup>i,k</sup> Christopher B. Granger, MD,<sup>h</sup> Akiko Maehara, MD,<sup>a,b</sup> Ajay J. Kirtane, MD, SM,<sup>a,b</sup> Philippe G  n  reux, MD,<sup>a,l,m</sup> Paul L. Jenkins, PhD,<sup>n</sup> Ori Ben-Yehuda, MD,<sup>a,b</sup> Gregg W. Stone, MD<sup>a,o</sup>

# 研究设计

- **研究类型：**本研究案例案例是基于临床试验对象基础上进行的二次分析（队列研究）。
- **研究对象：**接受PCI治疗的STEMI患者，临床随访时间至少6个月以上。
- **研究因素（暴露因素）：**近期吸烟状态，具体定义：当前吸烟或确诊患病前3个月内吸烟判定为吸烟，当前不吸烟或患病前3个月已戒烟的判定为不吸烟。
- **基线数据及观察指标：**年龄、性别、高血压、高脂血症、糖尿病、陈旧性心肌梗死、冠状动脉搭桥术史、发病时球囊扩张的最小值、“罪犯血管”、基线心肌梗死溶栓（TIMI）血流分级、最终心肌梗死溶栓（TIMI）血流分级、肌酐、白细胞计数、心肌梗死面积(Infarct size, IS)、微血管阻塞(microvascular obstruction, MVO)、左室射血分数(Left Ventricular Function, LVEF)、首次设备检出症状的时间（即随访开始到终点的时间）。
- **随访终点：**1年内全因死亡、心力衰竭住院、复发性心肌梗死。


# 统计分析结果—均衡性比较

- 目的：根据分组均衡性的结果，若某因素分组不均衡，那就是潜在混杂因素。
- 结果：
  - 年龄、性别、糖尿病、高血压、高脂血症、陈旧性心肌梗死、肌酐、白细胞计数在吸烟组和不吸烟组人群中分布不均衡
  - IS、MVO、LVEF呢？无论单因素还是多因素线性回归， $P$ 值大于0.05，因此上述三者不是混杂因素。

表 1 基本特征

| 项目          | 不吸烟者(n=1471)       | 吸烟者(n=1093)      | P 值    |
|-------------|--------------------|------------------|--------|
| 年龄,岁        | 64.6±11.73         | 55.0±10.4        | <0.001 |
| 男性          | 76.1 (1,120/1,471) | 80.4 (879/1,093) | 0.009  |
| 糖尿病         | 19.9 (291/1,464)   | 12.7 (138/1,090) | <0.001 |
| 高血压         | 56.8 (834/1,468)   | 43.4 (474/1,092) | <0.001 |
| 高脂血症        | 25.7 (332/1,293)   | 20.1 (193/960)   | 0.01   |
| 陈旧性心肌梗死     | 7.2 (105/1,469)    | 5.3 (58/1,091)   | 0.043  |
| 冠状动脉搭桥术史    | 1.6 (24/1,471)     | 0.8 (9/1,092)    | 0.07   |
| 发病时球囊扩张的最小值 | 224±131            | 221±133          | 0.68   |
| “罪犯”血管      |                    |                  |        |
| 左前降支        | 63.9 (937/1,466)   | 60.9 (664/1,091) | 0.56   |
| 右冠          | 27.6 (405/1,466)   | 31.8 (347/1,091) | 0.13   |
| 左回旋支        | 8.0 (117/1,466)    | 7.2 (78/1,091)   | 0.23   |
| 左主干         | 0.5 (6/1,228)      | 0.4 (4/910)      | 0.88   |

图1 吸烟者和非吸烟者的心脏病发病、糖尿病发病和关节炎发病率




本图展示了吸烟者和非吸烟者的心脏病发病、糖尿病发病和关节炎发病率。图中显示了中位数、四分位数和p值。p值表示吸烟者和非吸烟者之间的差异是否具有统计学意义。p值大于0.05表示差异不显著，p值小于0.05表示差异显著。

# 统计分析结果—单因素分析

## (1) 首先开展未控制混杂的单因素回归分析（模型①）

- 由于结局是生存时间资料，因此采用logRank方法提供 $P$ 值，单因素Cox回归提供HR值。
- 采用单因素COX回归分析显示，**与不吸烟者相比，吸烟者的全因死亡风险（1.0% vs 2.9%； $P<0.001$ ）和死亡或心力衰竭住院风险（3.3% vs 5.1%； $P=0.009$ ）较低**，而在心力衰竭住院风险（2.5% vs 2.7%； $P=0.64$ ）和复发性心肌梗死风险（2.0% vs 2.3%； $P=0.17$ ）上相似。

图3 吸烟者和非吸烟者的生存曲线



(A)全死因死亡

(B)心力衰竭住院

(C)全死因死亡或心力衰竭住院

(D)复发性心肌梗死

CI=置信区间; HR=风险比

统计分析“公众号”

# 统计分析结果—多因素分析

## (2) 多个回归模型进行混杂因素的控制（模型②③④）

分别构建了3个多因素Cox回归来探讨吸烟与结局的关系。

- ②：双因素回归，纳入自变量分别是吸烟和年龄，控制年龄产生的混杂偏倚；
- ③：多因素回归，纳入更多的自变量，包括：吸烟、年龄、性别、糖尿病、左冠状动脉前降支阻塞、首次设备检出症状的时间；
- ④：多因素回归，在模型③的基础上，增加IS协变量。

# 统计分析结果—多因素分析

(A)全死因死亡



(B)心力衰竭住院

(C)全死因死亡或心衰住院

(D)复发性心肌梗死

CI=置信区间; HR=风险比

图4 未调整或已调整协变量的吸烟与临床结局之间的关系



该图显示了吸烟与临床结局之间的关系。在吸烟者中，HR值小于1.0表示吸烟者比不吸烟者有较低的死亡风险。在吸烟者中，HR值大于1.0表示吸烟者比不吸烟者有较高的死亡风险。在吸烟者中，HR值等于1.0表示吸烟者和不吸烟者的死亡风险相同。

(A)全死因死亡的风险。在模型3和4中调整协变量后，吸烟者比不吸烟者有较低的死亡风险。在模型3和4中调整协变量后，吸烟者比不吸烟者有较高的死亡风险。

(B)心力衰竭住院的风险。在模型3和4中调整协变量后，吸烟者比不吸烟者有较高的死亡风险。在模型3和4中调整协变量后，吸烟者比不吸烟者有较高的死亡风险。

(C)全死因死亡或心衰住院的风险。在模型3和4中调整协变量后，吸烟者比不吸烟者有较高的死亡风险。在模型3和4中调整协变量后，吸烟者比不吸烟者有较高的死亡风险。

(D)复发性心肌梗死的风险。在模型3和4中调整协变量后，吸烟者比不吸烟者有较高的死亡风险。在模型3和4中调整协变量后，吸烟者比不吸烟者有较高的死亡风险。

IS: 缺血性心脏病。

# 什么是Adjusted（调整）

- **Unadjusted**: 未调整、未控制混杂因素、
- **Adjusted**: 调整后、控制混杂因素
  - The risk factors **adjusted for** in models 3 and 4 were sex, diabetes, culprit lesion in the left anterior descending coronary artery, and symptom-to-first-device time.
- 什么是Adjusted ?
- 统计分析中，往往意味着多因素分析（最常见的多因素回归）
- 一旦采用多因素回归，就意味着控制了一定的混杂因素的影响。

# 为什么采用多因素回归分析

单因素线性回归公式如下： $Y=\alpha+\beta X_1+\varepsilon$ 。  
具体到本案例：

$\alpha$ 为截距，  
可忽略


生存结局（死亡）= $\alpha+\beta*\text{吸烟}+\varepsilon$

$\beta$ 效应值，吸烟  
组相对不吸烟组  
的结果差异

这里的 $\beta$ 值为吸烟组的生存结局和不吸烟组生存结局的差别，但是不是吸烟相对于不吸烟，年龄的效应也体现在 $\beta$ 中。

# 为什么采用多因素回归分析

多因素线性回归公式如下： $Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$ 。



实际上，多因素回归的吸烟效应就从单因素的 $\beta$ 变为多因素的 $\beta_1$ 。  
年龄造成的偏倚被剔除，最后得到了 $\beta_1$ 更准确地估计了吸烟对死亡的影响。



## 第3节 因果推断理论与常见方法



# “吸烟与肺癌”的因果争议

- 20世纪40-50年代，**Austin Bradford Hill**为首的流行病学家进行了一系列病例对照研究和队列研究。
  - 强度大：吸烟者患肺癌的风险远高于不吸烟者。
  - 剂量-反应关系：吸烟量越大、吸烟时间越长，患癌风险越高。
  - 一致性：在不同人群、不同时间、由不同研究者进行的研究中，都得到了相似的结果。



- 现代统计学的奠基人Fisher**认为，观察性研究发现的关联可能由混杂因素所导致。
- 提出了几个替代性解释：基因混杂假说、观察性研究的固有缺陷
- Fisher**：“你们的数据只显示了关联，但无法证明因果关系”。

# 基于相关的结果是否可推导出因果关系？

## ■ Hill的方法与观点

- 逐渐被医学和公共卫生界接受，并推动了全球范围内的控烟运动。


### Hill法则

#### Criteria for Causation Bradford Hill Criteria

- |                               |                                    |
|-------------------------------|------------------------------------|
| • Temporal relationship       | • Alternative explanations         |
| • Strength of the association | • Cessation of exposure            |
| • Dose-response relationship  | • Specificity of the association   |
| • Replication of findings     | • Consistency with other knowledge |
| • Biologic plausibility       |                                    |

## ■ 50-90年代的统计学界观念

- “相关不等于因果”，
- 观察性研究只能提示关联，无法证明因果。
- 随机对照试验被奉为因果推断的“黄金标准”




# 直到两大因果推断框架的提出

20世纪80年代，基于“反事实”理论，统计学家如Donald Rubin提出潜在结果框架和计算机科学家Judea Pearl提出因果结构模型。

## ■ “反事实框架” (Counterfactual)

- “反事实”框架是科学哲学家大卫·刘易斯 (David Lewis) 等人提出的推断因果关系的标准
- 事实是指在某个特定变量 (A) 的影响下可观测到的某种状态或结果 (B)。
- “反事实”是指在该特定变量 (A) 取负向值时可观测到的状态或结果 (B')。




# 潜在结果框架

## ■ Rubin用潜在结果来刻画“反事实”的结果


- 定义：对于每个个体，针对每一种可能的处理状态，都存在一个相应的潜在结果。
- 可分为两个结果：事实结果与反事实结果

# 假设我们研究一种新降压药A，想知道它是否能降低血压



潜在结果

# 假设我们研究一种新降压药A，想知道它是否能降低血压



对于每个人，只能观察到一个事实结果，另一个潜在结果永远是“缺失”的。

# 潜在结果框架与ATE


## ■ “反事实”潜在结果

- $Y_{i(1)}$ : 个体i 如果接受处理时的结果。
- $Y_{i(0)}$ : 个体i 如果未接受处理时的结果。
- 个体因果效应 被定义为这两个潜在结果之差:  
 $Y_{i(1)} - Y_{i(0)}$

- 平均处理效应  $ATE = E[Y(1) - Y(0)] = E[Y(1)] - E[Y(0)]$


## ■ ATE 是最常用的因果推断估计效应指标

- ATE: Average Treatment Effect
- 在整个群体中，每个人都接受处理和每个人都不接受处理的平均结果会相差多少？



# 因果结构模型

- 1980年代，图灵奖得主朱迪亚·珀尔（Judea Pearl）提出了结构因果模型（SCM）
- 它认为，世界是由一系列稳定、自主的因果机制构成的。例如，物理定律、生物过程、经济规则等。
- SCM的语言是有向无环图（Directed Acyclic Graph, DAG）。



# DAG与偏倚控制

- DAG是一个带有箭头的、没有回路的图形，表示假设的因果影响的方向(例如，从吸烟到肺癌)。
- 在DAG中，每个节点代表一个变量，每条有向边(箭头)  $X \rightarrow Y$  代表一个直接的因果机制
- DAG的核心价值在于，**它迫使研究者基于领域知识，明确提出关于变量之间因果结构的假设。**
- 通过节点(代表变量，如暴露、结局或协变量)和箭头(表示因果方向)，DAGs能够帮助研究者识别混杂因子、中介变量、碰撞变量以及其他潜在的偏倚来源。




# DAG与偏倚控制

## ■ DAG通常与“潜在结果”框架”结合开展统计学的因果推断

- 明确识别并控制混杂因素；
- 确定不应控制的碰撞变量以免引入偏倚；
- 理清中介路径和潜在的效应修饰，以免引入偏倚；
- 判断何种变量可用作工具变量；

Figure. Example of Directed and Nondirected Paths



The directed paths represent the effect of E on O that is being estimated. Bias can be reduced by adjusting or controlling for C to close that nondirected path. Conversely, the nondirected path that includes S is closed if it is uncontrolled and thus is not a biasing path; controlling for S opens that path and may introduce bias.

# DAG通常与“潜在结果”框架”结合

- **随机化方法塑造了反事实人群：**因为它能保证处理组和对照组在所有已知和未知的混杂因素上是可比的。
- **观察性研究：**数据分析阶段通过统计方法“创造”出类似随机化的条件，形成反事实人群和反事实结果
  - 找到一种统计方式，使得在“调整后”的数据中，处理组和对照组在所有已观测的混杂变量上尽可能相似。
  - 混杂变量的选择往往基于先验知识、以及DAG方法进行选择，避免非因果路径的干扰（中给路径、碰撞路径）

# 因果推断方法1 回归方法

■  $Y = \beta_0 + \beta_1 * X_1 + \beta_2 * X_2 + \beta_3 * X_3 + \varepsilon$

- Y: 结果 (如肺癌)
- $X_1$ : 处理变量 (如吸烟)
- $X_2$ 、 $X_3$ : 协变量 (如年龄、性别、职业等)

- 线性回归:  $\beta$ 值
- 广义线性回归: OR值、RR值
  - Logistic、等级logistic、泊松回归及其修正版、负二项回归、零膨胀模型、广义加性模型
- Cox比例风险模型: HR值

■ 常见的模型: 线性回归、广义线性模型、Cox模型

■ 回归系数 $\beta_1$ 解释: “在保持其他变量X不变的情况下, A变动一个单位, Y平均变动 $\beta$ 个单位”, 类似于分层分析。

■ 回归作用: 影响因素、预测模型、控制混杂

# 注意回归的用途——不一定推导出因果关系

## ■ 描述性研究

- 回归是一种标准化的方法

## ■ 多个“影响因素”研究

- 探索性的关联性研究，变量相互校正，称之为“独立影响因素”

## ■ 临床的诊断与预后预测模型

- 预测因子并不需要一定与结局有因果关系


## ■ 控制混杂偏倚

- 一种因果推断的基本方法

表4 深圳市龙岗区社区女性的 HPV 疫苗接种率影响因素的多因素 logistics 回归分析结果

| 变量   | B      | SE    | Wald $\chi^2$ 值 | P 值   | OR 值  | 95%CI       |
|------|--------|-------|-----------------|-------|-------|-------------|
| 年龄   | -0.030 | 0.008 | 15.22           | 0.000 | 0.970 | 0.956-0.985 |
| 居住地  | -0.387 | 0.146 | 7.056           | 0.008 | 0.679 | 0.511-0.904 |
| 婚姻状态 | 0.274  | 0.119 | 5.261           | 0.022 | 1.315 | 1.041-1.661 |
| 职业   | -0.075 | 0.038 | 3.923           | 0.048 | 0.928 | 0.861-0.999 |
| 文化程度 | 0.447  | 0.076 | 34.455          | 0.000 | 1.563 | 1.347-1.815 |

注：HPV—人乳头瘤病毒。



# 注意回归的用途--不一定推导出因果关系

- **风险因素**（或保护因素）通常来自关联性研究，或需要事后分析来确认其对结局的作用。
- **因果因素**则要求采用能够确立因果关系的对照实验设计，包括反事实框架设计）。



# 何种情况下，回归才用于因果推断？

- 回归可用于关联/预测，也可用于因果推断

- ✓ 关联性分析探讨影响因素

- ✓ 因果推断控制混杂偏倚

- 两者最大的区别在于，是否基于domain knowledge，临床/生物的知识

**数据驱动型分析 vs 知识推动型分析**


# 回归系数 $\beta_1$ =ATE吗？

- 反事实潜在结果框架下，ATE与 $\beta_1$ 只有在一定条件下才相等。
- 假设1：条件可忽略性/无额外混杂
  - 回归依赖于我们已将所有重要的混杂变量X都纳入模型。
  - 在给定X的条件下，处理分配A与潜在结果 $Y(0)$ ,  $Y(1)$ 独立。
  - 若遗漏了任何与A和Y都相关的变量， $\beta_1$ 就是有偏的。
- 假设2：正确的函数形式
  - 回归假设A对Y的效应是线性的、可加的。
  - 无论X是什么值，A对Y的效应都是恒定的 $\beta_1$ 。

# 因果推断方法2 G计算

- G计算（G-Computation），是反事实框架下更直接、更灵活的一种方法。
- 在标准化人群中，分别计算暴露与对照组发病概率
  - 如果强制全世界所有人都吸烟，肺癌发病率会是多少？
  - 如果强制全世界所有人都不吸烟，肺癌发病率又是多少？
- 两个发病率的差值，就是我们要的ATE。

将反事实思想操作化



# G计算的过程

## 步骤一：构建一个结果预测模型

$$Y \sim \beta_0 + \beta_1 * A + \beta_2 * X_2 + \beta_3 * X_3^2 + \text{spline}(X_3) + \dots$$

线性模型、逻辑回归、机器学习模型等。

## 步骤二：得到标准化人群的反事实结果

- 将数据中的处理变量A强制设定为1（吸烟），但同时保持原始协变量 $X_i$ 不变。  
然后将这个新数据 ( $A=1, X_i$ ) 代入步骤一的模型，预测出他们的潜在结果  $\hat{Y}_i(1)$ 。
- 同样，将A强制设定为0（不吸烟），保持 $X_i$ 不变，预测出他们的潜在结果  $\hat{Y}_i(0)$ 。

## 步骤三：计算因果效应

- $E[Y(1)]$  的估计值 = 所有  $\hat{Y}_i(1)$  的平均值。
- $E[Y(0)]$  的估计值 = 所有  $\hat{Y}_i(0)$  的平均值。

$$ATE = E[Y(1) - Y(0)] = E[Y(1)] - E[Y(0)]$$

# G计算优势

## ■ 模型灵活且复杂化

- 包含任意复杂的交互项（如  $A * \text{年龄} + A * \text{性别}$ ）。
- 使用非线性项（如多项式、样条函数）。
- 可结合机器学习算法（如随机森林、梯度提升树）来拟合  $E[Y|A, X]$ 。


## ■ 效应估计的透明与直观：

- 效应 = “如果全世界都吸烟？” - “如果全世界都不吸烟？”
- 将焦点从“解读一个神秘的系数 $\beta_1$ ”转移到“构建一个尽可能接近现实的数据生成模型，并利用它进行透明的反事实结果”上来。

# 因果推断方法3 倾向得分方法

- 倾向性得分 (PS) 是指在一定协变量条件下, 一个观察对象接受某种暴露/处理因素的可能性, 它是一个从0到1的范围内连续分布的概率值。
- PS计算常用Logistic回归, 它是以暴露因素 (结局变量) 作为因变量Y (0或1), 以其它诸多影响研究对象进入研究分组的变量作为自变量X, 拟合Logistic回归, 计算预测概率作为PS。
- 把多个协变量 (混杂变量用一个指标代替), PS相似者, 群体特征相似

$$\ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$




# 因果推断方法3 倾向得分方法

## • 倾向得分构造反事实的方法

- 倾向得分匹配
- 倾向得分加权
- 逆概率加权
- 标准化死亡比加权
- 重叠加权


| target population  | $h(x)$                          | estimand | weight ( $w_1, w_0$ )                                                                                     |
|--------------------|---------------------------------|----------|-----------------------------------------------------------------------------------------------------------|
| combined           | 1                               | ATE      | $\left(\frac{1}{e(x)}, \frac{1}{1-e(x)}\right)$ [HT]                                                      |
| treated            | $e(x)$                          | ATT      | $\left(1, \frac{e(x)}{1-e(x)}\right)$                                                                     |
| control            | $1 - e(x)$                      | ATC      | $\left(\frac{1-e(x)}{e(x)}, 1\right)$                                                                     |
| overlap            | $e(x)(1 - e(x))$                | ATO      | $(1 - e(x), e(x))$                                                                                        |
| truncated combined | $1(\alpha < e(x) < 1 - \alpha)$ |          | $\left(\frac{1(\alpha < e(x) < 1 - \alpha)}{e(x)}, \frac{1(\alpha < e(x) < 1 - \alpha)}{1 - e(x)}\right)$ |
| matching           | $\min\{e(x), 1 - e(x)\}$        |          | $\left(\frac{\min\{e(x), 1 - e(x)\}}{e(x)}, \frac{\min\{e(x), 1 - e(x)\}}{1 - e(x)}\right)$               |



# 倾向得分方法--逆概率加权

**逆概率加权**（ the inverse probability of treatment weighting, IPTW ） **以所有观察对象作为标准人群进行调整**，暴露/处理组各观察对象的权重 $w=1/PS$ ，对照组各观察对象的权重为 $w=1/(1-PS)$ 。

Crude (whole population)





IPTW (ATE)



# 倾向得分方法--标准化比加权


标准化死亡比加权法 (the standardized mortality ratio weighting, SMRW) 以暴露组观察对象作为标准人群进行调整, 暴露/处理组各观察对象的权重为  $W_t=1$ , 对照组各观察对象的权重为  $W_c=PS/(1-PS)$ 。



# 因果推断方法4 机器学习方法


## ➤ 传统统计方法的局限

- 假设较强（如线性关系、正态分布）
- 变量多时容易失效
- 难以灵活适应非线性、交互作用等复杂模式



## ➤ 机器学习的优势




- 能自动从数据中学习规律
- 更灵活处理高维、多变量、非线性问题
- 提升预测能力



# 因果推断方法4 机器学习方法

## ➤ 机器学习在医学数据分析的应用

- **描述：**发现疾病分布、类别和人群聚集
- **预测：**疾病诊断与预后预测
- **因果推断：**评估暴露、干预与结果的因果关系



# 机器学习方法核心功能是预测

## ■ 预测结局

- 构建结果模型，代替常规的G计算预测模型算法

## ■ 预测暴露

- 计算倾向得分，代替常规的logistic回归

## ■ 通过复杂的策略提升模型的预测效果

- 交叉验证、集成学习、深度学习

# 机器学习方法：超级学习者

## ■ 超级学习者

- 超级学习者 (Super Learner, SL) 是一种强大的集成学习方法，用于构建具有最佳预测模型。
- 它将多个候选学习算法（基学习器）的预测结果作为输入，使用交叉验证和另一个学习算法（元学习器）来学习如何最优地组合这些基预测器，以获得比任何单一基学习器更好的预测性能。

## ■ 基学习器

- 数据挖掘，独立构建预测模型：
- 逻辑回归、线性判别分析、决策树、随机森林、梯度提升树（如XGBoost）、支持向量机（SVM）、K-近邻算法等。

## ■ 元学习器：

- 聪明的汇总
- 往往基于线性方程，结合交叉验证方法，给不同的基学习器分配合适的权重，从而构建最佳预测模型。

# 机器学习方法：超级学习者

## ■ 超级学习者解决了常规因果推断方法的核心痛点

- 倾向得分不准确：倾向得分模型误设（如遗漏非线性关系）
- 结果预测偏差：结果模型（回归方法）误设（如错误函数形式）

| 传统方法痛点                | Super Learner突破                  | 模型反映非线性关系，降低模型误设风险，提升结果模型预测精度，效应估计更接近真值 |
|-----------------------|----------------------------------|-----------------------------------------|
| <b>模型单一化</b>          | <b>集成多算法</b>                     |                                         |
| 线性/逻辑回归主导，易忽略交互项与复杂模式 | 非线性基学习器，自动挖掘变量间深层关联              |                                         |
| <b>主观选择风险</b>         | <b>数据驱动组合</b>                    |                                         |
| 依赖人工选择模型，易引入过拟合/选择偏差  | K折交叉验证客观评估基学习器性能，并通过元学习器自动加权最优模型 |                                         |
| <b>强参数假设</b>          | <b>非参灵活性</b>                     |                                         |
| 存在预设函数形式，误设会导致偏差      | 广泛的基学习器，自适应逼近最佳模型                |                                         |

# 超级学习者+双重稳健估计方法

JOURNAL ARTICLE

EDITOR'S CHOICE

## Invited Commentary: Demystifying Statistical Inference When Using Machine Learning in Causal Research

Laura B Balzer , Ted Westling

*American Journal of Epidemiology*, Volume 192, Issue 9, September 2023, Pages 1545–1549, <https://doi.org/10.1093/aje/kwab200>

Published: 15 July 2021    Article history ▼

A correction has been published: *American Journal of Epidemiology*, Volume 192, Issue 9, September 2023, Pages 1607–1608, <https://doi.org/10.1093/aje/kwad132>

“统计人生”公众号

# 超级学习者+双重稳健估计方法

欢迎关注“医学论

> Obes Sci Pract. 2020 Aug 18;6(6):628-637. doi: 10.1002/osp4.447. eCollection 2020 Dec.

**Estimating the effects of body mass index and central obesity on stroke in diabetics and non-diabetics using targeted maximum likelihood estimation: Atherosclerosis Risk in Communities study**

统计分析”公众号

医学

# 基于超级学习者模型的TMLE结果

- The **super learner** approach is an ensemble machine learning approach that uses cross-validation to select an optimal statistical model from among many candidate models
- 超级学习器方法是一种集成机器学习方法，它通过交叉验证从众多候选模型中选择最优统计模型。
- **Double-robust methods** have the advantage of using both exposure and outcome models that remain consistent if either exposure or outcome models are estimated consistently. In addition, **TMLE** can use the super learner machine learning algorithms that result in protecting against bias。
- 双重稳健方法的优势在于同时利用暴露模型和结果模型进行估计——只要其中任一个模型被准确估计，就能保持估计结果的一致性。此外，目标最大似然估计（TMLE）可以结合超级学习器机器学习算法，从而有效防止偏差产生。

# 基于超级学习者模型的TMLE结果

**TABLE 2** Estimated risk ratios of stroke by baseline body mass index and central obesity of total participants (N = 12 725) in the ARIC study, 1987–2014, based on targeted maximum likelihood estimation with super learner modelling

| Index             | Model 1           | Model 2           | Model 3           | Model 4           |
|-------------------|-------------------|-------------------|-------------------|-------------------|
|                   | RR (95% CI)       | RR (95% CI)       | RR (95% CI)       | RR (95% CI)       |
| BMI               | 1.35 (1.23, 1.47) | 1.38 (1.27, 1.50) | 1.24 (1.14, 1.35) | 1.11 (1.02, 1.21) |
| WC <sup>a</sup>   | 1.30 (1.20, 1.41) | 1.30 (1.20, 1.40) | 1.15 (1.07, 1.24) | 1.08 (1.01, 1.17) |
| WHR <sup>a</sup>  | 1.32 (1.20, 1.44) | 1.30 (1.19, 1.41) | 1.13 (1.04, 1.22) | 1.09 (1.01, 1.18) |
| WHtR <sup>a</sup> | 1.17 (1.06, 1.30) | 1.19 (1.08, 1.31) | 0.99 (0.92, 1.07) | 0.95 (0.88, 1.02) |
| BSI <sup>a</sup>  | 1.32 (1.22, 1.43) | 1.27 (1.18, 1.37) | 1.13 (1.06, 1.22) | 1.12 (1.04, 1.20) |
| BRI <sup>a</sup>  | 1.25 (1.15, 1.36) | 1.27 (1.17, 1.37) | 1.06 (0.99, 1.14) | 1.04 (0.96, 1.11) |

Note: Model 1: adjusted for demographic variables and family history; Model 2: Model 1 plus behavioural variables; Model 3: Model 2 plus biologic variables; Model 4: Model 3 plus waist circumference and hip circumference.

Abbreviations: ARIC, Atherosclerosis Risk in Communities; BMI, body mass index; BRI, body roundness index; BSI, body shape index; CI, confidence interval; RR, risk ratio; WC, waist circumference; WHR, waist-to-hip ratio; WHtR, waist-to-height ratio.

<sup>a</sup>Adjusted for Model 3 plus hip circumference.

# 因果推断方法5 双重稳健估计

## ➤ 两种传统的因果推断模型

- **结果模型** (Outcome Model)

根据协变量 $X$ ，预测接受或不接受处理时结果 $Y$ 的期望值。

$$\mu_a(X) = E[Y|A = a, X], a \in \{0, 1\}$$

- **暴露模型/倾向性评分模型** (Propensity Score Model)

根据协变量 $X$ ，估计接受处理的概率，用来调整混杂影响

$$e(X) = P(A = 1|X)$$

## ➤ 双重稳健估计是一类结合了倾向得分模型和结果回归模型的因果推断方法。

## ➤ 意义

- 在双重稳健方法中，只要倾向得分模型或结果模型中有一个被正确建模，就可以得到可靠的因果效应估计。

# 因果推断方法5 双重稳健估计

- 增强逆概率加权法 (AIPTW)
  - 分别建两个模型，再把它们拼起来用残差校正因果效应
  - R包: drtmle、AIPW
- 靶向最大似然估计 (TMLE)
  - 先估结果模型，再用聪明变量做个“小手术”去修正它，让它更稳健
  - R包: tmle、ltmle
- 双重机器学习 (DML)
  - 用机器学习分别建两个模型，采用交叉拟合技术，数学上更“正交”，但更复杂。
  - R包: DoubleML

# 靶向最大似然估计 (TMLE)

- **双重稳健性：**
- **效率最优：** 在满足条件下可达到理论上最小方差，比AIPW更高效；
- **机器学习兼容性强：** 可整合任意监督学习模型（如Super Learner），无须依赖参数化假设；
- **靶向校正机制：** 自动根据“聪明算法”调整预测值，使估计“对准”目标参数，更贴近真实因果效应；
- **衍生方法的多样性：** 适用于普通、高维、缺失、生存时间等多种场景

# 靶向最大似然估计 (TMLE)



表1 TMLE衍生方法图

# 靶向最大似然估计 (TMLE) 的一个综述

Annals of Epidemiology 86 (2023) 34–48



Contents lists available at ScienceDirect

Annals of Epidemiology

journal homepage: [sciencedirect.com/journal/annals-of-epidemiology](https://www.sciencedirect.com/journal/annals-of-epidemiology)



Review article

## Application of targeted maximum likelihood estimation in public health and epidemiological studies: a systematic review

Matthew J. Smith, PhD<sup>a,\*,1</sup>, Rachael V. Phillips, PhD<sup>b</sup>,  
Miguel Angel Luque-Fernandez, PhD<sup>a,c,2</sup>, Camille Maringe, PhD<sup>a,2</sup>


<sup>a</sup> Inequalities in Cancer Outcomes Network, London School of Hygiene and Tropical Medicine, London, UK

<sup>b</sup> Division of Biostatistics, School of Public Health, University of California at Berkeley, Berkeley, CA

<sup>c</sup> Department of Statistics and Operations Research, University of Granada, Granada, Spain



# 靶向最大似然估计 (TMLE)



知乎 公众号

# 靶向最大似然估计 (TMLE)




Fig. 2. World map of publications using targeted maximum likelihood estimation by the geographical location of the first author (2006 to mid-2022). Colors represent the number of observational studies and the crosshatch pattern identifies where at least one methodological publication stems from.

# 靶向最大似然估计 (TMLE)

## TMLE常见衍生方法

| 方法                                   | 适用数据类型 / 场景                       |
|--------------------------------------|-----------------------------------|
| Doubly Robust TMLE                   | 结果模型或倾向模型中存在模型设定误差时（尤其适合模型部分错设时）。 |
| C-TMLE(Collaborative TMLE)           | 高维协变量、多模型结构选择目标是优化最终估计器性能。        |
| CV-TMLE(Cross-Validated TMLE)        | 样本量较小或复杂机器学习建模时，避免过拟合。            |
| HAL-TMLE(Highly Adaptive Lasso TMLE) | 高维、非线性、多交互数据场景需要非参数灵活建模。          |

# 靶向最大似然估计 (TMLE) 一篇中文

• 632 •

中华疾病控制杂志 2021 年 6 月第 25 卷第 6 期 Chin J Dis Control Prev 2021 Jun; 25 (6)

• 现实世界研究 •

## 基于靶向最大似然估计模型在高血压药物治疗评价中的应用

潘凤鸣 赵红玉 吴新莹 冯一平 侯庆振 王淑康 季晓康 张振堂 王菁  
薛付忠

250012 济南, 山东大学齐鲁医学院公共卫生学院生物统计系, 山东大学健康医疗大数据研究院(潘凤鸣、赵红玉、吴新莹、冯一平、侯庆振、王淑康、季晓康、王菁、薛付忠); 266400 青岛, 青岛西海岸新区疾病预防控制中心健康管理科(张振堂)

通信作者: 王菁, E-mail: wangqing1984@126.com; 薛付忠, E-mail: xuefzh@sdu.edu.cn

DOI: 10.16462/j.cnki.zhjbkz.2021.06.003

# 小结

- 数据驱动不能带来因果关系，现代医学因果推断是预测模型+领域知识的结合

That is, we cannot answer causal questions with the data alone, *no matter how big the data are and how deep the neural network is.* doi: 10.3389/fmed.2021.678047

- 反事实潜在结果+DAG+倾向得分方法是因果推断的常见组合
- 反事实潜在结果+DAG框架下开展机器学习，将产生更大的能量，尤其是机器学习+双稳健估计方法



谢谢