

因果推断模型与机器学习方法

郑老师团队

时间：2025-2026

“因果推断模型与机器学习方法”训练营--理论篇

第三讲 反事实潜在结果框架与G计算

1. 反事实潜在结果框架

- 反事实因果推断: **What if** 如果施加了干预措施, 会怎么样?
- 针对同一群体, 没有施加措施 vs 施加措施

为了形式化因果推断, 统计科学家Robin引入潜在结果框架 (Potential Outcomes Framework)。对于每个单元*i*和处理状态*t*, 我们定义潜在结果 $Y_i(t)$ 。

- $Y_i(1)$: 单元*i*接受治疗时的潜在结果
- $Y_i(0)$: 单元*i*未接受治疗时的潜在结果
- 因果效应 $ATE = Y_i(1) - Y_i(0)$

回归分析的问题

■ 回归描述的是“数据中发生了什么”，但我们需要解决的问题是“如果干预会发生什么”。

- 简单差异性比较：直接比较治疗组和对照组的结局会产生严重偏倚，因为两组可能在重要的混杂因素上分布不同。
- 分层分析：只能处理少量分类变量，无法处理连续变量，且当混杂因素较多时面临“维度诅咒”。
- 标准回归：虽然可以调整多个协变量，但模型假设依赖性强，且当时变混杂受既往治疗影响时会产生偏倚。

回归分析的问题

研究者尝试用回归控制混杂

通过将所有混杂变量纳入模型，似乎可以控制所有混杂。然而，这种方法也有其局限性，特别是在严格的反事实框架下。

回归模型的优势

- ✓ 能处理多个变量:可同时调整20+个混杂变量
- ✓ 保留连续变量:不需要离散化,保留更多信息
- ✓ 高效利用数据:不需要每层足够样本
- ✗ 非严格反事实框架:回归估计的是条件关联,非因果效应
- ✗ 时变混杂问题:当时变混杂受既往治疗影响时产生偏倚
- ✗ 模型假设依赖:依赖线性、可加等假设,易误设

回归分析虽然比传统标准化更灵活,但仍不是严格的反事实框架下的分析结果,特别是在处理高维和时变混杂时仍有不足。我们需要一种既能处理高维混杂,又根植于因果推断理论的方法。

James Robins与G公式的诞生


- James Robins在1986年首次提出了G公式与G计算，作为处理时变混杂问题的突破性解决方案
- G代表"Generalized"，即"广义"的意思，是传统标准化的广义形式，它将标准化思想从：
 - 静态处理 → 动态处理序列
 - 低维混杂 → 高维混杂
 - 简单场景 → 复杂时变场景

$$E[Y^a] = \sum_w E[Y \mid A = a, W = w] \cdot P(W = w)$$

"What if we replace the stratum-specific rates with model-based predictions, and standardize to the empirical distribution of the study population?"

从标准化率到G计算

- G公式：广义标准化率
- G计算：利用G公式进行因果推断计算ATE的方法



标准化率的思路

例8 某医院医生用甲疗法和乙疗法分别治疗了400名胃溃疡患者，治疗效果见下表。
试比较甲疗法与乙疗法的有效率？

病型	甲疗法			乙疗法		
	病人数	治愈数	治愈率	病人数	治愈数	治愈率
普通型	300	180	60	100	65	65
危重型	100	35	35	300	125	41.7
合计	400	215	53.8	400	190	47.5

问题：直接比较总有效率会产生偏倚，因为两组的病情构成不同

标准化法的基本思想

- 标准化法的思想是在共同的“标准”上计算标准率，比较两组或多组指标。
- 在公共卫生领域，“标准”的选择最常用的是大样本的群体，如省、全国或世界的人口构成；还可将比较的一组作为共同标准或**将比较的组合并作为共同标准**。


$$\text{标准化率} = \sum (\text{层内率}_i \times \text{标准人口权重}_i)$$

其中权重 = 标准人群中该层的比例

直接法计算标准化治愈率 (%)

病型	甲疗法			甲疗法		
	标准人口比重	治愈数	层内治愈率	标准人口比重	治愈数	层内治愈率
普通型	0.8	180	0.60	0.8	65	0.65
危重型	0.2	35	0.35	0.2	125	0.42
合计	1.0	215	0.55	1.0	190	0.604

在标准化率计算中，权重反映了各层在标准人群中的重要性。权重越大，该层对最终标准化率的贡献越大。权重的作用是重新分配各层的相对影响，使得不同治疗方法在“公平”的基础上进行比较。

传统方法的优点

直观易懂

- 直观易懂是标准化方法的最大优势之一。
- 核心思想简单：在相同基准上比较。

计算简单

- 计算简单使得标准化方法在计算机时代之前广泛使用。
- 只需基本的加减乘除，无需复杂软件，手工即可完成。

结果透明

- 结果透明意味着可以追溯每层的贡献。
- 每个分层的结果都清晰可见，便于识别异常层。

历史价值与现代意义

传统标准化方法在流行病学和公共卫生领域发挥了重要作用。这些方法奠定了比较分析的基础，其思想直接启发了现代因果推断方法（如G-计算）的发展。即使在今天，当处理少量分类变量时，传统标准化仍然是有效且可靠的工具。理解这些经典方法的原理，有助于更好地把握高级因果推断方法的本质。

传统方法的缺点

只能处理少量分层变量

传统标准化通常只能处理1-2个分层变量。

问题：增加变量导致层数指数增长

2变量(各3层) → 9层, 3变量 → 27层

每层需要足够样本量

传统标准化要求每层有足够样本。如果某些层样本量过少：

- 层内估计不稳定，方差大 ✓
- 零样本层无法计算 ✓
- 整体估计不可靠

连续变量必须离散化

传统方法无法直接处理连续变量。必须将其分成几类，这会导致：

- 信息损失：连续变分箱会丢失细节
- 分界点选择主观性强
- 结果可能受分箱方式影响

无法处理高维混杂

这是最严重的问题。现代研究中常有20+混杂变量，传统方法完全无法处理。

现实场景：医学、经济学、社会科学研究常涉及大量潜在混杂因素。

维度诅咒（维度灾难）的数学现实

什么是维度诅咒？

维度诅咒（Curse of Dimensionality）是指当数据维度增加时，数据分析和模式识别变得极其困难的现象。在因果推断中，这意味着当混杂变量数量增加时，传统分层方法的计算复杂度和数据需求呈指数增长。

层数的指数增长

假设所有变量都是二分类，层数为 2^n ：

3个变量

$$2^3 = 8 \text{层}$$

5个变量

$$2^5 = 32 \text{层}$$

10个变量

$$2^{10} = 1024 \text{层}$$

20个变量

$$2^{20} = 1048576 \text{层}$$

现实研究场景

在实际研究中，20+混杂变量是常见情况：

- 医学研究：年龄、性别、BMI、吸烟、合并症、家族史...
- 社会科学：教育、收入、职业、婚姻、地域...
- 经济学：工作经验、行业、地区、公司规模...

传统方法完全无法处理这种复杂度！

维度诅咒的后果

维度诅咒的实际后果

维度诅咒不仅仅是理论问题，它带来了严重的实际后果，使得传统标准化方法在高维场景下失去实用性。

许多层样本量极少或为零

- 当层数超过样本量时，大多数层是空的。

层内估计不稳定

- 即使有样本，每层样本量很少。
- 每层1-2个观测：估计方差大，结果不可靠，易受极端值影响

无法获得有效估计

- 综合结果是无法获得有效估计。
- 空层无法计算率，少样本层估计不可靠，整体估计无意义

需要新的方法

维度诅咒表明，传统方法在高维场景下根本不可行。我们需要能够处理大量混杂变量、不需要每层足够样本、不依赖手工分层的新方法。G-计算正是为解决这些局限而设计的。

G-计算的思想融合

标准化率的思想

广义标准化法

- G-计算继承了传统标准化的核心思想：通过加权平均消除混杂因素差异，在共同基准上比较不同处理策略的效果。

DAG的思想

挑选协变量

- 借助有向无环图（DAG），G-计算可以识别需要控制的最小充分调整集，避免纳入碰撞节点。

回归的思想

用模型代替手工分层

- G-计算用回归模型预测各层发生率，避免维度诅咒，高效处理大量变量。

因果推断的思想

反事实潜在结果框架

- G-计算是反事实框架下的产物，回答“如果全部治疗vs如果全部不治疗”的因果问题。

G-计算的理论突破

🔑 相对于传统标准化的突破

G-计算在多个维度上实现了理论突破，使得因果推断从理想走向现实。

方面	传统标准化	G-计算	突破意义
处理维度	低维(1-2变量)	高维(多个变量)	处理现实复杂数据
变量类型	离散变量	离散+连续+交互	保留更多信息
样本要求	每层需足够样本	整体样本要求	更高效利用数据
实现方式	手工计算	算法/编程实现	自动化、可重复
扩展性	有限	可扩展至时变场景	应用更广

维度突破

从2-3个变量扩展到20+个变量

信息保留

保留连续变量的完整信息

效率提升

从手工到自动化

G-计算五步骤概览

完整流程

G-计算是一个系统化的五步骤流程，从建模到不确定性估计，提供完整的因果推断解决方案。

01

建模

计算各层的实际发生率

02

创建反事实

创建反事实人群下的率

03

边际化

计算边际期望值

04

效应度量

计算ATE等因果效应

05

不确定性

估计标准误和置信区间

核心步骤

步骤1-3是G-计算的核心：**建模 → 预测 → 标准化**。

通过回归模型预测每个个体在反事实场景下的结局，然后对所有个体进行平均，得到边际期望值。

完整推断

步骤4-5完成因果推断：**效应度量 → 不确定性估计**。

通过比较不同反事实场景的边际期望值，计算平均处理效应（ATE）等因果度量，并用自助法估计置信区间。

步骤1：建模阶段

📌 选择合适的模型

G-计算的第一步是选择合适的统计模型来拟合结局与协变量的关系。模型的选择取决于结局变量的类型和研究问题的性质。

01 二分类结局

结局是/否时，使用logistic回归。

$$\text{logit}(P(Y=1)) = \beta_0 + \beta_1 T + \beta_2 W$$

02 生存结局

结局是时间-to-event时，使用Cox回归。

$$\lambda(t) = \lambda_0(t) \exp(\beta_1 T + \beta_2 W)$$

03 连续结局

结局是连续变量时，使用线性回归。

$$E(Y) = \beta_0 + \beta_1 T + \beta_2 W$$

⚙️ 模型拟合

- 使用最大似然估计拟合模型参数
- 纳入所有混杂变量和处理变量
- 考虑交互项（如治疗与协变量交互）

⚠️ 模型假设

模型需要满足正确设定假设：

模型必须正确捕捉结局与协变量的真实关系，否则G-计算估计会有偏。

步骤2：创建反事实人群

👥 构建反事实场景

G-计算的第二步是**构建反事实场景**：设定所有人接受治疗 vs 所有人不接受治疗。

场景A：所有人都接受治疗

对每个个体，变量T全部取值 $T=1$ ，保持协变量W不变

场景B：所有人都不接受治疗

对每个个体，变量T全部取值 $T=0$ ，保持协变量W不变

🔒 保持协变量分布不变

关键原则：**保持协变量分布不变**。

这确保比较的是“相同的人群”在两种处理策略下的结果，消除混杂因素影响。

💡 反事实构建的本质

反事实人群构建的本质是用**模型预测**来填补缺失的潜在结果。

观察到的数据

每个人只有一个观测结果

模型预测

预测每个人在不同处理下的结局

反事实世界

构建两个完整的潜在结果向量

步骤3：计算边际期望值

📊 标准化（边际化）过程

G-计算的第三步是基于预测模型的概率计算规则，分别对事实与反事实人群计算预期概率，并得到反事实场景下的边际期望值。

$$E[Y^a] = (1/N) \times \sum_i E[Y_i | T=a, W_i]$$

即对所有个体的预测值求平均

⚖️ 两个边际期望

我们计算两个反事实场景的边际期望：

$E[Y^1]$

所有人接受治疗的平均结局

$E[Y^0]$

所有人不接受治疗的平均结局

💡 边际均值：在总群体中求均值

```
mod1 <- glm(Y ~ C + w1 + w2 + as.factor(w4), family="binomial", data=data[data$A==1,]) # Expected prob
mod0 <- glm(Y ~ C + w1 + w2 + as.factor(w4), family="binomial", data=data[data$A==0,]) # Expected prob
GcompRA <- cbind(Y1 = predict(mod1, newdata=data.frame(A = 1, C, w1, w2, as.factor(w4)), type="response"),
                 Y0 = predict(mod0, newdata=data.frame(A = 0, C, w1, w2, as.factor(w4)), type="response"))
GcompRA <- as.data.frame(GcompRA)
```

步骤4：因果效应度量

基于边际期望的因果度量

有了两个反事实场景的边际期望值，我们可以计算各种因果效应度量。

连续或一般结局

平均处理效应 (ATE)

$$ATE = E[Y^1] - E[Y^0]$$

所有人接受治疗vs不治疗的平均结局差异

二分类结局

风险差 (RD)

$$RD = P(Y^1=1) - P(Y^0=1)$$

风险比 (RR)

$$RR = P(Y^1=1) / P(Y^0=1)$$

优势比 (OR)

$$OR = (P_1/(1-P_1)) / (P_0/(1-P_0))$$

绝对效应

RD、ATE表示绝对差异，有明确的临床意义。

相对效应

RR、OR表示相对风险，便于比较和沟通。

时间效应

HR适用于生存分析，考虑时间维度。

步骤5：不确定性估计

🏠 目标与方法

G-计算的最后一步是**计算标准误和置信区间**，量化估计的不确定性。

常用方法：**自助法 (Bootstrap)**

非参数方法，通过重抽样估计统计量的分布

🔄 自助法步骤

- 1 从原始数据中有放回抽取B个样本 ($B=1000$) ✓
- 2 对每个样本重复G-计算步骤1-4 ✓
- 3 基于B个估计值计算标准误和置信区间

✅ 完整的不确定性估计

通过自助法，我们得到G-计算估计的**完整不确定性刻画**：

SE

标准误：估计量的变异程度

95% CI

置信区间：真实值的可能范围

p-value

p值：统计显著性检验

回归分析与G-计算对比

? 两种方法回答不同的问题

回归与G-计算的核心差异在于它们回答不同的问题。理解这种差异对于选择合适的方法至关重要。

01 回归分析

比较"相似的人"

"协变量W相同的人中，一个接受治疗，一个不接受，结果平均差多少？"

比喻：比较两个双胞胎

02 G-计算

比较"整个群体"

"所有人接受治疗vs所有人不接受，整个群体的平均结果差多少？"

比喻：全部高血压病人都服药

! 这种差异代表什么？

回归回答的是个体层面的条件效应（给定协变量下的效应），而G-计算回答的是群体层面的边际效应（整个人群的平均效应）。因果推断中，我们通常关心的是边际效应：如果实施某策略，总人口的健康状况会如何变化？

条件期望 vs 边际期望

📈 回归模型：条件期望

回归模型估计的是条件期望：给定协变量W下的处理效应。

$$E[Y|T,W]$$

特点：

- 效应可能随W变化（交互作用）
- 需要指定W的值才能得到具体数值

🏠 G-计算：边际期望

G-计算估计的是边际期望：整个人群的平均效应。

$$E[Y^a] = E_W[E[Y|T=a,W]]$$

特点：

- 得到单一数值
- 代表整个人群的平均效应

💡 数学关系

当处理与协变量无交互时，两者相等。G-计算通过回归建模和边际化，巧妙结合了回归的灵活性和标准化的因果解释。

小结：G 实际应用优势

🔧 技术优势

- 能处理20+混杂变量，打破维度诅咒 ✓
- 保留连续变量信息，避免离散化损失 ✓
- 高效利用数据，不需要每层足够样本 ✓
- 可重复性强，算法实现消除人为误差 ✓

🔗 扩展性优势

- 纵向数据：可扩展至时间依赖场景 ✓
- 动态策略：评估自适应治疗策略 ✓
- 多处理：可比较多个处理策略 ✓
- 复杂场景：处理死亡竞争风险等 ✓

★ 应用价值

G-计算的优势使其在医学、公共卫生、经济学、社会科学等领域得到广泛应用。它为观察性研究提供了可靠的因果推断工具，使得研究者能够从复杂数据中提取有效的因果结论，为循证决策提供科学依据。特别是在精准医疗和个性化治疗策略评估中，G-计算发挥着不可替代的作用。

小结：如何选择方法

🔗 如何选择合适的方法？

选择因果推断方法需要考虑研究问题、数据特征、混杂因素等多个因素。

01 传统标准化

适用条件

- 1-2个分类混杂变量
- 样本量充足
- 需要直观解释

优点

- 简单、透明、易理解

局限

- 无法处理高维混杂

02 回归分析

适用条件

- 描述观察到的关联
- 识别风险因素
- 预测个体结局

优点

- 灵活、可处理多变量

局限

- 非严格因果框架

03 G-计算

适用条件

- 估计因果效应
- 高维混杂
- 时变混杂

优点

- 严格因果框架、可扩展

注意事项

- 模型必须正确设定

⚠️ 关键注意事项

无论使用哪种方法，都需要：

- 确保无未测量混杂
- 验证模型假设
- 进行敏感性分析

方法选择应基于：

- 研究问题的本质
- 数据特征
- 需要回答的因果问题类型

谢谢!

因果推断的未来：从数据到决策

G-计算

高级因果推断

处理高维混杂

反事实

潜在结果框架

因果思维基础

应用

循证决策

推动真实世界研究

"G-计算为观察性研究提供了严格的因果推断工具，使得研究者能够从复杂数据中提取有效的因果结论。"