

因果推断模型与机器学习方法



郑老师团队

“因果推断模型与机器学习方法”训练营--理论篇

第二讲 DAG方法及回归应用

“文与统计分析”公众号

本讲内容

- DAG方法与混杂偏倚控制
- DAG 与回归引用
- 回归模型变量筛选方法




第1节 DAG与混杂偏倚




结构因果模型与DAG

- 1980年代，图灵奖得主朱迪亚·珀尔（Judea Pearl）提出了结构因果模型（SCM）
- 它认为，世界是由一系列稳定、自主的因果机制构成的。例如，物理定律、生物过程、经济规则等。SCM的目标就是用数学语言来显式地建模这些机制。
- SCM的语言是有向无环图（Directed Acyclic Graph, DAG）。



结构因果模型与DAG


- 因果DAG是一个带有箭头的、没有回路的图形，表示假设的因果影响的方向(例如，从接种疫苗到住院)。
- 在DAG中，每个节点代表一个变量，每条有向边（箭头） $X \rightarrow Y$ 代表一个直接的因果机制，即X是Y的一个直接原因
- DAGs的核心价值在于，它迫使研究者基于领域知识，明确提出关于变量之间因果结构的假设。
- 通过节点（代表变量，如暴露、结局或协变量）和箭头（表示因果方向），DAGs能够帮助研究者识别混杂因子、中介变量、碰撞变量以及其他潜在的偏倚来源。



概念1：后门路径与前门路径

后门 路径	后门路径是指从一个因变量与自变量之间一个关系的路径，但该路径通过一个或多个共同原因逆向链接到这个效应变量。例如 $E \leftarrow$ 。它是非因果路径
前门 路径	前门路径通过介入一个或多个介质（中介变量）的方式来传递变量间的因果效应。例如 $E \rightarrow$ 。又称：因果路径

概念1：后门路径与前门路径




概念2: DAG 几种变量类型

类型	中介变量	混杂变量	碰撞变量
定义	中介变量是指解释一个自变量 (X) 和因变量 (Y) 之间关系的中间变量。它是自变量对因变量影响途径上的变量。	混杂变量是干扰因素, 它同时影响自变量和因变量, 导致自变量和因变量之间的关系出现偏差。	碰撞变量是指在原本不存在关系的两个变量之间出现关系的变量。它可能创建假象的关系或改变原有的关系。
DAG	$X \rightarrow M \rightarrow Y$	$X \leftarrow C \rightarrow Y$	$X \rightarrow Z \leftarrow Y$

概念2: DAG 几种变量类型

Figure. Example of Directed and Nondirected Paths



The directed paths represent the effect of E on O that is being estimated. Bias can be reduced by adjusting or controlling for C to close that nondirected path. Conversely, the nondirected path that includes S is closed if it is uncontrolled and thus is not a biasing path; controlling for S opens that path and may introduce bias.

碰撞变量

- 如果一个节点是路径上两个或更多箭头的共同终点（被多个变量直接影响），它就是该路径上的碰撞变量（Collider）。
 - 存在一条路径 $A \rightarrow C \leftarrow B$ （即两个箭头同时指向该变量）。
 - C节点是路径中箭头汇聚的点，即碰撞变量
- 为什么叫“碰撞”？
 - 两条信息流（从 A 和 B 出发）在 C 点发生“碰撞”，导致：
 - 不观测 C 时：信息流相撞抵消，路径阻塞。
 - 观测 C 时：已知 C 的值，相当于知道了碰撞结果，从而能导致 A 和 B 的相关（即使它们无关）。

一个案例：出生体重悖论

1964年，一个学者发现：

- 低出生体重婴儿中，母亲吸烟的比不吸烟的存活率更高

Mother's cigarette smoking and survival
of infant

J. YERUSHALMY, Ph.D.
Berkeley, California

出生体重悖论



母亲吸烟



关系如何?



婴儿死亡

利用回归分析，探讨其中的关联

独立的影响因素就是意味着它是因吗？

- 影响因素研究是基于现有已测数据，以概率学的方法结合回归分析的方法去评价有关影响因素
- 构建回归模型，多影响因素分析
 - ✓ 因变量：死亡
 - ✓ 自变量：母亲是否吸烟、孩子出生体重

$$Y=b_0+b_1x_1+b_2x_2$$

一个案例：出生体重悖论

初步分析（单因素分析）

在不矫正出生体重情况下，吸烟促进了婴幼儿死亡率（ $HR=1.55$ ，95%CI 1.50-1.59），

回归分析

在包括出生体重作为X的情况下，这个比值变成了1.09（ $HR=1.09$ ，95%CI 1.02-1.12）。

吸烟是独立的影响因素($HR=1.09$ ，95%CI 1.02-1.12)

一个案例：出生体重悖论

初步分析（单因素分析）unadjusted

在不矫正出生体重情况下，吸烟促进了婴幼儿死亡率（ $HR=1.55$ ，95%CI 1.50-1.59），

回归分析（adjusted）

在包括出生体重作为X的情况下，这个比值变成了1.09（ $HR=1.09$ ，95%CI 1.02-1.12）。

因此，吸烟是独立的影响因素($HR=1.09$ ，95%CI 1.02-1.12)

在这个案例中，回归扮演可能扮演了另外一个角色，控制混杂偏倚，出生体重是混杂偏倚，当它被纳入模型，相当于它产生地偏倚被控制了。问题真的矫正了混杂偏倚吗？

一个案例：出生体重悖论

亚组分析

在亚组人群，低出生体重群体里面，吸烟预防因幼儿的死亡率
(HR=0.79, 95%CI 0.76-0.82, 高出生体重群体里面，吸烟促进因幼儿的死亡率(HR=1.80, 95%CI 1.72-1.88)


- **难道是交互作用？**
- **出现出生体重悖论！**

it has been suggested that the effect of maternal smoking is modified by birth weight in such a way that smoking is beneficial for LBW babies (Am J Epidemiol 1971;93:443-56)

“出生体重悖论”：混淆相关与因果推断


- **相关：**孕期吸烟和婴儿死亡率在数据中呈现关联，出生体重可能是相关的一个因素。
 - “调整”出生体重后发现吸烟母亲的婴儿死亡率低 → 得出荒谬结论
- **因果推断：**需要明确孕期吸烟是否真正导致婴儿死亡率升高，以及出生体重在因果路径中的角色（是中介变量还是混杂变量）。
 - 正确识别出生体重是中介/碰撞变量，不能随意调整 → 得出正确因果效应

因果推断重要方法：DAG




识别变量类型的工具：DAG


吸烟作为混杂变量




LBW作为碰撞变量



LBW作为中介变量




中介变量+混杂



LBW是混杂吗？

LBW可能不是混杂而是中介



初步分析（单因素分析）`unadjusted`

在不矫正出生体重情况下，吸烟促进了婴幼儿死亡率（ $HR=1.55$ ，95%CI 1.50-1.59），


回归分析（`adjusted`）

在包括出生体重作为X的情况下，这个比值变成了1.09（ $HR=1.09$ ，95%CI 1.02-1.12）。吸烟是独立的影响因素（ $HR=1.09$ ，95%CI 1.02-1.12）

这严重错误的结论

LBW真的是中介吗？


LBW是中介吗？



中介作用的分析，解决不了出生悖论

在亚组人群，低出生体重群体里面，吸烟预防因幼儿的死亡率
(HR=0.79, 95%CI 0.76-0.82, 高出生体重群体里面，吸烟促进因幼儿的死亡率(HR=1.80, 95%CI 1.72-1.88))

LBW 可能还是碰撞变量




碰撞变量：一个变量受暴露因素影响，且与结局受共同变量影响

- 碰撞变量不应该在因果推断的路径上（或者不应该在回归模型中）
- 当回归分析纳入碰撞变量，而建立起不正确的关系：即包括出生体重作为X的情况下，
HR=1.09，95%CI 1.02-1.12，引发了后续错误的亚组分析结果（Am J Epidemiol 2006;164:1115-1120）


DAG因果推断的主要作用

- 1. 明确识别并控制混杂因素；
- 2. 确定不应控制的碰撞变量以免引入偏倚；
- 3. 理清中介路径和潜在的效应修饰，以免引入偏倚；
- 4. 判断何种变量可用作工具变量；


DAG的作用：选择合适的变量进入模型



如果吸烟是混杂，要分析LBW与死亡率的关系。建立统计模型，吸烟必须纳入模型中



LBW是碰撞变量，建立吸烟与死亡的关系，不能纳入LBW进入回归模型



LBW是中介，建立吸烟与死亡的关系，不能纳入LBW进入回归模型；或者开展中介分析

That is, we cannot answer causal questions with the data alone, *no matter* how big the data are and how deep the neural network is

DAG绘制

因果推断革命

DAGitty — draw and analyze causal diagrams

DAGitty is a browser-based environment for creating, editing, and analyzing causal diagrams (also known as directed acyclic graphs or causal Bayesian networks). The focus is on the use of causal diagrams for minimizing bias in empirical studies in epidemiology and other disciplines. For background information, see the ["learn"](#) page.

Launch



Launch DAGitty
online in your
browser.

Download



Download DAGitty's
source for offline
use.

Learn



Learn more about
DAGs and DAGitty.

Code



The R package
"dagitty" is
available on [CRAN](#)
or [github](#).

DAGitty is developed and maintained by [Johannes Textor](#) (Institute for Computing and Information Sciences, [Radboud University](#), and Medical BioSciences department, [Radboudumc](#), Nijmegen, The Netherlands).

Many algorithms implemented in DAGitty were developed in close collaboration with [Maciej Liskiewicz](#) and [Benito van der Zander](#), University of Lübeck, Germany (see literature references below).

DAGitty development happens on [github](#). You can download all source code from there and also get involved.



Changelog

2023-10-07

Moved to a new webserver after 12 years.

2023-07-11

Version 3.1 is out, featuring selection variables.

2020-01-09

Version 3.0 has been released! Complete reimplementaion of the interface, should work with mobile/touch now.

2018-04-04

Updated the development version and preparing for a long overdue release!


2015-08-19

www.dagitty.net

欢迎参加郑老师团队的“因果推断与机器学习”训练营，请联系助教aq566665，一步一步学会R语言因果推断方法

(2) DAG绘制

因果推断案例





第2节 DAG与回归应用



回归模型

- **构建一个类真实的模型，模拟真实环境**
 - 一个健康结局的发生，由多个因素共同决定

- **回归的应用**
 - 分类
 - 预测
 - 因果关联性分析

- 线性回归
- 广义线性回归
 - Logistic、等级logistic、泊松回归及其修正版、负二项回归、零膨胀模型、广义加性模型
- Cox比例风险模型

线性回归

- 线性回归分析常用于定量数据建模

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots \cdots + \beta_m X_m + e$$

- 结局为定量数据，自变量不作要求
- 可探讨影响因素、控制混杂偏倚、建立预测模型

logistic回归

- Logistic 回归分析用于分类结局，常用于二分类

$$\ln\left(\frac{P}{1-P}\right) = b_0 + b_1X_1 + b_2X_2 + \cdots + b_mX_m$$



- 结局为分类数据（常见二分类），计算OR值
- 可以探讨影响因素、控制混杂偏倚、建立预测模型
- 主要形式
 - 非条件logistic回归
 - 条件logistic回归
 - 等级logistic回归

Cox回归

- Cox回归分析常用于随访的队列研究或者RCT研究

$$h_i(t) = h_0(t) \exp(\beta_1 x_{i1} + \dots + \beta_j x_{ij})$$

- 结局为生存数据（双结局：时间和生存结局），计算HR值
- 可探讨影响因素、控制混杂偏倚、建立预测模型
- 尤其擅长动态队列的随访分析



2.1. 表2谬误

- 表2：一篇文章第二个主表（多因素回归分析）
- 举例：分析COPD发生的影响因素
- 经Logistic回归分析，结果显示年龄、肺炎疫苗、吸烟影响COPD的因素（均 $P < 0.05$ ）

变量	B	$s_{\hat{B}}$	Wald χ^2 值	P 值	OR值	95%CI
肺炎疫苗	-0.030	0.008	15.22	0.000	0.970	0.956~0.985
年龄	0.274	0.119	5.261	0.022	1.315	1.041~1.661
吸烟	0.447	0.076	34.455	0.000	1.563	1.347~1.815

单一模型的结果是数据驱动的

- A widespread approach is first to “find the best model for the data” and second to develop an appropriate interpretation of the fitted model.
- **这是因果推断吗？**

统计学解读

$$\ln [P / (1 - P)] = \beta_0 + \beta_1 \text{肺炎疫苗} + \beta_2 \text{吸烟} + \beta_3 \text{年龄} + e$$

- 统计学系数解读：

- 其它自变量不变的情况下，每改变一个单位，Y改变的量
- 另一种说法是调整其它自变量的影响（相互调整）

- 若P值<0.05，该解释为独立的影响因素吗？

回归系数解读

- 在给定吸烟状况和年龄的条件下，系数 β_1 代表感染肺炎疫苗对 COPD 对数比值 (logit) 的条件总效应 (conditional total effect)。
- β_2 不能以相同的方式解释，它不能被解释为吸烟的总效应。
 - 在调整后的模型中， β_2 是相对于肺炎疫苗而言，吸烟的直接效应 (direct effect) (一个直接的对数比值比)。
 - β_2 是吸烟对 COPD 的影响中，不通过吸烟对肺炎疫苗的影响来介导 (mediated) 的那部分效应。更准确地说，它是吸烟的受控直接效应 (controlled direct effect)，即当肺炎疫苗被固定，在给定水平时，吸烟对对数比值的因果效应。肺炎疫苗，阻断了吸烟对结局的部分影响。
- 若谈论年龄的影响，那么 β_3 类似地是在肺炎疫苗和吸烟被固定住时，年龄增长对的受控直接效应。

表2谬误：回归的致命问题


- 回归只是研究统计学相关
- 许多传统统计分析更关注模型本身，而不是试图解决的问题”，并将观察到“拟合模型”视为真相进行解释而存在错误。

同样都是回归

- 描述性的回归VS因果推断的回归
 - ✓ 关联性分析用于关联与预测分析
 - ✓ 因果推断控制混杂偏倚
- 两者最大的区别在于，是否基于domain knowledge，临床/生物的知识

数据驱动型分析 vs 知识推动型分析

DAG往往是重要的工具



每个变量的混杂、中介都不同，如果开展回归，则需要结合DAG的方法来考虑

2.2 因果推断的回归方法

- **先验知识主导、先因后果的一种分析策略**
 - DAG思维
 - 包括混杂、潜在混杂，不包括中介变量或碰撞变量的回归模型
 - 多模型策略
 - 敏感性分析

多模型策略

- 协变量从零个到多个，基于专业知识和文献挑选协变量
- 从人口学、社会经济、生活行为方式、疾病特征
- 详细呈现协变量的影响，以及哪个层面的影响，
- 是一种敏感性分析

Table 2

Association between sleep duration and depression in multiple regression model.

	Non-adjusted Model OR (95% CI)	P-value	Model I OR (95% CI)	P-value	Model II OR (95% CI)	P-value	Model III OR (95% CI)	P-value
Sleep duration Hours of Sleep	0.86 (0.82, 0.90)	<0.001	0.86 (0.83, 0.90)	<0.001	0.87 (0.84, 0.91)	<0.001	0.88 (0.84, 0.91)	<0.001
< 7	2.21 (1.90, 2.56)	<0.001	2.03 (1.74, 2.36)	<0.001	1.92 (1.65, 2.24)	<0.001	1.86 (1.59, 2.17)	<0.001
7 - 9	Ref		Ref		Ref		Ref	
≥ 9	1.97 (1.62, 2.38)	<0.001	1.62 (1.33, 1.97)	<0.001	1.57 (1.29, 1.92)	<0.001	1.49 (1.22, 1.83)	<0.001

Model I: Adjust for sex, age, race, education, marital status, and annual family income.

Model II: Adjust for the variables in Model I plus BMI, alcohol status, and smoking status.

Model III: Adjust for the variables in Model II plus hypertension, diabetes, dyslipidemia, work activity, and Physical activity.

案例分享

- 2021年8月27日，中国中日友好医院曹彬教授联合首都医科大学等研究人员在国际顶级期刊《柳叶刀》上在线发表了题为"1-year outcomes in hospital survivors with COVID-19: a longitudinal cohort study"的研究论文

1-year outcomes in hospital survivors with COVID-19: a longitudinal cohort study

Lixue Huang*, Qun Yao*, Xiaoying Gu*, Qiongya Wang*, Lili Ren*, Yeming Wang*, Ping Hu*, Li Guo*, Min Li*, Jiuwang Xu, Xueyang Zhang, Yali Ou, Yanqing Fan, Xia Li, Caihong Li, Ting Yu, Jiaan Xia, Ming Wei, Li Chen, Yanping Li, Fan Xiao, Dan Liu, Jianwen Wang, Xiangguang Wang, Bir Edr

基本情况

- 该研究对2020年1月7日至5月29日期间从金银潭医院出院的 COVID-19 幸存者进行了一项双向队列研究。
- 在6个月和12个月的随访中，幸存者接受了有关症状和健康相关生活质量 (HRQoL) 的问卷调查，并接受了体检、6分钟步行测试和实验室测试。
- **主要结果：**症状、改良的英国医学研究委员会 (mMRC) 评分、HRQoL 和 6分钟步行距离 (6MWD)。
- **多变量调整logistic回归模型**用于评估 12个月结果的危险因素。

影响因素分析

针对疲劳或肌肉无力、焦虑或抑郁、弥散功能障碍三个结局指标，作者开展了影响因素研究。

Outcome: 它的结局是三个分类变量结局：疲劳或肌肉无力（是/否）、焦虑或抑郁（是/否）、弥散功能障碍（是/否）

Expoure暴露因素: 这些影响包括age, sex, cigarette smoking, education, comorbidity, corticosteroids, antivirals, and intravenous immunoglobulin、disease severity 。

主要统计学方法

- Logistic回归

We used multivariable adjusted logistic regression analysis to explore risk factors associated with diffusion impairment, anxiety or depression, and fatigue or muscle weakness. For the association of disease severity with

混杂控制策略

(1) 首先分析的暴露因素是疾病严重程度 (disease severity) , 对于这个变量而言, 年龄、性别、吸烟状态、教育程度、并发症、皮质类固醇、抗病毒治疗、静脉注射免疫球蛋白是潜在混杂变量, 所以回归分析的时候都一同纳入。

weakness. For the association of disease severity with outcome, age, sex, cigarette smoking, education, comorbidity, corticosteroids, antivirals, and intravenous immunoglobulin were adjusted. For the association

混杂控制策略

(2) 分析教育和吸烟程度与结局的关系。并发症、疾病严重程度不能纳入模型，因为它们可能是中介变量。

When exploring the associations of education and smoking with outcome, the aforementioned variables except for comorbidity, and both comorbidity and disease severity (due to the potential mediation) were included, respectively

混杂控制策略

(3) 分析年龄和结局的关系。性别、吸烟状态、教育程度能放了，因为其它变量可能是中介变量。


respectively. Only sex, smoking, and education were adjusted for the association between age and outcome due to the potential mediation of other factors. For

混杂控制策略

(4) 分析并发症和结局的关系。 疾病严重程度不能纳入模型，因为它可能是中介变量。

due to the potential mediation of other factors. For the association of comorbidity with outcome, the aforementioned variables except for disease severity were all included. Additionally, a sensitivity analysis with

DAG示意图



案例2

Original Investigation | Psychiatry

Association Between Childhood Behavioral Problems and Insomnia Symptoms in Adulthood

Yohannes Adama Melaku, MPH, PhD; Sarah Appleton, PhD; Amy C. Reynolds, MScMed(ClinEpi), PhD; Alexander M. Sweetman, PhD; David J. Stevens, PhD; Leon Lack, PhD; Robert Adams, MBBS, MD

儿童行为问题与成人失眠症状关系

JAMA Network Open, 2019

研究大致方案

Cohort: the United Kingdom 1970 Birth Cohort Study

Exposure: behavioral problems at 5, 10, and 16 years of age using the Rutter Behavioral Scale(RBS) **(儿童行为问题)**


Outcome: Self-reported difficulties initiating or maintaining sleep (DIMS) were collected using a self-administered questionnaire at 42 years of age **(成人失眠)**

研究主要协变量（混杂变量）

Covariates

A series of potential confounders were selected a priori based on a direct acyclic graph (eFigure 2 in the Supplement).^{40,41} Details on assessment and categorization of covariates that were included in this analysis are provided in the eAppendix in the Supplement. In brief, data on sex, parent-reported childhood sleep difficulty, and parents' educational status and social class were collected at 5, 10, and 16 years of age. At 42 years of age, data on sociodemographic factors, including marital status, social class, and educational level, were collected. Behavioral factors, including smoking, alcohol consumption, and physical activity, were also assessed. Height and weight were collected at 10, 16, 26, 29, 33, 38, and 42 years of age, and body mass index (BMI) was calculated (as weight in kilograms divided by height in meters squared).³¹ At 42 years, mental health was assessed using the Warwick-Edinburgh Mental Well-being Scale.⁴² Perceived health status was determined by interview. The number of prevalent self-reported noncommunicable diseases (hypertension, diabetes, cancer, asthma, and migraine) was determined.

本案例的DAG图



本案例回归方法

years, we used log-binomial logistic regression and determined odds ratios (ORs) and 95% CIs. Two models were developed: model 1 was adjusted for sex, parent's social class and educational level, marital status, educational status, and social class; model 2 was additionally adjusted for physical activity level and BMI trajectory (from 10 to 42 years), perceived health status, and number of

采用log-binomial logistic 回归方法，构建2个不同层次的回归方法

本案例的中介变量

noncommunicable diseases. Childhood behavioral problems may affect childhood sleep,^{28,29} as well as smoking,⁴⁶ alcohol consumption,⁴⁷ and mental well-being²⁶ during adulthood. Because these factors may mediate an association between CBPs and insomnia, we did not adjust for them in our main analysis. However, we conducted secondary analyses in which these factors were considered as

儿童期睡眠、成年期饮酒、吸烟、精神状态等作为中介变量，回归分析时不纳入，但进行敏感性分析（二次分析）。

小结

- 变量是混杂还是中介并非一成不变
- 混杂因素与中介因素都将影响暴露因素与结局的关联性。
- 混杂因素应该纳入模型，中介变量因一般不纳入模型。



第3节 回归自变量筛选方法



3.1 回归自变量筛选方法

构建多因素回归模型的基本要求

大道至简


自变量个数尽量少，纳入有限的自变量数量往往能构建合适的回归模型

模型自变量筛选原则

- 纳入模型的变量少一些
- 多淘汰一些变量出去

严进严纳

统计学四大刊



AJE
(IF=5.0)



EPI
(IF=7.3)



EJE
(IF=13.6)



IJE
(IF=7.7)



American Journal of Epidemiology
© The Author(s) 2023. Published by Oxford University Press on behalf of the Johns Hopkins Bloomberg School of Public Health. All rights reserved. For permissions, please e-mail: journals.permissions@oup.com.

Vol. 193, No. 2
<https://doi.org/10.1093/aje/kwad193>
Advance Access publication:
September 28, 2023

Practice of Epidemiology

Recent Methodological Trends in Epidemiology: No Need for Data-Driven Variable Selection?

《流行病学研究中的方法学变化趋势：无需数据驱动的变量选择？》

Christian Staerk*, Alliyah Byrd, and Andreas Mayr

* Correspondence to: Dr. Christian Staerk, Department of Medical Biometry, Informatics and Epidemiology, University Hospital Bonn, Venusberg-Campus 1, 53127 Bonn, Germany (e-mail: christian.staerk@uni-bonn.de).

Initially submitted January 20, 2023; accepted for publication September 27, 2023.

Variable selection in regression models is a particularly important problem in epidemiology, because observational studies often encounter confounding. Unlike randomized clinical trials or laboratory experiments, confounding is not controlled by randomization, but must be controlled by appropriate statistical methods. For example, when estimating the effect of a risk factor on a disease outcome, multivariable regression techniques can help to adjust for confounding. We summarize the current practice of variable selection in epidemiology, with a focus on high-dimensional data situations (i.e., large sample size compared with the number of variables). Based on our results, we discuss the role of data-driven variable selection in epidemiology.

confounders; epidemiologic methods; modeling; regression; variable selection

在流行病学中，回归模型中的变量选择是一个特别重要的问题，因为在流行病学中通常会遇到观察性研究。与随机临床试验或实验室试验不同的是，混杂因素往往不受研究设计的控制，而必须通过适当的统计方法加以考虑。例如，当需要通过无干扰效应估计值来确定风险因素时，多变量回归技术就可以帮助调整干扰因素。我们汇总了2019年流行病学四大期刊在变量选择方面的现行做法。

the main aim of analysis was hypothesis-driven effect estimation. In high-dimensional data situations (i.e., large sample size compared with the number of variables), based on our results, we discuss the role of data-driven variable selection in epidemiology.

关键词： 观察性研究 混杂因素 变量选择

自变量筛两种策略

自变量筛选两种策略

- 理论驱动法
 - 先验知识(DAG)法
- 数据驱动法
 - 先单后多
 - 逐步回归法
 - 效应改变法
 - LASSO法

(1) 如何挑选自变量进入模型

- 《美国流行病学》杂志把筛选自变量的方法分为两类，一类是理论驱动方法，另外一类是数据驱动方法，先单因素再多因素或者逐步回归法是数据驱动的一类方法。
- 具体来说，现在常见的筛选自变量方法有四种：

“Among those, 199 studies (73%) reported using prior knowledge or **causal graphs** for selecting variables, 18 (7%) used **change in effect estimate** methods, 11 (4%) used **stepwise approaches**, 9 (3%) employed **univariate analyses**, and 43 (16%) did not provide sufficient details to allow classification

表1. 2019 年 4 种主要流行病学期刊发表文章的变量选择方法综述结果

Classification Category	Journal								Total					
	AJE (n = 109)		EPI (n = 43)		EJE (n = 42)		IJE (n = 78)		2019 (n = 272)		2015 ^a (n = 292)		2008 ^a (n = 300)	
	No.	%	No.	%	No.	%	No.	%	No.	%	No.	%	No.	%
Variable selection methods														
Prior knowledge									199	73	146	50	83	28
Prior knowledge and causal graphs	15	9	21	4	10	6	8	35	13	— ^b	—	—	—	—
Data-driven variable selection									43	16	69	24	112	37
Change-in-estimate	9	8	2	3	7	5	6	18	7	34	12	44	15	
Stepwise selection	4	4	2	1	2	5	6	11	4	16	5	59	20	
Univariate selection	4	4	2	0	0	4	5	9	3	26	9	—	—	
Regularization methods	0	0	0	1	2	1	1	2	1	0	0	0	0	
Other methods	2	2	2	0	0	4	5	7	3	5	2	9	3	
Not described	21	19	11	26	1	2	10	13	43	16	107	37	105	35

- 大多数文章利用知识先验地确定了纳入回归的变量
- 数据驱动型越来越少，而基于先验知识的先验变量选择越来越多
- 13%明确使用了“因果图”

自变量筛选方法所处阶段

- 严进
 - 先验知识 (DAG法)
 - 先单后多
- 严纳
 - 效应改变法
 - 逐步回归法

(2) 先单后多的策略

- “先单后多”的基本建模方法：“严进”策略
 - 首先，一个一个进行单因素分析（简单关联性方法）
 - t检验、卡方、秩和、相关分析、方差分析
 - 单因素回归
 - 然后，挑选 P 值较小者进入多因素回归
 - $P < 0.2$ ，还是0.1，还是0.05，根据自变量数量而定
 - 自变量越少， P 值越大

“先单后多”不是必须

- DAG方法，不一定“先单后多”
- 样本量很大，自变量数量不多，可全部纳入（多因素回归不一定都需要先单后多）
- 单因素分析没有发现有统计学差异、但是专业上认为与因变量关系密切的自变量也要纳入多因素模型。

(3) 效应改变法

- “严纳”的重要方法—因果推断研究专用
- DAG方法之后，分为以下几种场景
 - 自变量不多，严纳策略不再考虑
 - 自变量略多，先单后多，严纳策略不再考虑
 - 自变量略多，不采用先单后多，而考虑效应改变法
 - 自变量很多，采用先单后多，而后再考虑效应改变法

效应改变法的统计思维

效应改变法 (Change-in-Estimate, CIE) 是一种数据驱动自变量筛选方法，通过剔除多因素回归模型中对重要的自变量效应影响不大的变量从而减少自变量个数的方法。这些目标研究因素效应改变较大的，一般是混杂因素，需要留在多因素回归模型中。

效应改变法的统计思维

案例2:

这是一项关于胰腺癌病人生存时间的研究。

该研究的终点为死亡，此外还包括生存时间。跟结局有关的变量比较多，其中，主要关心的是**术中放疗对生存结局**的影响。

本研究相关变量赋值情况

变量名	变量说明	变量类型	分类变量的编码
time	生存时间（月）	连续	
censor	生存结局	2 分类	0: 删失、1: 死亡
age	手术时的年龄	连续	
trt	有无手术中放疗	2 分类	0: 无术中放疗、1: 有术中放疗
sex	性别	2 分类	0: 男、1: 女
bui	占位处	2 分类	0: 胰脏头部、1: 头部以外
ch	胰胆管浸润程度	有序多分类	1: ch0、2: ch1、3: ch2、4: ch3
p	有无腹膜转移	2 分类	0: 无、1: 有
stage	TNM 分期	2 分类	3: III期、4: IV期

多因素分析

术中放疗是目标研究因素，开展Cox回归分析，结果如下图，其效应指标为HR=0.302。

变量	<i>B</i>	<i>SE</i>	<i>Wals</i>	<i>P</i> 值	<i>OR</i> HR值
手术时的年龄	0.059	0.018	11.208	0.001	1.061
性别	-0.648	0.423	2.349	0.125	0.523
有无手术中放疗	-1.197	0.566	4.469	0.035	0.302
占位处	-0.087	0.564	0.024	0.877	0.916
胰胆管浸润程度	-0.157	0.198	0.627	0.428	0.855
有无腹膜转移	0.459	0.468	0.960	0.327	1.582
TNM 分期	1.279	0.464	7.589	0.006	3.593

效应改变法的统计原理

基本原理:

- 当某个协变量不是混杂因素，它在不与在，对关键暴露因素效应值影响甚微，因此一般回归模型不保留该协变量。
- 如果某协变量是混杂因素，则回归模型纳入和不纳入，关键暴露因素效应值改变很大。
 - 纳入：扣除了偏倚
 - 不纳入：暴露因素与结果的关系存在着偏倚

效应改变法的统计原理

当剔除自变量后，对最初模型效应值的影响不超过10%者，删除变量。

根据以下公式，计算效应改变量：

$$\Delta HR = |HR_i - HR| / HR$$

(HR_i 为剔除某一个自变量后，术中放疗的HR值，当 $\Delta HR < 0.1$ 时，证据显示，该自变量的确可以舍弃掉了，因为它对术中放疗的HR值影响不大。)

效应改变法的统计原理

例如：剔除年龄的变量，得到 $HR=0.208$ ，则 $0.208/0.302=68.7\%$ ，远远小于90%的界限，因此，年龄需要保留。

变量	<i>B</i>	<i>SE</i>	<i>Wals</i>	<i>P</i> 值	OR 估计值 HR值
性别	-0.426	0.406	1.100	0.294	0.653
有无手术中放疗	-1.570	0.504	9.704	0.002	0.208
占位处	0.340	0.505	0.452	0.502	1.404
胰胆管浸润程度	-0.123	0.185	0.437	0.508	0.885
有无腹膜转移	0.269	0.447	0.363	0.547	1.309
TNM 分期	1.009	0.438	5.305	0.021	2.743

效应改变法的统计过程

具体过程:

首先，逐一剔除每一个变量，分别构建回归模型，得到所有的术中放疗的HR值，挑选出一个对HR影响最小，且不超过10%（常见）的删除出去。

第二轮，逐一剔除余下的每一个变量，分别构建回归模型，再挑选一个HR影响最小且不超过10%的自变量删除出去，**以此类推**，直到自变量再无法删除为止。

效应改变法的统计过程

效应改变法筛选变量的HR值汇总

变量	变量名	第一轮	第二轮	第三轮	第四轮
age	手术时的年龄	0.208	0.216	0.197	0.202
sex	性别	0.293	0.291	0.299	
bui	占位处	0.299			
ch	胰胆管浸润程度	0.389	0.391	0.493	0.487
p	有无腹膜转移	0.248	0.243	0.243	0.257
stage	TNM 分期	0.292	0.301		

- 是否留在模型的HR值界限为0.272-0.339，根据该界限，得到以下结果：
 - 第一轮，**占位处**被剔除；第二轮，**stage**被剔除；第三轮，**sex**被剔除；最后一轮，**没有剔除者**。

效应改变法的统计原理

多因素Cox 逐步回归分析结果

变量	B	SE	Wals	P 值	HR值
有无手术中放疗	-1.206	0.522	5.344	0.021	0.299
手术时的年龄	0.055	0.018	9.058	0.003	1.056
胰胆管浸润程度	-0.304	0.174	3.066	0.080	0.738
有无腹膜转移	0.338	0.450	0.566	0.452	1.403

最终得到HR为0.299。

效应改变法一般用于控制混杂偏倚，关键看对目标变量的影响。

(4) 逐步回归法

- 逐步回归法包括三类
 - 向前
 - 向后
 - 双向逐步

一般不推荐逐步回归法

- 逐步回归法在回归模型探讨影响因素的过程中，都不是主要策略。
 - 若探讨影响因素，尽量不要用逐步回归法。若自变量太多，在单因素分析时限制（ P 值较小者纳入多因素回归）。

逐步回归法意味着垃圾进、垃圾出

何时考虑逐步回归法

- 构建预测模型
- 多影响因素分析时，多因素回归自变量个数实在太多
- 存在多重共线性时

权威杂志的统计学指南

- 内科学年鉴 (Annals of Internal Medicine)的统计分析指南:
- Authors should **avoid stepwise methods of model building**, except for the narrow application of hypothesis generation for subsequent studies. Stepwise methods include forward, backward, or combined procedures for the inclusion and exclusion of variables in a statistical model based on predetermined P value criteria.
- 应该避免使用逐步回归方法进行多因素回归。

小结

- 因果推断，俗称焦点因素研究，聚焦于关键1-2个暴露变量（比如治疗措施、个体特征）对疾病结局的影响，控制混杂偏倚

变量	是否参与	地位
与结局相关	是	可能是混杂
结局的结局	否	
暴露因素	是	地位超然
协变量	是	可能是混杂

因果推断焦点因素研究

- 不注重模型整体AUC面积是否大, R^2 是否大, 不考虑模型整体效果有多好
- 它也需要控制自变量数量, 一般更严格(仅限于混杂或潜在混杂)
- **特别要求不能纳入中介变量进入模型**, 免得会干扰目标研究指标的作用。
- 不采用采用逐步回归法, 允许没有统计学意义的协变量留在模型

焦点因素研究回归策略

- 先验知识结合DAG引导
- 可考虑先单因素、后多因素方法
- 可考虑采纳“效应改变法”策略进行自变量的去留考虑。

谢谢！

欢迎关注“医学论文与统计分析”公众号

欢迎关注“医学论文与统计分析”公众号