

靶向最大似然估计法及其衍生方法



郑老师团队



时间：2025

目录

- 双重稳健法概述：AIPW、TMLE、DML
- TMLE 衍生方法：C-TMLE（协作靶向最大似然估计法）、CV-TMLE（交叉验证靶向最大似然估计）、LS-TMLE（纵向生存数据的靶向最大似然估计法）
- 案例：TMLE及衍生法结果，AIPW，DML

01

PART ONE

双重稳健法概述

1.1 为什么要使用双重稳健估计方法？

- 在公共卫生研究中，我们常常想回答这样的问题
 - “如果大家都接受某种疫苗，平均死亡风险会降低多少？”
 - “吸烟对肺癌生存时间的影响到底有多大？”
- } 因果推断问题
- 理想状况，随机对照试验 (Randomized Controlled Trials, RCT) 被认为是实现因果推断的“金标准”
 - 但在现实中，RCT研究因伦理限制、成本高、周期长难以实施
 - 观察性研究 (Observational Study) 在进行因果推断时，常常面临混杂、偏倚、缺失数据和模型设定错误等挑战。

因果效应估计容易被严重**扭曲**

1.1 为什么要使用双重稳健估计方法?




Figure 1 Causal diagrams for a randomized controlled trial (A) and an observational study (B). A , binary treatment assignment/exposure; U , unmeasured confounders; W , confounders; W_g , confounder(s) that affect(s) the treatment assignment; W_Q , baseline prognostic covariates; Y , outcome.

1.2 因果推断效应指标

➤ 潜在结果模型 (Potential Outcomes Framework, 即反事实模型)

- $Y(1)$: 个体在接受处理时的结果
 - $Y(0)$: 个体在不接受处理时的结果
- 现实中, 只能观察到其中一个结果

➤ 因果推断的核心任务是估计因果效应, 使用双重稳健估计方法可以估计多种因果效应指标, 包括:

- 因果风险差 (RD)、因果风险比 (RR)、因果优势比 (OR)、平均处理效应 (ATE)、处理组\未处理组的平均处理效应 (ATT\ATC)
- 其中平均因果效应 (Average Treatment Effect) 是最常用的估计指标

$$ATE = E[Y(1) - Y(0)]$$

在整个人群中, 都接受处理和每个人都不接受处理的平均结果会相差多少?

1.3 什么是双重稳健？

➤ 双重

- **结果模型** (Outcome Model)

目标是估计在给定协变量 X 下，接受处理与否对结果变量 Y 的期望值。

- **暴露模型**/倾向性评分模型 (Propensity Score Model)

用于估计协变量给定的处理概率（即接受处理的倾向性），用于控制混杂。

在观察性研究中我们经常通过以上两种模型对混杂进行控制，但这依赖于某一种方法必须正确。

➤ 稳健

- 双保险：只要其中一个模型是正确的，估计结果就可以是一致的；
- 两个模型互补而非只依赖于其中一种。

1.4 双重稳健估计方法——增强逆概率加权法AIPW

$$\widehat{ATE}_{AIPW} = \frac{1}{n} \sum_{i=1}^n \left[\underbrace{\hat{m}_1(X_i) - \hat{m}_0(X_i)}_{\text{(A) 结果模型部分}} + \underbrace{\frac{A_i}{\hat{e}(X_i)} (Y_i - \hat{m}_1(X_i)) - \frac{1 - A_i}{1 - \hat{e}(X_i)} (Y_i - \hat{m}_0(X_i))}_{\text{(B) 暴露模型 (PS) } \times \text{残差矫正项}} \right]$$

1. 结果模型预测 ($m_a(X)$ 部分)

- $m_1(X_i)$ 是基于个体的特征 X_i ，使用结果模型预测的“如果接受处理”的结果。
- $m_0(X_i)$ 是预测的“如果接受对照”的结果。
- 这是 G-Computation 或回归调整方法的基础。如果结果模型是完美的，那么单靠这部分就能得到无偏估计。

2. 逆概率加权残差 (增强部分)

- $\frac{A_i}{\hat{\pi}(X_i)}$ 和 $\frac{1-A_i}{1-\hat{\pi}(X_i)}$ 是 IPTW 的权重。
- $(Y_i - m_1(X_i))$ 和 $(Y_i - m_0(X_i))$ 是观测结果与模型预测结果之间的残差。

这个“增强部分”的作用是纠偏：

- 如果结果模型 $m_a(X)$ 的预测有偏差，那么残差 $(Y_i - m_a(X_i))$ 会包含这个偏差信息。
- IPTW 权重 $\frac{A_i}{\hat{\pi}(X_i)}$ 确保了残差信息被“输送”给了正确的潜在结果估计。
- 如果一个个体实际接受了处理 ($A_i = 1$)，但他的倾向评分 $\hat{\pi}(X_i)$ 很小 (意味着他本不太可能接受处理)，那么他的观测结果 Y_i 就会被赋予很高的权重 (通过 $\frac{A_i}{\hat{\pi}(X_i)}$)，以此来修正预测 $m_1(X_i)$ 可能的偏差。

双重稳健估计方法通过残差矫正项提高稳健性，降低模型错误指定的风险。

所以，并不是分别估计“结果模型”和“暴露模型”后再做一个简单平均或相加，而是将这两个模型通过特定的数学形式组合成一种新的估计量。

1.4 双重稳健估计方法——增强逆概率加权法AIPW

➤ 核心优势

- 双重稳健性：只要结果模型或倾向评分模型任一正确，即可得到一致的因果估计；
- 比 IPW 更稳定：残差矫正项可减少极端权重影响，显著提高估计稳定性。在满足条件下可达到理论上最小方差，比IPW更高效。
- 兼容机器学习，模型灵活：可与 Super Learner、随机森林、XGBoost 等结合，减少模型设定错误；
- 输出医学友好的因果效应，如ATE。

1.5 双重稳健估计方法——靶向最大似然估计法

- 靶向最大似然估计法 (Targeted Maximum Likelihood Estimation, TMLE) 是在**双重稳健**的思想下由van der Laan和Rubin于2006年提出的一种因果推断方法。
- 其核心思想是利用暴露模型的信息构造“聪明协变量”，对初始结果模型的预测值进行“靶向更新”，从而实现对目标估计参数（例如，ATE）的正确估计。
- 核心优势
 - 双重稳健性；
 - 效率最优：在满足条件下可达到理论上最小方差，比AIPW更高效；
 - 机器学习兼容性强：可整合任意监督学习模型（如Super Learner），无须依赖参数化假设；
 - 靶向校正机制：自动根据影响函数调整预测值，使估计“对准”目标参数，**更贴近真实因果效应。**

1.5 双重稳健估计方法——靶向最大似然估计法

- TMLE (Targeted Maximum Likelihood Estimation) = 结果模型 (Q-model) + 暴露模型 (g-model) + 针对高效影响函数 (EIF) 的有机化迭代更新 → 得到既双重稳健又半参数有效的估计。

具体过程：

➤ 1. 建立初始结果模型

- 设观测数据为 $O_i = (A_i, Y_i, L_i), i = 1, \dots, n$, 其中A表示二元暴露变量; Y表示结局变量; L表示协变量。
- 建立初始结果模型 $Q(A, L) = E(Y|A, L)$ 。
- 利用该模型, 可以得到每个个体在暴露 ($A=1$) 和未暴露 ($A=0$) 两种状态下的潜在结果, 分别记为 $\hat{Q}(1, L)$ 和 $\hat{Q}(0, L)$;

1.5 双重稳健估计方法——靶向最大似然估计法

➤ 2.构造“聪明协变量”

- 首先，建立暴露模型 $g(L) = P(A = 1|L)$ ，即倾向评分模型。
- 该模型用于估计个体在给定协变量 L 下接受暴露的条件概率，即倾向得分，记为 $\hat{\pi}$ 。
- 随后，基于估计的倾向得分 $\hat{\pi}$ 和个体实际观测到的暴露状态 A ，构造“聪明协变量” $H(A, L)$ ，其计算公式为 $H(A, L) = \frac{I(A=1)}{\hat{\pi}} - \frac{I(A=0)}{1-\hat{\pi}}$ 。
- 在后续靶向更新步骤中， $H(A, L)$ 将作为回归模型中的协变量。

1.5 双重稳健估计方法——靶向最大似然估计法

➤ 3. 基于“聪明协变量”靶向更新初始结果估计

- 以 Y 为因变量， $H(A, L)$ 为协变量，同时将 $\hat{Q}(A, L)$ 指定为固定截距，建立回归模型。
- 例如，以二分类结局构建逻辑回归为例，回归公式为 $\text{logit}(Q^*(A, L)) = \text{logit}(\hat{Q}(A, L)) + \varepsilon \cdot H(A, L)$ ，通过模型系数估计方法得到 $\hat{\varepsilon}$ 。
- 因此，靶向更新后的潜在结果为 $\hat{Q}^*(1, L) = \hat{Q}(1, L) + \hat{\varepsilon} \cdot H(1, L)$ 以及 $\hat{Q}^*(0, L) = \hat{Q}(0, L) + \hat{\varepsilon} \cdot H(0, L)$ 。

1.5 双重稳健估计方法——靶向最大似然估计法

➤ 4. 计算目标参数估计值

- 平均因果效应定义为潜在结局之差的期望 $ATE = E[Y(1) - Y(0)]$ ，表示假定所有人都接受治疗时的结局平均值和假定所有人都不接受治疗时的结局平均值的差。
- 以目标参数为ATE为例，其估计值为 $\widehat{ATE} = \frac{1}{n} \sum_{i=1}^n [\widehat{Q}^*(1, L) - \widehat{Q}^*(0, L)]$ 。


1.5 双重稳健估计方法——靶向最大似然估计法

传统方法



直接用所有数据拟合模型
像一支盲目射的箭 会偏离靶心

TMLE



- 1.先用强大的“机器学习弓”（超级学习器）射一箭，尽可能靠近靶的区域（但不一定正中靶心）；
- 2.再用利用聪明协变量（靶向步骤），轻轻把箭推到正中靶心。

1.6 双重稳健估计方法——双重机器学习

- 双重机器学习 (Double/Debiased Machine Learning, DML) 是在2010年提出的一种允许使用任何机器学习方法来估计因果效应，同时保证统计推断有效性的框架。它通过正交化和样本分割技术，解决了机器学习模型在因果推断中的过拟合偏差问题
- 双重的“双”在何处
 - 双重估计对象：估计因果效应和两个辅助模型（暴露模型和结果模型）
 - 双重计算步骤：
 - 用机器学习算法拟合暴露模型和结果模型
 - 用正交化统计方法，从原始数据中“减掉”辅助模型的预测值
 - 双重数据分割
 - 用训练集来训练两个辅助模型；测试集计算因果效应

1.6 双重稳健估计方法——双重机器学习法

基本流程

- 第一步，创建数据结构，得到结构化数据 $\{(Y_i, D_i, X_i)\}_{i=1}^n$ ，其中 D 是处理变量， Y 是结局变量， X 是协变量；
- 第二步，将样本随机划分为 K 个大小相似的互斥子集（折）。对于第 v 折（ $v = 1, \dots, K$ ），定义为验证集 I_v ，除该折以外的为训练集 I_{-v} ；
- 第三步，在训练集中构建暴露模型和结局模型，并估计对应的预测值和正交化残差，构建正交得分函数

$$\psi(Y, D, X; \theta, m, g) = [Y - m(X) - \theta \cdot (D - g(X))] \cdot (D - g(X))$$

1.6 双重稳健估计方法——双重机器学习法

基本流程

- 第四步，基于训练集中构建好的暴露模型和结局模型，将其应用在验证集中计算验证集的残差
 - 结果残差： $\tilde{Y}_i = Y_i - m(X_i)$
 - 剥离了X对Y的可预测影响后，Y中“剩余”的部分。
 - 处理残差： $\tilde{D}_i = D_i - g(X_i)$
 - 剥离了X对D的可预测影响后，D中“像随机变动”的部分。
- 第五步，通过正交得分函数得到ATE估计，最终取均值作为最后的ATE。

$$\tilde{Y}_i = \theta \cdot \tilde{D}_i + \varepsilon_i$$

1.6 双重稳健估计方法——双重机器学习法

核心优势

- 可以使用机器学习方法，特别适合高维数据和非线性关系；
- 通过正交化使得目标参数的估计对干扰参数的估计误差不敏感
- 通过样本分割来消除过拟合带来的正则化偏差
- 具有很强的灵活性和扩展性：可以计算多种因果参数、处理不同类型的处理变量、结合不同的ML进行最优模型的选择

1.6 双重稳健估计方法——双重机器学习法

DML简单口诀:

- 分样本
- 练两个模型
- 在没见过的数据上算残差
- 用残差回归得效应、最后聚合。

02

PART TWO

TMLE的衍生方法

Derived Methods of TMLE

2.1 衍生方法1：协作靶向最大似然估计

The International Journal of Biostatistics

Volume 6, Issue 1

2010

Article 17

Collaborative Double Robust Targeted Maximum Likelihood Estimation

Mark J. van der Laan*

Susan Gruber†

- 协作靶向最大似然估计法（Collaborative Targeted Maximum Likelihood Estimation, C-TMLE）由van der Laan等在2010年提出，是一种通过逐步优化干扰参数的模型复杂程度的“协作”方式来构建TMLE估计器，从而更好地针对靶参数进行偏差最小化的方法。

2.1 衍生方法1：协作靶向最大似然估计

- TMLE的问题：对暴露模型的设定敏感：若暴露模型存在过度拟合或欠拟合，即使结果模型正确，也可能导致估计效率损失或结果估计错误。
- 针对以上不足，CTMLE引入“协作学习”机制，使得暴露模型能根据结果模型预测表现动态选择，通过反馈机制最小化结果模型的靶向化偏差，则整体估计将更加稳健和高效。



2.1 衍生方法1：协作靶向最大似然估计

基本构建流程

- (1) 采用机器学习等方法建立初始结果模型并得到初始估计 $\hat{Q}^{(0)}(A, L)$ 。
- (2) 通过前向选择的方法，构建协变量递增复杂的一系列暴露模型 $\{g^{(1)}(L), g^{(2)}(L), \dots, g^{(k)}(L)\}$ ，对每个暴露模型计算对应的聪明协变量，得到聪明协变量序列 $\{H^{(1)}, H^{(2)}, \dots, H^{(k)}\}$ 。
- (3) 基于每个暴露估计对初始结果估计进行更新。以二分类为例，利用 $\text{logit}\left(Q_n^{*(k)}(A, L)\right) = \text{logit}\left(\hat{Q}(A, L)\right) + \epsilon_n^{(k)} \cdot H^{(k)}(A, L)$ 对每个初始结果进行更新，得到更新后得到 $\{Q^{*(1)}(A, L), Q^{*(2)}(A, L), \dots, Q^{*(k)}(A, L)\}$ ，其中 $\epsilon_n^{(k)}$ 通过极大似然估计获得。

2.1 衍生方法1：协作靶向最大似然估计

基本构建流程

- (4) 使用惩罚对数似然损失函数 $k_n = \arg \min_k \left[E_{B_n} P_{n,B_n}^1 L(Q_n^{*(k)}) + \lambda \cdot \overline{\text{MSE}}(\psi_n^{(k)}) \right]$, 从候选估计序列当中选择组合最优的暴露模型和结果模型为最终的暴露模型和结果模型。
- (5) 以最终选定的暴露模型和初始结果模型, 进行靶向更新计算最终的因果

$$\text{效应} \psi_n^{\text{C-TMLE}} = \frac{1}{n} \sum_{i=1}^n \left[Q_n^{\text{final}}(1, L_i) - Q_n^{\text{final}}(0, L_i) \right].$$

2.2 衍生方法2：交叉验证靶向最大似然估计

University of California, Berkeley
U.C. Berkeley Division of Biostatistics Working Paper Series

Year 2010

Paper 273

Asymptotic Theory for Cross-validated Targeted Maximum Likelihood Estimation

Wenjing Zheng*

Mark J. van der Laan†

- 交叉验证靶向最大似然估计 (Cross-Validated Targeted Maximum Likelihood Estimation, CV-TMLE) 由van der Laan等在2010年提出，是一种在TMLE框架中引入交叉验证机制的改进方法，通过分割样本、独立拟合与靶向更新，从而提升因果效应估计的稳健性与统计推断的有效性。

2.2 衍生方法2：交叉验证靶向最大似然估计

- TMLE 要求估计函数不能过于复杂，避免过拟合。当数据稀疏、接近正性违反时，该条件易被违反，导致方差被低估、置信区间覆盖度不足。
- 使用高度灵活的机器学习算法（如随机森林）时，TMLE 容易过拟合，影响置信区间覆盖度。
- 在小样本、接近正性违反或暴露不平衡的情况下，TMLE 的置信区间覆盖度可能偏低，而 CVTMLE 能显著改善这一点。

In our setting, given the bias correction step, the data is used twice: To estimate (i) the nuisance functions and (ii) the bias reduction. Donsker class implies that the estimator of the nuisance functions are not too complex, including smooth parametric models, but also bounded monotone functions and smooth functions with bounded partial derivatives, to avoid overfitting [23]. This can become overly restrictive when we use arbitrarily flexible machine learning algorithms to estimate the nuisance parameters (i.e., Lasso, Random Forest, Boosting, etc.), which are prone to overfitting and break the Donsker class condition. In situations where the Donsker class condition is violated, the variance is anti-conservative, leading to confidence intervals with poor coverage [14, 24]. Cross-validation or cross-fitting of the TMLE algorithm (CVTMLE) is a simpler, yet effective, way to ensure efficiency, especially in settings where the Donsker class condition is violated [14, 25]. Cross-validation is a statistical learning technique widely used in regression and classification problems to avoid over-fitting and improve the asymptotic consistency and efficiency of estimations [26].


2.2 衍生方法2：交叉验证靶向最大似然估计

基本构建流程

- (1) 将样本随机划分为 K 个大小相似的互斥子集（折）。对于第 v 折（ $v = 1, \dots, K$ ），定义为验证集 I_v ，除该折以外的为训练集 I_{-v} ；
- (2) 在 I_{-v} 上建立初始结局模型 $Q(A, L)$ ，得到初始结果估计 $\hat{Q}(A, L)$ 。同时，在 I_{-v} 上建立暴露模型 $g(L)$ ，并计算聪明协变量 $H(A, L)$ ，通过靶向更新得到 $\hat{Q}^*(A, L)$ ；
- (3) 对于 I_v 上的每个个体，使用在 I_{-v} 更新后的预测 $\hat{Q}^*(A, L)$ 计算得到该折的平均处理效应；
- (4) 重复以上步骤 k 次，确保每个子集都作为验证集一次，取各折的平均值

为最终的平均因果效应估计 $\widehat{ATE}_{CVTMLE} = \frac{1}{K} \sum_{v=1}^K \widehat{ATE}_v$ 。

2.2 衍生方法2：交叉验证靶向最大似然估计



2.3 衍生方法3:纵向生存数据的靶向最大似然估计法

*The International Journal of
Biostatistics*

Volume 8, Issue 1

2012

Article 26

A General Implementation of TMLE for
Longitudinal Data Applied to Causal Inference
in Survival Analysis

Ori M. Stitelman, *University of California - Berkeley*
Victor De Gruttola, *Harvard School of Public Health*
Mark J. van der Laan, *University of California - Berkeley*

- 纵向生存数据的靶向最大似然估计法 (Longitudinal Survival Targeted Maximum Likelihood Estimation, LS-TMLE) 由Stitelman等人于2012年提出, 是一种通过二值化分解与后向迭代更新的方式对时间依赖性协变量进行处理, 从而在双重稳健性框架下对处理特异性生存曲线进行估计的置换估计器构建方法。

2.3 衍生方法3:纵向生存数据的靶向最大似然估计法

- 传统方法（如Cox模型、IPCW、A-IPCW）在存在时依性混杂或信息性删失时容易产生偏倚。
- 传统TMLE在包含时间依赖性协变量时，需要计算大量可能的历史路径组合，计算复杂度呈指数级增长。
- 提出了一种适用于一般纵向数据结构的TMLE算法，可扩展至更复杂的干预策略（如时依性治疗、动态治疗）和更复杂的纵向数据结构。

Many clinical trials are designed to assess the causal effect of different treatments on the time it takes for a particular outcome to occur, such as death or symptom relief. Such trials collect on each subject a longitudinal data structure which includes baseline covariates, the randomized treatment assignment, and other time-dependent covariates for as long as the subject is observed prior to experiencing the outcome of interest. The typical approach for assessing the causal effect of the randomized treatment in the literature and as mandated by the FDA for pharmaceutical drug development, is to employ a Cox-proportional hazards model only including treatment in the model. Once the parameters of the Cox-proportional hazards model is estimated a test is conducted to determine if the coefficient on treatment is not equal to zero. This approach ignores the available covariate information. It is well known that this test is biased if censoring depends on baseline covariates or even time-dependent covariates that are also predictive of survival.

2.3 衍生方法3:纵向生存数据的靶向最大似然估计法

- 在纵向研究中，我们不仅关心基线时的治疗（A），还关心随时间变化的协变量和删失（C）。这些时变因素如果同时影响治疗/删失和结局，就会造成时依性混杂，用传统方法（如仅用基线的Cox模型）估计治疗效果会有偏误。
- 纵向TMLE的目标：在存在时依性混杂和信息性删失的情况下，无偏且高效地估计“如果所有人都接受治疗 $A=a$ 且未被删失”的生存曲线。
- LS-TMLE的核心思想：
 - 先拟合：用一个灵活的模型（如机器学习）去预测数据中观察到的关系（初始估计）。
 - 再校准：对这个初始估计进行一个“微小的、有目标的调整”，让它专门针对我们关心的因果参数（如生存概率）进行优化，同时确保这个调整过程能自动纠正由删失和混杂引起的偏倚。

2.3 衍生方法3:生存数据的靶向最大似然估计法

基本构建流程

- 1.比较接受治疗A和治疗B的患者在36个月的生存概率差异。对于个体 i , 设观测数据

$$O_i = (W_i, A_i, L_i(1), C_i(1), Y_i(1), \dots, L_i(t), C_i(t), Y_i(t))$$

- 其中, W_i : 基线协变量 (如年龄、性别) ;

A_i : 二元处理变量 (如治疗A vs.治疗B) ;

$L_i(t)$: 时变协变量;

$C_i(t)$: 删失指示变量 (1 表示在 t 时刻删失, 0 表示未删失) ;

$Y_i(t)$: 结局指示变量 (1 表示在 t 时刻发生事件 (如死亡) ,
0 表示未发生)

2.3 衍生方法3:生存数据的靶向最大似然估计法

基本构建流程

- 2. 基于时间顺序，将观测数据的似然分解为时间链式乘积，利用机器学习等方法建立结局模型 Q 和建立暴露模型 g 。
- 3. 为了估计治疗特异性生存曲线 $S_a(t)$ ，我们需要对整个时间链上的所有初始结局模型估计进行靶向更新。更新过程采用**逆时间顺序**进行：从终点时间 $t = K$ 开始：为该时间点的结局模型 $Q_Y^{(0)}(K)$ 构建聪明协变量，并进行靶向更新，得到 $Q_Y^*(K)$ 。依次向前回溯：对于更早的每个时间点 $t = K - 1, K - 2, \dots, 1$ 的结局模型估计。最终得到 $\{Q_Y^*(K), Q_Y^*(K - 1), \dots, Q_Y^*(1)\}$ 。

2.3 衍生方法3:生存数据的靶向最大似然估计法

基本构建流程

- 5. 按照 $t=1,2,3,\dots,k$ 的时间顺序来模拟干预世界
 - $t=1$ 模拟
 - 从基线分布 $P(W)$ (通常用经验分布) 得到 W
 - 从 $Q_{L(1)}^*$ 生成 $L(1)$: 基于 $W, A = a$ $L(1)$ 时变协变量。
 - 从 $Q_{Y(1)}^*$ 生成 $Y(1)$: 基于 $W, A = a, L(1)$
 - 记录: $Y(1) = 0$ 表示在时间1存活
 - $t=2$ 模拟 (仅在 $Y(1) = 0$ 条件下继续)
 - 从 $Q_{L(2)}^*$ 生成 $L(2)$: 基于 $W, A = a, L(1), Y(1) = 0$
 - 从 $Q_{Y(2)}^*$ 生成 $Y(2)$: 基于 $W, A = a, L(1), L(2), Y(1) = 0$
 - 继续至 $t = K$

2.3 衍生方法3:纵向生存数据的靶向最大似然估计法

基本构建流程

➤ 4. 计算生存概率

- 对于任意时间点 t , 可以估计整个治疗特异性生存曲线

$$\hat{S}_a(t) = \frac{1}{n} \sum_{i=1}^n I(\text{在模拟中, 个体 } i \text{ 在时间 } 1, \dots, t \text{ 均存活})$$

➤ 5. 计算因果效应, 以风险差为例

$$\widehat{RD}(t) = \hat{S}_1(t) - \hat{S}_0(t)$$

2.4 更多衍生方法



欢迎关注“医学论文与统计分析”公众号

03

PART THREE

案例

3.1 案例概述•PICO原则

P (Population/人群)

- 研究对象：ICU患者。

I (Intervention/Exposure/干预或暴露因素)

- 右心导管术RHC干预（二分类；1=RHC，0=未行RHC）

C (Control/控制)

- 未执行RHC的ICU患者

O (Outcomes/结局)

- 是否死亡；


分析目的：右心导管在重症患者初期护理中的因果效应分析

3.2 案例实操·设置工作空间

➤ 设置工作空间

➤ 方案一·代码设置



例如, `setwd("C:/Users/12867/Desktop/数据")`



3.3 案例实操·设置工作空间

➤ 设置工作空间

➤ 方案二·操作面板手动设置



②点设置空间即可

①点“...”找到数据存储的文件夹



3.4 案例实操·导入数据

➤ 设置工作空间

➤ 方案一·代码设置

例如, `data <- read_csv("data.csv")`

➤ 方案二·操作面板手动设置



3.5 R包•AIPW

AIPW: Augmented Inverse Probability Weighting

repo status **Active** codecov **91%** R-CMD-check **passing** CRAN **0.6.9.2**

Contributors: [Yongqi Zhong](#), [Ashley Naimi](#), [Gabriel Conzuelo](#), [Edward Kennedy](#)

Augmented inverse probability weighting (AIPW) is a doubly robust estimator for causal inference. The `AIPW` package is designed for estimating the average treatment effect of a binary exposure on risk difference (RD), risk ratio (RR) and odds ratio (OR) scales with user-defined stacked machine learning algorithms ([SuperLearner](#) or [sl3](#)). Users need to examine causal assumptions (e.g., consistency) before using this package.

- AIPW 软件包旨在通过用户自定义的堆叠机器学习算法（SuperLearner）估算二元暴露对风险差（RD）、风险比（RR）和比值比（OR）尺度的平均处理效应）。

3.5 代码详解•AIPW

#设置SuperLearner库

```
SL.library <- c("SL.glm", "SL.ranger", "SL.xgboost", "SL.mean")
```

SL.glm: 逻辑回归, 适合二分类问题, 提供可解释性

SL.ranger: 随机森林, 能捕捉复杂非线性关系

SL.xgboost: 梯度提升, 处理复杂模式能力强

SL.mean: 基准模型, 防止过拟合

3.5 代码详解·AIPW

AIPW\$new(Y = NULL,
A = NULL,
W = NULL,
W.Q = NULL,
W.g = NULL,
Q.SL.library = NULL,
g.SL.library = NULL,
k_split = 3,
verbose = FALSE,
save.sl.fit = TRUE)

结局变量向量 (二分类: 0,1 或连续变量)

二分类暴露变量向量 (只能是0或1)

同时用于暴露模型和结局模型的协变量

专门用于结局模型 (Q) 的协变量

专门用于暴露模型 (g) 的协变量

用于拟合结局模型的机器学习算法

用于拟合暴露模型的机器学习算法

数据分割的折数 (默认 = 10)

是否打印运行过程和结果 (默认 = TRUE)

是否保存模型, 默认为FALSE

3.5 代码详解•AIPW

打印结果

```
print(AIPW_SL$result, digits = 2)
```

```
> print(AIPW_SL$result, digits = 2)
```

	Estimate	SE	95% LCL	95% UCL	N
Risk of Exposure	0.54	0.0107	0.524	0.57	2183
Risk of Control	0.46	0.0084	0.448	0.48	3551
Risk Difference	0.08	0.0135	0.054	0.11	5734
Risk Ratio	1.17	0.0263	1.114	1.23	5734
Odds Ratio	1.38	0.0539	1.241	1.53	5734

3.5 代码详解·AIPW

1. 暴露组风险 (Risk of Exposure)

- 估计值: 54% (95%CI: 52.4%-57.0%)
- 含义:在调整了年龄、疾病严重程度等混杂因素后, 接受右心导管术 (RHC) 治疗的患者中, 估计有54%的患者发生了死亡。

2. 对照组风险 (Risk of Control)

- 估计值: 46% (95%CI: 44.8%-48.0%)
- 含义:在调整了相同的混杂因素后, 未接受右心导管术 (RHC) 治疗的患者中, 估计有46%的患者发生了死亡。

3.5 代码详解·AIPW

3. 风险差异 (Risk Difference, RD)

- 估计值: 0.08
- 含义: 接受RHC使患者死亡风险增加8个百分点

4. 风险比 (Risk Ratio, RR)

- 估计值: 1.17
- 含义: RHC组死亡风险是对照组的1.17倍

5. 优势比 (Odds Ratio, OR)

- 估计值: 1.38
- 含义: RHC组死亡优势是对照组的1.38倍

3.6 代码详解•TMLE



 Maintainer: Susan Gruber

 License: BSD_3_clause + file LICENSE | GPL-2

 Last published: 2025-08-30

 <https://CRAN.R-project.org/package=tmle>

- `tmle()` 函数计算与二元点处理相关的调整后平均效应边际差值，适用于连续或二元结局。还报告了二元结果的相对风险和比值比估计。

3.6 代码详解·TMLE

```
tmle(Y,  
      A,  
      W,  
      Q.SL.library ,  
      g.SL.library,  
      family)
```

结局变量 (二分类: 0,1 或连续变量)

二分类暴露变量 (0或1)

同时用于暴露模型和结局模型的协变量

用于拟合结局模型的机器学习算法

用于拟合暴露模型的机器学习算法

'gaussian' (连续结局, 默认), 'binomial'
(二分类结局)

更多详情可以查看help文件

1. "?Tmle" 查看help文件
2. 手动查看



3.6 代码详解•TMLE

查看结果

Marginal mean under treatment (EY1)

Parameter Estimate: 0.5488
Estimated Variance: 9.7235e-05
p-value: <2e-16
95% Conf Interval: (0.52947, 0.56812)

Marginal mean under comparator (EY0)

Parameter Estimate: 0.46477
Estimated Variance: 6.6408e-05
p-value: <2e-16
95% Conf Interval: (0.4488, 0.48074)

Additive Effect

Parameter Estimate: 0.084025
Estimated Variance: 0.00016114
p-value: 3.609e-11
95% Conf Interval: (0.059146, 0.10891)

Additive Effect among the Treated

Parameter Estimate: 0.074853
Estimated Variance: 0.00017735
p-value: 1.9016e-08
95% Conf Interval: (0.048752, 0.10095)

Additive Effect among the Controls

Parameter Estimate: 0.091319
Estimated Variance: 0.00015973
p-value: 4.9908e-13
95% Conf Interval: (0.066548, 0.11609)

欢迎关注“医学”

3.6 代码详解•TMLE

1.暴露的边际风险Marginal mean under treatment (EY1):

- 估计值: 0.5488 (54.88%)
- 接受RHC治疗的患者, 发生死亡的概率为54.88%。

2.对照的边际风险 Marginal mean under comparator (EY0):

- 估计值: 0.46477 (46.48%)
- 未接受RHC治疗的患者, 发生死亡的概率为46.48 %。

3.平均处理效应 (Additive Effect , ATE) $ATE = E[Y(1) - Y(0)] = EY1 - EY0$

- 估计值: 0.084025 (8.4%)
- 解释:在调整了可能的混杂因素后, 接受RHC的患者比未接受RHC的患者死亡风险显著高出8.4个百分点。

3.6 代码详解•TMLE

4.在暴露人群中的平均效应 (Additive Effect among the Treated ,ATT)

- 风险差: 0.074853 (7.49%)
- 解释:如果这些患者未接受RHC, 预计死亡风险可降低7.5个百分点

5.在对照人群中的平均效应 (Additive Effect among the Controls ,ATC)

- 风险差: 0.091319 (9.13%)
- 解释:如果这些患者接受了RHC, 预计死亡风险将增加9.1个百分点

3.6 代码详解•TMLE

6. 相对风险 (Relative Risk)

➤ 估计值: 1.181

➤ 解释: 接受RHC的患者死亡风险是未接受者的1.18倍

➤ $RR = EY1 / EY0$

3.6 代码详解•TMLE

7.优势比 (Odds Ratio)

- 估计值: 1.40
- 解释:接受RHC的患者死亡优势是无RHC患者的1.40倍
- $OR = [EY1 / (1 - EY1)] / [EY0 / (1 - EY0)]$

3.7 代码详解·DML

DoubleML - Double Machine Learning in R

build failing codecov 98% codefactor B CRAN 1.0.2



DoubleML

The R package **DoubleML** provides an implementation of the double / debiased machine learning framework of [Chernozhukov et al. \(2018\)](#). It is built on top of [mlr3](#) and the [mlr3 ecosystem](#) (Lang et al., 2019).

Note that the R package was developed together with a python twin based on [scikit-learn](#). The python package is also available on [GitHub](#) and [pypi package 0.11.1](#).

- 面向对象的 DoubleML 实现基于 R6 软件包非常灵活。模型类别包括 DoubleMLPLR、DoubleMLPLIV、DoubleMLIRM 和 DoubleIIVM 通过机器学习实现干扰函数的估计方法以及奈曼正交评分函数的计算。

3.6 代码详解·DML

```
DoubleMLIRM$new(data  
  ml_g,  
  ml_m,  
  n_folds,  
  n_rep )
```

提供数据并指定因果模型的变量结构

用于结果模型的机器学习回归器

用于暴露模型的机器学习分类器

交叉验证折数，默认为5

样本分割的重复次数，默认为1

更多详情可以查看help文件

1. "?DoubleMLIRM\$new" 查看help文件
2. 手动查看



3.6 代码详解·DML

查看结果

```
> dml_irm$summary()
```

Estimates and significance testing of the effect of target variables

	Estimate.	Std. Error	t value	Pr(> t)
--	-----------	------------	---------	----------

RHC	0.08451	0.01376	6.139	8.29e-10 ***
-----	---------	---------	-------	--------------

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

1. 平均处理效应 (Additive Effect, ATE)

$$ATE = E[Y(1) - Y(0)] = EY1 - EY0$$

- 估计值: 0.08451 (8.45%)
- 解释: 在调整了可能的混杂因素后, 接受RHC的患者比未接受RHC的患者死亡风险显著高出8.45个百分点。

3.7 代码详解·CTMLE

Collaborative Targeted Maximum Likelihood Estimation

Collaborative Targeted Maximum Likelihood Estimation (C-TMLE) is an extension of Targeted Maximum Likelihood Estimation (TMLE). It applies variable/model selection for nuisance parameter (e.g. the propensity score) estimation in a 'collaborative' way, by directly optimizing the empirical metric on the causal estimator.

In this package, we implemented the general template of C-TMLE, for the estimation of the average treatment effect (ATE).

The package also offers convenient functions for discrete C-TMLE for variable selection, and LASSO-C-TMLE for model selection of LASSO, in estimation of the propensity score (PS).

- `ctmle()` 函数可估算平均处理效应 (ATE)，该软件包还提供了便捷的函数，用于变量选择的离散 C-TMLE，以及用于估计倾向得分 (PS) 的 LASSO 模型选择的 LASSO-C-TMLE。

3.7 代码详解· CTMLE

ctmleDiscrete(Y,
A,
W,
SL.library,
family)

结局变量 (二分类: 0,1 或连续变量)

二分类暴露变量 (0或1)

同时用于暴露模型和结局模型的协变量

用于自适应估计Q的预测算法库

'gaussian' (连续结局, 默认), 'binomial' (二分类结局)

更多详情可以查看help文件

1. "? ctmleDiscrete" 查看help文件
2. 手动查看



3.7 代码详解• CTMLE

打印结果

```
summary(ctmle_fit)  
> summary(ctmle_fit)
```

C-TMLE result:

```
parameter estimate: 0.07806  
estimated variance: 0.00018  
p-value: 4.4025e-09  
95% conf interval: (0.05199, 0.10413)
```

1. 平均处理效应 (Additive Effect, ATE)

- 估计值: 0.07806 (7.8%)
- 解释: 接受RHC与未接受RHC相比, 死亡风险增加约7.8个百分点。

3.7 代码详解· CV-TMLE

```
cv_tmle<- tmle(  
  Y = Y,          # 结局变量（连续型结局，对应 family = "binomial"）  
  A = A,          # 暴露 / 处理变量（通常为 0/1 的二分类变量）  
  W = W,          # 基线协变量矩阵，用于控制混杂（Q 模型和 g 模型）  
  Q.SL.library = SL.library, # 结局模型  $Q(Y | A, W)$  使用 Super Learner  
                           # 通过交叉验证组合多种机器学习算法  
  g.SL.library = SL.library, # 倾向得分模型  $g(A | W)$  使用 Super Learner  
                           # 用于估计处理分配机制，保证双重稳健性  
  cvQinit = TRUE,   # 启用 Cross-Validated TMLE:  
                   # 对初始结局回归 Q 使用交叉验证（cross-fitting），  
                   # 减少机器学习过拟合带来的偏倚  
  V.Q= 3,           # Number of cross-validation folds for super learner estimation of Q  
  
  V.g= 3            # Number of cross-validation folds for super learner estimation of g  
)
```

3.7 代码详解· CV-TMLE

打印结果

```
summary(cv_tmle_sl)
```

```
> cv_tmle_sl
```

Marginal mean under treatment (EY1)

Parameter Estimate: 0.54618
Estimated Variance: 0.0001014
p-value: <2e-16
95% Conf Interval: (0.52645, 0.56592)

Marginal mean under comparator (EY0)

Parameter Estimate: 0.46594
Estimated Variance: 6.744e-05
p-value: <2e-16
95% Conf Interval: (0.44985, 0.48204)

Additive Effect

Parameter Estimate: 0.080241
Estimated Variance: 0.00016639
p-value: 4.95e-10
95% Conf Interval: (0.054959, 0.10552)

Additive Effect among the Treated
Parameter Estimate: 0.071738
Estimated Variance: 0.00017959
p-value: 8.643e-08
95% Conf Interval: (0.045473, 0.098004)


Additive Effect among the Controls
Parameter Estimate: 0.086215
Estimated Variance: 0.00016525
p-value: 1.9918e-11
95% Conf Interval: (0.061019, 0.11141)

Relative Risk
Parameter Estimate: 1.1722
Variance(log scale): 0.0006409
p-value: 3.4658e-10
95% Conf Interval: (1.1155, 1.2318)

Odds Ratio
Parameter Estimate: 1.3795
Variance(log scale): 0.0026998
p-value: 5.9618e-10
95% Conf Interval: (1.2459, 1.5274)

欢迎关注“医学论”

3.7 代码详解•SurvivalTMLE



The screenshot shows the CRAN page for the R package 'survtmle' version 1.1.3. The page header includes navigation links: 'survtmle 1.1.3', a home icon, 'Reference', 'Articles', and 'Changelog'. The main title is 'R/survtmle'. Below it, the subtitle reads 'Targeted Minimum Loss-Based Estimation (TMLE) for Survival Analysis with Competing Risks'. The authors are listed as 'David Benkeser and Nima Hejazi'. The 'Description' section states: 'survtmle is an R package designed to use targeted minimum loss-based estimation (TMLE) to compute covariate-adjusted marginal cumulative incidence estimates in right-censored survival settings with and without competing risks. The estimates can leverage ensemble machine learning via the SuperLearner package.'

- `survtmle` 是一个 R 软件包，旨在利用基于最小损失的目标估计（TMLE）计算右审查生存环境下的协变量调整边际累计发病率估计，且该环境包含与是否存在竞争风险。这些估算可以通过 `SuperLearner` 软件包利用集合机器学习

3.7 代码详解· SurvivalTMLE

```
survtmle(ftime,  
         ftype,  
         trt,  
         adjustVars,  
         t0,  
         SL.ftime ,  
         SL.ctime ,  
         SL.trt ,  
         method ="hazard")
```

观测到死亡的事件

结局类型

暴露变量

调整的协变量

返回累积发生率估计的时间点

用于结局回归的超级学习库

用于删失风险估计的超级学习库

用于治疗估计的超级学习库


估计方法

3.7 代码详解• SurvivalTMLE

打印结果

```
tp <- timepoints(fit_surv_tmle, times = seq(1, 180, by = 10))
```

```
plot(tp)
```





谢谢