

因果推断模型与机器学习方法



郑老师团队




时间：2026

“因果推断模型与机器学习方法”训练营--理论篇

第九讲 处理效应异质性分析


为什么需要处理效应异质性分析？

——“平均”之下，个体效果各异



同一种疗法，为何有人有效、有人无效甚至有害？

精准医疗的核心挑战：同药不同效



方法学的演进：亚组分析 → 疾病风险评分 → 效应评分

技术前沿：Meta-Learner、因果森林、TMLE

目录

01

HTE基本概念与方法概览

02

效应评分法建模策略

03

因果森林方法

04

方法整合与应用

第一节

HTE基本概念与方法概览

旧概念：平均处理效应 (ATE)

- 定义

衡量处理（如政策、干预）对**整体人群**的平均因果影响。

$$ATE = \mathbb{E}[Y(1) - Y(0)]$$

其中 $Y(1)$ 为接受处理时的潜在结果， $Y(0)$ 为未接受处理时的潜在结果。

- 特点

- 单一数值，反映总体平均效果
- 忽略个体异质性
- 适用于政策整体评估、随机对照试验（RCT）的主要指标

- 局限

无法回答“谁受益更多”的问题

处理效应的异质性 (HTE)

- **定义:**

同一干预或暴露在不同患者中可能产生的**反应差异**。

- **新效应概念: 条件平均处理效应 (CATE) :**

在给定协变量 X 的条件下, 处理效应的条件期望效应:

- **特点**

- 揭示处理效应在**不同群体间**的异质性
- 可用于个性化决策 (如精准医疗、精准营销)

- **应用场景**

- 哪些人群从政策中获益最大?
- 是否应针对不同特征用户采取不同干预策略?

临床困境：同药不同效

华法林临床应用对比

患者A:

使用华法林，卒中
风险降低65%，无
出血

VS

患者B:

使用华法林，发生
严重颅内出血

肿瘤免疫治疗效果对比

PD-L1高表达患者:

肿瘤完全缓解，长
期生存

VS

PD-L1低表达患者:

治疗无效且出现免
疫性肺炎

抗血小板药物

CYP2C19基因型导致
疗效3-5倍差异



抗抑郁药物

仅约30%患者对一线
治疗充分应答



核心问题

为何基线相似的患者结局迥异?

关键挑战

如何在治疗前预测个体反应?

处理效应的异质性 (HTE) -CATE

数学公式:

$$\tau(x) = E[Y(1) - Y(0) \mid X = x]$$

- $Y(1)$: 治疗下的潜在结局
- $Y(0)$: 对照下的潜在结局
- X : 基线特征变量

造成异质性原因:

能够改变治疗效果大小的**基线特征**。

例如:

年龄、基因型、生物标志物、疾病严重程度等

为何HTE分析不可或缺？

临床决策优化

获益最大化：识别高应答人群，提高治疗成功率

例：仅对HER2阳性乳腺癌患者使用曲妥珠单抗

风险最小化：识别易受伤害亚组，避免不必要伤害

例：根据CYP2C19基因型调整氯吡格雷剂量

资源精准配置：将昂贵疗法集中于最可能获益者

科学研究驱动

机制探索：效应修饰模式提示药物作用通路

例：PD-L1预测免疫疗效，深化免疫逃逸机制理解

生物标志物发现：识别新的预测性标志物

药物研发优化：支持富集试验设计，提高研发效率

卫生体系影响

指南精细化：推动基于证据的分层治疗推荐

医疗经济学：提高整体医疗体系的成本效益

公平性促进：确保所有亚组患者获得适宜治疗

三类主要HTE分析方法

亚组分析 (Subgroup Analysis)

根据一个或少数几个**预先设定的特征分层**，分别估计效应。

基于疾病风险评分 (Disease Risk Score, DRS)

按多变量综合（预测模型）的**基线风险评分**分层，观察各层治疗效应。

基于效应评分 (Effect Score)

直接建模估计**个体治疗效应(ITE)** τ_i 作为效应评分并进行个性化决策。

方法1：传统亚组分析

第一步：识别——是否存在效应差异？

- 分层估计：计算各亚组的处理效应CATE
- 交互检验：测试亚组间效应差异是否显著

第二步：验证——差异是否可信？

- 先验性：亚组假设是否预先设定？
- 合理性：是否有生物学机制支持？
- 可重复性：定义是否标准，便于验证？

四大约束原则

原则	含义	目的
先验性	亚组假设分析前预先设定	避免数据挖掘导致的假阳性
生物学合理性	基于机制而非纯粹数据驱动	确保发现的科学意义
临床可操作性	分层标准清晰、可测量	确保结果能落地应用
一致性	使用标准定义	便于跨研究比较和验证

亚组分析实施流程：从规划到解释

规划阶段

预先设定

选择潜在修饰因子、定义
分层界值、计划多重性校正方法

分析阶段

量化估计

分层估计各亚组效应、检验
治疗与亚组的交互效应、
报告置信区间

解释阶段

结果判断

区分探索性发现与验证性
发现，评估临床意义、讨论
局限性

亚组分析核心工具——交互项检验

● 模型设定

$$Y = \beta_0 + \beta_1 T + \beta_2 X + \beta_3 (T \times X) + \varepsilon$$

- Y: 结局变量
- T: 治疗指示变量 (0=对照, 1=治疗)
- X: 亚组特征变量 (连续或分类)
- $T \times X$: 治疗与特征的交互项
- β_3 : 交互效应系数

● 检验内容

重点关注 β_3 是否显著, 当 $\beta_3 \neq 0$, $P < 0.05$ 存在效应修饰作用

加法尺度看 β_3 , 当 β_3 显著时, 说明绝对获益在不同亚组间存在差异

乘法尺度 $\exp(\beta_3)$, 当 $\exp(\beta_3)$ 显著时, 说明相对获益在不同的亚组间存在差异

方法2：疾病风险评分方法

● 基本原理

- **假设：**治疗效应可能与患者的基线预后风险相关
- **思路：**用基线预后风险作为效应修饰的代理变量
- **方法：**用多变量预后评分替代单变量分层，更全面捕捉异质性

关键

- 采用临床预测模型方法计算疾病风险评分模型
- 模型构建仅能使用**治疗前变量**，因为治疗后变量已被治疗影响，要避免引入偏倚

疾病风险评分方法实施步骤与方法评价

步骤	操作	要点
step 1	开发预后模型	纳入协变量建模
step 2	计算风险评分	将模型应用于全人群
step 3	风险分层	如按四分位数或临床阈值分组
step 4	层内效应估计	仍需控制层内混杂（评分不代表因果）

● 优势

- ✓ 综合多变量，避免单变量分析的片面性
- ✓ 风险分层临床意义明确，易于理解和应用
- ✓ 可整合现有临床工具，提高研究效率

● 局限

预后因子 $\neq$ 效应修饰因子（高风险不等于高获益）
机制解释有限（只回答“谁获益”，不回答“为什么”）
模型开发需足够样本量

方法3：效应评分法

- 核心公式（个体处理效应ITE）：

$$\tau_i = Y_i(1) - Y_i(0)$$

- 对单个个体 i 的真实因果效应，是确定性的但不可观测（反事实缺失）

- 估计公式（CATE）：

$$\tau(x) = E[Y(1) - Y(0) \mid X=x]$$

- 给定患者特征 x ，用药结局 $Y(1)$ 减去不用药结局 $Y(0)$ 的期望差异
- 通过模型来实现，估计 $\hat{\tau}(x)$ 值

效应评分思维

“这个病人用药比不用药好多少？”

预测效应 τ

直接估计增量价值

通俗理解 ITE 与CATE

假设我们研究一种降压药对血压的影响：

- **ITE**：张三服用后血压下降 5 mmHg（但我们永远无法同时知道他不服用的结果）
- **CATE**：所有 50 岁、男性、有高血压病史的人，平均血压下降 4.8 mmHg
- 当我们用模型预测时，对张三给出的 $\hat{\tau}(x) = 4.8$ ，这是**基于他特征的群体平均**，而非他个人的真实 ITE

效应评分法的两阶段流程

阶段一 效应建模

输入： 患者特征 X 、治疗分配 T 、结局 Y

过程： $\tau(x) = E[Y(1) - Y(0) | X=x]$

输出： 个体CATE预测值 $\hat{\tau}(x)$

阶段二 效应评分应用

输入： $\hat{\tau}(x)$ 预测值

过程： 将连续预测值转化为临床决策类别

输出： 患者分层（高/中/低获益）、治疗推荐

建模是“生产工具”，应用是“使用工具”，二者形成闭环

阶段一详解：如何“生产”效应预测值？

- **核心任务：**

从观测数据(x_i, T_i, Y_i)中学习函数 $\tau(x)$

- **关键方法：**

临床预测模型（一个往往含有暴露因素与协变量的临床预测模型）

- **核心统计学技术**

回归、机器学习方法等

阶段二详解：将数值转化为行动

- **核心任务：**将**连续预测** $\hat{\tau}(x)$ 转化为离散的临床行动

- 输入：个体化CATE估计 $\hat{\tau}(x)$
- 输出：患者分层、治疗推荐、决策辅助工具

- **常见操作**

- 个体化预测，在此基础上进行个体化决策
- 按照特定因素进行分层分析，进行亚组分析（不同群体效果如何）
- 根据 $\hat{\tau}(x)$ 评分本身进行分层，进行亚组分析（有效者，到底效果有多好）

与传统方法的本质区别

● 三类方法回答的问题

亚组分析

- 在x定义的群体中效应如何?
- 群体事先确定

疾病风险评分

- 在不同基线风险群体中效应如何?
- 群体由根据风险评分定义

效应评分

- 对这个特定个体预测效应多大?
- 个体化效应
- 可群体化评估


与传统分析方法对比（一）——分析单元

➤ 从“群体平均”到“个体预测”：医疗分析范式的演进



亚组分析

以“**群体**”为分析单元
“该亚组里，平均效应是多少？”



疾病风险评分

以“**风险层级**”为分析单元
“该风险层里，平均效应是多少？”



效应评分法

以“**个体患者**”为分析单元
“特定患者，预测效应是多少？”

与传统分析方法对比（二）——多变量处理方式

➤ 三种方法，三种整合逻辑

亚组分析 (Subgroup Analysis)

单独考察每个变量的独立作用，逐一验证其影响差异。

局限：结果易碎片化，难以综合应用

疾病风险评分 (Disease Risk Score, DRS)

通过权重计算将多变量压缩，生成单一的综合风险分数。

局限：过度简化损失变量特异性信息，可能无法反映异质性


效应评分 (Effect Score)

多变量灵活组合，直接输出个体综合效应评分。

优势：方法多样、灵活，可充分结合双重稳健估计


与传统分析方法对比（三）--应用

👤 传统亚组/DRS分析：混乱与困惑



- 输出一系列条件效应估计（每个亚组/层一个值）。
- 不同亚组结论冲突，导致医生难以决策。

🏠 效应评分法：整合与清晰



- 输出一个个体化预测函数 $\hat{r}(x)$ ，可为任何新患者计算预测值。
- 将多维矛盾信息整合为**统一预测值**，提供精准的临床决策依据。

第二节

效应评分法的效应建模策略

--CATE计算/ $\hat{\tau}(x)$ 估计

效应建模方法--如何从 (X, T, Y) 数据中估计 $\tau(x)$?

- **核心任务：**从包含特征(X)、方案(T)和结局(Y)的数据中，精准估计 $\tau(x)$
- **两大策略阵营：**参数化方法 vs. 非参数/机器学习方法
 - 关键框架：Meta-Learner
——将预测模型转化为效应估计器的灵活框架。
 - 专题聚焦：因果森林
——专门为估计CATE设计的强大算法。
 - 复杂整合：如何将因果森林嵌入其它框架中，获得稳健估计。

参数化方法--传统回归（通过交互项建模CATE）

- **基本原理：** 预测结局Y的模型中，显式加入治疗T与协变量X的交互项。

线性模型示例： $Y = \beta_0 + \beta_1 T + \beta_2 X + \beta_3 (T \cdot X) + \varepsilon$

CATE估计： $\hat{\tau}(x) = \beta_1 + \beta_3 X$ （线性模型）

● 模型形式：

- 连续结局：线性回归
- 二分类结局：逻辑回归
- 生存结局：Cox模型

传统回归

核心优势

- **简单透明**: 模型结构清晰, 参数解释直观。
- **统计性质明确**: 假设检验、置信区间计算成熟。
- **软件支持完善**: 所有统计软件均可轻松实现。

主要局限

- **线性假设**: 假设效应修饰是线性的, 与现实常不符。
- **交互项预设**: 必须事先知道哪些X可能有交互作用。
- **维度灾难**: 无法处理高维数据或复杂交互。

为何需要机器学习？——机遇与挑战

●三个驱动力

- **处理高维数据：**可同时分析数百甚至数千个特征。
- **捕捉复杂模式：**自动建模非线性关系与高阶交互作用。
- **灵活的函数形式：**不依赖预设的数学模型，数据驱动学习。

●三个核心挑战

- **因果与预测之别：**优秀的预测模型未必是好的因果模型。
- **过拟合风险：**复杂模型在小样本下易拟合噪声。
- **可解释性降低：**“黑箱”模型难获临床信任。

两大实现路径--Meta-Learner vs. 专门化因果算法

路径一：Meta-Learner框架

Meta-Learner的思路是**将CATE估计问题拆解为多个预测子问题**。

核心特点：**灵活**，可以将任何预测模型（如随机森林、神经网络、甚至传统回归）转化为CATE估计器。主要类型包括：S-Learner、T-Learner、X-Learner、R-Learner。

路径二：专门化因果学习算法。

专门化算法**从头设计以估计 $\tau(x)$ 为直接目标的模型**。

其中最具代表性的是**因果森林**——它在采用随机森林建模并分裂产生分类树的时候不再以预测结局的精度为目标，而是直接最大化处理组与对照组之间的效应差异，从而更精准地捕捉异质性。

最简单的元学习策略：S-Learner

S-Learner (单一学习器)

$$\hat{\tau}(x) = \hat{\mu}(x, T=1) - \hat{\mu}(x, T=0)$$

将治疗T作为一个普通特征，与X一起训练一个模型 $\mu(x, t)$ 。

- 优点：充分利用所有数据，避免了数据分割。
- 缺点：当特征X维度很高时，治疗T的信号可能被淹没，导致低估异质性。

S-Learner像请了一位全科医生，同时学习治与不治的病人的结局，然后让他回答“如果治会怎样，如果不治会怎样”。

最简单的元学习策略：T-Learner

T-Learner (双学习器)

$$\hat{\tau}(x) = \hat{\mu}_1(x) - \hat{\mu}_0(x)$$

用**治疗组**数据训练模型 $\mu_1(x)$ ，预测 $E[Y|X, T=1]$ 。

用**对照组**数据训练模型 $\mu_0(x)$ ，预测 $E[Y|X, T=0]$ 。

- 优点：概念最简单，直接模拟潜在结果框架。
- 缺点：两个模型独立，误差会叠加；治疗组样本量不平衡时效果差。

T-Learner像请了两位专科医生，一位只看治好的病人总结经验，一位只看没治的病人总结经验，然后两人会诊给出差异。

进阶的元学习策略：X-Learner

X-Learner (针对样本不平衡)

- 类似T-Learner, 先得到 $\mu_1(x)$ 和 $\mu_0(x)$ 。
- 计算“**伪效应**”：对治疗组病人, 用其真实Y减 $\mu_0(x)$; 对对照组病人, 用 $\mu_1(x)$ 减其真实Y。
- 分别用这两个“伪效应”训练模型, 最后用倾向评分加权平均。
- **优势**: 在观察性研究中, 当治疗组 (如接受新药者) 数量远小于对照组时, 表现常优于T-Learner。

更稳健的元学习策略R-Learner

R-Learner (双重稳健)

- 基于Robinson的正交化分解（双重机器学习）：

$$Y - E[Y|X] = \tau(X) * (T - E[T|X]) + \text{误差}。$$

- 先估计**两个干扰参数**：倾向评分 $e(x)=P(T=1|X)$ 和条件均值 $m(x)=E[Y|X]$ 。
- 基于残差 $Y-m(x)$ 和 $T-e(x)$ ，**通过特定方程来估计 $\tau(x)$** 。
- **优势**：具有双重稳健性，只要 $e(x)$ 或 $m(x)$ 之一估计正确， $\tau(x)$ 的估计就是一致的；理论性质优良。

对比总结：4种策略怎么选？

策略	核心特点	最佳适用场景	注意事项
T-Learner	直观、易于实现	治疗组与对照组样本量大致平衡； 作为复杂方法的基准。	样本不平衡时表现可能很差。
S-Learner	数据利用充分、计算高效	样本量有限，需要最大化数据利用； 预测任务中T信号强。	高维数据中可能淹没治疗信号，低 估HTE。
X-Learner	针对样本不平衡设计	观察性研究中治疗组远小于/大于对照 组。	实现相对复杂，计算步骤多。
R-Learner	双重稳健、理论性质好	对估计稳健性要求高； 能较好估计倾向评分或条件均值。	需要高质量估计两个干扰参数，对 数据要求高

专门化因果算法：因果森林原理


从预测到因果的 专用设计

- **传统随机森林（预测）**：目标是准确预测结局 Y 。
- **因果森林（推断）**：目标是准确估计处理效应 $\tau(x)$ 。
- **根本区别**：体现在决策树的分裂准则上。

回归树（预测） 分裂准则

- **回归树（预测）分裂准则**：
选择能使子节点内结局 Y 的方差减少最多的特征和分割点。
- **因果树（推断）分裂准则**：
选择能使子节点间处理效应 τ 的差异最大化的特征和分割点。

随机森林的“树”与分裂节点



因果森林原理：输出与聚合

对于每个患者，每棵因果树会将其分配到一个“叶子”节点。
在该叶子节点内，利用其他样本估计一个局部处理效应。

单树预测分配

1

森林结果聚合

2

对所有树的局部效应估计取平均，得到该患者的 $\hat{\tau}(x)$ 。

3

不确定性量化

计算所有树估计结果的方差，提供置信区间。

本节小结——策略全景回顾

参数方法

代表：传统回归

透明、解释性好，
但假设强、灵活性低。

非参数方法

代表：Meta-Learner

灵活、强大，通过
框架将预测模型转化
为因果估计器。

专门化算法

代表：因果森林

从算法底层为CATE
估计优化，自动探索
异质性。

核心理念掌握：

- Meta-Learner的精髓在于“分解与组合”。
- 因果森林的精髓在于“专门化的分裂准则”。

如何选择？--三步决策法

- **第一步：**从简单开始。

先尝试**传统回归**或**T-Learner**作为基准，建立性能底线。

- **第二步：**根据**数据特点**选择。

- a) 如果治疗组与对照组样本量**严重不平衡**，优先考虑**X-Learner**；
- b) 如果对估计**稳健性有极高要求**，或者倾向评分和条件均值能够较好估计，**R-Learner**是理想选择；
- c) 如果数据维度高、交互复杂，且目标是探索未知的异质性模式，**因果森林**更为适合。

- **第三步：**进行敏感性分析。

尝试**2-3种不同策略**，比较结果的稳定性。如果多种方法给出高度一致的结果，结论的可信度会大大增强；如果结果差异显著，则需要深入探究差异来源。

第三节

因果森林方法

为何专门介绍因果森林？

- 从通用到专用：

- Meta-Learner是框架，可使用随机森林等作为其“基学习器”。
- 因果森林是专门算法，2019年提出，从底层设计就是为了估计 $\tau(x)$ 。

- 核心创新---分裂准则的重设计：


- 随机森林（用于预测）：分裂节点时，目标是让子节点内结局Y的纯度更高（方差更小）。
- 因果森林（用于推断）：分裂节点时，目标是让子节点间治疗效应 τ 的差异更大。

- 根本区别：一个优化对Y的预测，一个优化对 τ 的估计。

随机森林到因果森林（一）——决策树

决策树 (Decision Tree) 是一类经典的机器学习监督模型，也是一些机器学习集成模型，例如随机森林、XGBoost模型的基本结构单元。

决策树模型名称的由来就是因为其和一颗树一样，从底部的根向上生长，每个分支代表一个规则，每片叶子表示一个最终结果。



决策树生成步骤


- 1.选择根节点：** 从所有特征中选择最佳的特征（分组变量）作为根节点。
- 2.分裂数据集：** 根据选定的特征将数据集分割成子集，使得每个子集在特定特征上具有最大的纯度（方差最小）。
- 3.递归构建：** 对每个子集递归地应用以上步骤，直到满足停止条件（如达到最大深度、样本数小于阈值等）为止。
- 4.生成决策树：** 构建完整的决策树结构，其中每个叶节点代表一个最终的决策结果。

不足之处：

容易过拟合、不稳定性、忽略了特征之间的相关性

随机森林到因果森林（一）——决策树与随机森林

- 一棵树 与 多棵树；
- 三个“臭皮匠”赛过“诸葛亮”



随机森林生成步骤


1. **随机选择样本：** 从训练集中随机选择一定数量的样本（有放回抽样）。
2. **随机选择特征：** 从所有特征中随机选择一部分特征。
3. **构建决策树：** 基于选定的样本和特征，构建多棵决策树。
4. **集成预测：** 将每棵决策树的预测结果进行集成，通常采用投票法确定最终预测结果。

随机森林到因果森林（一）——随机森林回顾

随机森林的分裂逻辑

- **目标**：准确预测个体结局 Y 。
- **分裂准则**：选择使子节点内 Y 的方差**减少最多的特征和分割点**。
- **公式**：
- **结果**：找到能最好区分不同 Y 值的特征，构建预测模型。

决策树分裂示意图




💡 分裂点选择策略：使子节点内方差最小化 (更纯净)

随机森林到因果森林（二）——因果森林的创新

随机森林的分裂逻辑

- **目标：**准确估计个体处理效应 $\tau(x)$ 。
- **分裂准则：**选择使子节点间处理效应 τ 的**差异最大的特征和分割点**。
- **结果：**找到能最好区分“高疗效患者”和“低疗效患者”的特征。

因果树分裂逻辑示意



分裂点选择：最大化子节点间的效应差异 (Heterogeneity)

随机森林到因果森林（三）——直观对比

● 以降压药效果研究为例

▮ 随机森林的问题

如果按年龄分割，两组人群的**血压水平**差异大吗？

关注点：结果变量本身的分布差异（关注“现状”）

▮ 因果森林的问题

如果按年龄分割，两组人群在接受治疗后的**血压变化**差异大吗？

关注点：干预带来的效应差异（关注“变化”）



核心区别：随机森林关注结果变量的预测（Predicting Outcomes），而因果森林关注异质性处理效应的估计（Estimating Treatment Effects）。

从单棵树到因果森林——集成与估计过程

1. 输入数据

准备包含结果变量(Y)、处理变量(T)和协变量(X)的数据集。

2. Bootstrap采样

有放回地随机抽取多个样本集，构建多棵树的基础。

3. 诚实估计

将每个样本集随机切分为“分裂集”和“估计集”，避免过拟合。

4. 构建树结构

使用“分裂集”数据学习最优分裂规则，生成树的结构。

5. 估计节点效应

利用“估计集”数据，在叶子节点内计算局部的处理效应

6. 效应聚合

将所有树的局部估计结果进行平均，输出最终的CATE估计。

核心逻辑：通过集成学习（Bootstrap + 聚合）降低方差，通过诚实估计（样本拆分）降低偏差，从而获得更稳健的因果效应估计。

因果森林的软件实现



R包 - grf

Generalized Random Forests

由因果森林的提出者团队开发，功能全面，是实现因果森林的首选工具。

<https://github.com/grf-labs/grf>



Python库 - EconML

Econometrics for Machine Learning

由微软研究院开发，集成了多种因果推断方法，包括因果森林。

<https://github.com/microsoft/EconML>



选择建议：如果您主要使用 R 语言进行统计分析，推荐使用 grf；如果您的技术栈以 Python 为主，EconML 提供了更完善的工程化封装和更丰富的模型集成。

因果森林其它结果（一）——特征重要性

核心定义与对比

定义：衡量特征在区分患者高/低治疗效应方面的贡献。


特征重要性：衡量对效应 τ 的区分。

计算逻辑与解读

计算方法：综合考虑特征在树中的分裂频率及每次分裂的增益。

结果解读：得分越高，该特征越可能是重要的效应修饰因子。

特征因果重要性得分示例



因果森林其它结果（一）——特征重要性

- **计算方法：**

通常基于特征在森林所有树的分裂中被使用的频率，以及使用它带来的效应差异增益。

在grf包中，可通过variable_importance()函数直接获取。

- **如何解读：**

重要性得分越高，表明该特征越有可能是效应修饰因子。
结果是一个排序列表，用于优先关注和研究最重要的特征。

因果森林其它结果（二）——部分依赖图（PDP）


⚙️ 功能与生成步骤

- **功能：**展示特征与个性化治疗效应(CATE)的边际关系。
- **步骤：**固定其他特征，仅改变目标特征取值，预测并平均CATE。

📈 曲线解读规则

- **曲线上升：**特征值越高，获益越大（正修饰）。
- **曲线下降：**特征值越高，获益越小（负修饰）。
- **曲线平坦：**特征对效应无明显修饰作用。
- **非线性曲线：**揭示复杂的U型或阈值效应。

PDP 曲线图示例：特征值 vs 平均治疗效应



结论：通过观察曲线趋势，可精准识别特征对治疗效应的修饰作用。

因果森林的核心优势

目的明确

专为估计个体化处理效应 (CATE) 设计，目标清晰，聚焦异质性分析。

非参数与灵活

无需预设效应模型形式，能捕捉复杂的非线性关系和高阶交互作用。

内置异质性分析

提供特征重要性、部分依赖图(PDP)等工具，便于结果解释和科学发现。

统计性质良好

作为机器学习的方法，集成学习法优势较为明显

有效处理混杂

通过正交化技术，能有效控制混杂因素的影响，降低偏倚。

高计算效率

基于集成学习框架，支持并行计算，能够高效处理大规模医疗或商业数据集。

不止于预测：因果森林的多维价值

CATE的预测器

直接输出每个个体的 $\tau(x)$ ，
揭示个体效应分布

识别异质性

- 整体检验：
提供基于森林的“**异质性重要性**”检验。
- 变量重要性：
评估哪些协变量 X 对驱动
效应异质性**贡献最大**。

发现与描述亚组

根据 $\tau(x)$ 的分布，可以：

- 划分高/低获益群体。
- **可视化**高获益群体的特征
(如使用部分依赖图)。

第四节

因果森林方法与其他方法

整合应用

为什么需要整合？

- **因果森林：**

- 是一种**具体的机器学习算法/估计器**，用于从数据中学习复杂的函数关系。它擅长拟合，但自身不直接提供双重稳健等高级统计属性。

- **Meta-Learner (S, T, X, R) 和 双重稳健估计：**

- 是**更高级的估计框架或策略**。它们定义了估计CATE的步骤和原则（如如何利用倾向评分、如何组合预测模型），并可以容纳任何机器学习算法作为其组件。

- **整合的逻辑：**

- 将因果森林作为这些框架内的“组件”，替代框架中原有的简单模型（如线性回归）。

因果森林与Meta-Learner、双重稳健的结合应用

● 策略一：因果森林作为“基学习器”(前期整合)

- 方法: **直接嵌入** S/T/X-Learner或双重稳健估计框架内, 用于估计倾向评分、条件均值或直接估计CATE
- 目标: 提升CATE估计的精度和稳健性。
- 关键: 模型拟合过程

● 策略二:因果森林作为“侦察兵”(后期整合)

- 方法: 1.独立运行因果森林, **识别关键异质性变量**。 2.将这些变量作为分层因素, 对另一估计器(如TMLE)得到的CATE进行分组评估和比较。
- 目标: 验证异质性存在性, 解释异质性来源, 生成可行动的亚组。
- 关键: 特征值重要性排序。

强强联合：当因果森林遇见双重稳健估计

问题

单一的机器学习模型(如因果森林)可能因模型误设而产生偏差。

解决方案

将因果森林作为分类器,识别异质性, 辅助双重稳健估计(如TMLE或AIPW)

优势

增强稳健性: 即使CATE模型部分有误,只要倾向评分模型或条件均值模型之一正确,最终估计仍一致。

提升效率: 能利用更多数据信息,得到更精确(方差更小)的估计。

基于关键因素进行亚组分析

- 因果森林输出因果特征重要性排序
- 由因果森林计算出CATE, 并进行分组
- 分组内部, 开展因果推断, 计算组内ATE
- 由因果森林识别出的Top K个关键特征, 并按照特征进行亚组分析:
 - 单因素分层: 按最重要特征的取值 (如年龄: <50, 50-65, >65岁) 分组。
 - 多因素交叉分层: 按前两个最重要特征交叉分组 (如: 年龄组 × 基因型) 或者构建预测模型再分组。
 - 在各组内进行因果推断计算ATE

亚组内ATE为什么不直接取CATE平均

因果森林

- 因果森林CATE估计在特定亚组上可能存在偏差，且难以提供准确的标准误和置信区间。
- 因果森林它更适合回答“**可能是什么**”，而非“**确切是多少**”

双重稳健估计

- AIPW/TMLE提供**无偏或低偏的亚组ATE估计**。
- AIPW/TMLE更适合回答“**确切是多少**”以及“**这个差异是否真实存在**”

与TMLE方法结合R语言代码

步骤1: 使用grf拟合因果森林, 识别重要变量

```
library(grf)
cf <- causal_forest(X, Y, W) # W是处理变量
var_imp <- variable_importance(cf)
top_features <- names(sort(var_imp, decreasing = TRUE))[1:2] # 取前两个
```

步骤2: 使用你选择的方法 (如tmle) 估计CATE

```
# 假设已用`tmle`包得到包含个体CATE估计值`tau_hat_tmle`的数据框
`df_tmle`
df_tmle$tau_hat <- tau_hat_tmle
```

步骤3: 基于top_features创建分层

```
df_tmle$sage_group <- cut(df_tmle$sage, breaks = c(0, 50, 65, 100))
df_tmle$geno_group <- as.factor(df_tmle$genotype)
```

与TMLE方法结合R语言代码

步骤4: 分层分析 - 计算各亚组平均CATE及置信区间

```
library(dplyr)
library(broom)
subgroup_effects <- df_tmle %>%
  group_by(age_group, geno_group) %>%
  summarise(
    mean_cate = mean(tau_hat),
    se = sd(tau_hat) / sqrt(n()),
    n = n()
  ) %>%
  mutate(
    ci_lower = mean_cate - 1.96 * se,
    ci_upper = mean_cate + 1.96 * se
  )
```

随后可进行可视化（如森林图）和组间检验（如线性模型）

存在现成的整合函数： CausalForestDynamicSubgroups

发现

在R的*EpiForsk*扩展包中，存在一个名为*CausalForestDynamicSubgroups*的专用函数，可结合因果森林与AIPW

● 具体功能：

该函数可以：

1. 基于因果森林的CATE估计，将样本动态分为若干组（如高、中、低效应组）。
2. 使用**样本外估计**（通过交叉验证）计算每个动态亚组的平均处理效应。
3. 提供亚组间效应差异的**正式统计检验**。
4. 生成各亚组**协变量分布的热力图**，用于解释。

整合函数具体运行步骤

步骤	操作内容	目的与说明
1. 数据准备与分组	根据初始因果森林对全体样本的 CATE 预测值进行排序，并划分为 $n_rankings$ 个亚组（如高、中、低效应组）。	动态确定异质性亚组，为后续分析提供框架。
2. 交叉验证训练	将数据分为 n_folds 折。对于每一折，使用其他所有折的数据训练一个新的因果森林模型。	确保后续对某一折数据的预测完全基于未见过该折数据的模型，实现严格的样本外估计，避免过拟合。
3. 计算样本外AIPW分数	对每个样本 i ，使用未包含 i 所在折的模型，为其计算 增广逆概率加权分数。	AIPW 分数是该方法的核心。它是一个双重稳健的估计量，结合了倾向评分和结果回归模型。即使其中一个模型有误，只要另一个正确，仍能保证估计的一致性。
4. 计算亚组平均效应	对于第1步确定的每个亚组，将该组内所有样本的 AIPW 分数取平均。	这个平均值就是该亚组的样本外平均处理效应估计值。同时可以计算标准误，用于统计推断。
5. 亚组间差异检验	基于亚组的 ATE 估计值及其标准误，进行正式的统计检验（如 t 检验）。	检验不同效应亚组（如高效应 vs. 低效应）之间的平均处理效应是否存在显著差异。

案例解读

- Journal of Dental Research杂志一篇论文:
- **因果森林与双重稳健估计**的组合, 系统评估牙齿脱落对死亡率的因果效应。

> J Dent Res

Journal of Dental Research

医学TOP

SCI升级版 医学1区

IF 5.9

IF: 5.9

Q1

2026 Mar 15:220345251414360.

doi: 10.1177/00220345251414360. Online ahead of print.

High-Dimensional Effect Heterogeneity of Tooth Loss on Mortality

Y Matsuyama¹, S Kiuchi¹, T Yamamoto², J Aida¹

Affiliations + expand

PMID: 41834379 DOI: 10.1177/00220345251414360

基本情况

- 研究团队使用**日本老年学评估研究 (JAGES)** 2013年基线调查数据，经过纳排，最终纳入69,265名65岁及以上老年人，随访时间中位数为9.2年。
- **暴露变量**：牙齿状态，按WHO功能牙齿标准分为“ ≥ 20 颗牙”与“ < 20 颗牙”两组。其中47.2%的参与者牙齿缺失（ < 20 颗牙）。
- **结局变量**：全因死亡，通过市政死亡登记记录。
- 纳入44个协变量，涵盖人口学、社会经济、健康状况、行为、社会关系、社区层面因素。

ATE估计：逆概率加权（IPW）方法

- 研究者首先通过估计**平均治疗效应（ATE）**来探究牙齿缺失与死亡率之间的关联。
- 先通过**逆概率加权（IPW）**平衡两组，纳入44个协变量构建逻辑回归模型计算牙齿缺失（<20颗牙）概率的稳定权重。
- 风险差尺度估计**平均处理效应（ATE）**。此外，使用**Cox比例风险模型**来验证关联的稳健性。

分析结果

- 研究结果显示，牙齿脱落显著增加了老年人群的死亡风险。
- 具体表现在，牙齿脱落与死亡风险增加3.2个百分点相关（系数=0.032；95%CI 0.023~0.040）。
- 使用Cox比例风险模型观察到了类似的关联（HR=1.19；95%CI 1.14~1.25）。

Characteristic	LPM	Cox PH Model
	Coefficient (95% CI)	HR (95% CI)
Counterfactual scenario on the number of teeth		
If everyone had ≥ 20 teeth	Reference	Reference
If everyone had < 20 teeth	0.032 (0.023–0.040)	1.19 (1.14–1.25)


CI, confidence interval; HR, hazard ratio; LPM, linear probability model; PH, proportional hazard.

CATE估计：因果森林+双重稳健

- 研究团队应用了广义随机森林（GRF）算法中的**因果森林方法**。
- 首先，使用**20折交叉拟合**进行预测计算CATE
- 接着，通过使用**增强逆概率加权（AIPW）**估计CATE五等分亚组的组平均处理效应（GATE）来评估模型性能。
- 工具：**CausalForestDynamicSubgroups**或者类似方法

分析结果

按CATE五等分分组后，效应最大组死亡率高达32.5%，而效应最小组仅12.7%，相差近2.5倍；且按CATE五等分亚组估计的CATE值呈递增趋势。




异质性特征识别

- 将第二步中估计出的CATE作为预测目标，纳入44个协变量作为特征，使用**XGBoost**构建预测模型。
- 数据集按8:2划分为训练集和测试集，通过**网格搜索**进行超参数调优，以**最小化均方根误差（RMSE）**为优化目标。
- 用**SHAP值**对特征重要性进行可视化。SHAP值越大，说明该特征对CATE的预测贡献越大。
- 研究结果显示，**心脏病、性别和抑郁症状**是影响效应异质性最强的3个贡献因素。

分析结果

- 联合效应分析热图显示，在心脏病、性别和抑郁症状定义的亚组中，平均CATE存在差异，范围从无心脏病或无抑郁的女性的0.024，到有心脏病和重度抑郁的男性的0.054。



总结：从“黑箱预测”到“白箱洞察”

- **核心贡献：**这种结合策略将因果森林从单纯的“预测模型”，提升为强有力的“假设生成与发现工具”。
- **workflow 闭环：**它构建了“数据驱动探索” → “稳健靶向估计” → “清晰统计推断”的完整HTE分析范式。
- **实践意义：**为研究者提供了一条从高维、复杂数据中，系统地发掘、验证和报告可解释性异质性发现的可靠路径。

总结



- ✓ **CATE估计**是实现精准医疗决策的**核心**。
- ✓ **因果森林**等机器学习方法为探索复杂异质性提供了强大工具。
- ✓ 与**双重稳健框架**结合，能兼顾预测能力与统计可靠性。
- ✓ 这是一个快速发展、充满机遇的交叉领域。

第五节

处理效应异质性R语言 过程

汇报结束

OVER