

因果推断模型与机器学习方法

郑老师团队

时间: 2026

“因果推断模型与机器学习方法”训练营--理论篇

倾向得分方法控制混杂偏倚的理论

“论文与统计分析”公众号

“分析”公众号

倾向得分方法快速理解

- 是什么?
- 怎么得到?
- 有什么用?
- 什么原理?
- 怎么用?

欢迎关注“医学论文与统计分析”公众号

倾向得分方法快速理解 —— 是什么？

是什么？


倾向得分是一个条件概率，表示给定协变量的条件下，一个观察对象接受某种处理/治疗/暴露的可能性，它是一个从0到1的范围内连续分布的概率值。

$$P(A = 1 \mid \mathbf{X})$$

倾向得分方法快速理解 —— 是什么？

举个例子

- 一项关于肺癌药物有效性的前瞻性队列研究，总样本1000人。
- 暴露组：放疗+纳武利尤单抗；非暴露组：仅放疗。结局是客观缓解率（治疗有效率）。



倾向得分方法快速理解 —— 是什么？

举个例子

- 由于是非随机化研究，患者会根据自身情况选择接受暴露组还是对照组治疗方式。
- 假设收集了两个协变量，这两个协变量会决定一个人接受暴露组治疗的意愿大小。见下表。

协变量1 性别	协变量2 年龄	总人数	暴露组人数	暴露率
男	≥ 60 岁	330	200	60.6%
男	< 60 岁	240	180	75.0%
女	≥ 60 岁	280	140	50.0%
女	< 60 岁	150	90	60.0%

- 具体到一个个体，如果是男性，并且年龄 ≥ 60 ，那么他接受暴露组治疗的可能性，或者说意愿是60.6%，这个60.6% (0.606) 就是该个体的倾向性得分。

反映了这两个协变量对治疗选择的影响

倾向得分方法快速理解 —— 怎么得到？

注意：真实应用中不直接用“分层暴露率”，而要用 Logistic 回归等模型估计倾向性评分

- 分层暴露率只适合非常少量、离散的协变量；
- 模型能利用全样本信息得到更稳定的暴露概率估计，而不是依赖某个小格子的样本数。

倾向得分具体计算方式：

假设暴露因素是二分类的（是否服用降压药、是否抑郁等），以暴露因素作为因变量Y，以诸多可能影响研究对象暴露情况的变量作为自变量X，拟合Logistic回归，之后计算每个个体进入暴露组的预测概率作为个体的倾向得分。

Logistic回归的模型形式： $\ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$ P：进入暴露组的概率



倾向得分：

$$\hat{P} = \frac{1}{1 + e^{-(\hat{\beta}_0 + \hat{\beta}_1 X_1 + \dots + \hat{\beta}_k X_k)}}$$


倾向得分 $\hat{P}$ 习惯于写成 $\hat{\pi}$ 或者 $\hat{e}$

倾向得分方法快速理解 —— 有什么用？

- 本质作用都是：**观察性研究**中控制**混杂偏倚**，从而更准确估计处理效应。

- 什么是混杂偏倚？—— 由混杂因素导致的对处理效应的估计错误。

- 举个例子：



- ✓ 对于**随机对照实验研究**：

由于处理（日常喝茶/日常不喝茶）是随机分配的，这两组中的日常抽烟人数是相近的，即混杂因素在组间的**分布是均衡的**。所以RCT是估计处理效应的“**金标准**”。

- ✓ 而对于**观察性研究**：

日常抽烟的人大多也日常喝茶，即混杂因素在组间的**分布是不均衡的**。

在观察性研究中如果不加以处理，往往会错误估计处理的真实效果！

倾向得分方法快速理解 —— 什么原理？

- 核心原理：应用倾向性得分，使得处理组和对照组间协变量（特别是混杂因素）的分布均衡，类似于形成一个“伪随机对照试验”。

$$A \perp X \mid e(X)$$


- 通俗解释：
 - 原本：不同协变量的人有不同的“治疗倾向” → 即处理组间协变量“不平衡”
 - 但是：如果我们把两组中倾向性评分相同或相近的人找出来（倾向性评分匹配方法）
 - 这两组人在协变量上已经“平衡”
 - 就像在相同协变量背景下随机接受治疗
 - 混杂偏倚被消除或大幅减少

换句话说：

倾向得分把多个协变量压缩成一个能“平衡”协变量的概率，在应用后，使得处理像是随机分配的一样。

倾向得分方法快速理解 —— 怎么用？


➤ 第一种方式：倾向得分匹配 (Propensity Score Matching)



局限：往往损失样本，降低估计效率

倾向得分方法快速理解 —— 怎么用？

➤ 第二种方式：倾向得分分层 (Propensity Score Stratification)



倾向得分方法快速理解 —— 怎么用？

- 第三种方式：倾向得分校正 (Propensity Score Adjustment)

一般做法：

$$Y = \beta_0 + \beta_A A + \beta_e e(\mathbf{X})$$


也可以：

$$Y = \beta_0 + \beta_A A + \beta_e e(\mathbf{X}) + \beta_1 X_3 + \dots + \beta_J X_8$$

局限：无法做协变量均衡性分析（不能计算SMD）

倾向得分方法快速理解 —— 怎么用？

- 第四种方式：倾向得分加权 —— 逆概率加权 (Inverse Probability Weighting, IPW)



为何会有倾向得分方法？

控制混杂因素的策略

- **事先法**（设计阶段控制）：

匹配设计、限制、随机分组



实际中往往难以实施

- **事后法**（资料分析阶段的控制）：

传统方法：匹配分析、分层分析、多因素回归分析




各有局限


前沿方法：倾向得分等因果推断方法

传统方法的局限

- 协变量匹配分析



处理组



对照组


协变量越多，越难找到完美匹配个体



分析样本减少，统计效力降低，甚至可能影响估计结果可靠性

传统方法的局限

- 协变量分层分析



和匹配分析法**相同局限**：一些受试者可能没有合适的层次而被排除在外，进而影响估计结果可靠性

传统方法的局限

- 多因素回归分析

$$Y = \beta_0 + \boxed{\beta_A}A + \beta_1X_1 + \beta_2X_2 + \dots + \beta_JX_J$$

其估计值 b_a 为处理效应

✓ 模型**必须正确**（线性正确、无遗漏交互、无错误函数形式）才能得到无偏结果 ➡ 实际中无法验证正确与否

✓ 假如正确模型中有关于处理因素A的交互项


$$Y = \beta_0 + \boxed{\beta_A}A + \beta_1X_1 + \beta_2X_2 + \dots + \beta_JX_J + \beta_{J+1}A \cdot X_3$$

其估计值 b_a 还为处理效应吗? No


✓ 当结局事件发生较少而协变量较多时，样本量可能不符合回归模型的要求，导致ACE估计不准确甚至因模型不收敛而得不到估计值

倾向得分方法的优势

- “化多为一”，更加实用。



- 协变量平衡效果往往可以检验。(SMD是否 <0.1)



- 对模型形式要求相对较低，即使不严格也能校正部分混杂。

关于广义倾向得分 (GPS)

关于广义倾向得分 (GPS)

- 是倾向得分在**连续或多水平**处理情形下的推广

$$f_{A|X}(a | X)$$

即：在给定协变量 X 条件下，个体接受某一处理水平 a 的条件密度（或概率）。

关于广义倾向得分 (GPS)

- 一般先估计 $E(A|X)$ ，再结合残差分布构造 GPS

例如我们先建模：

$$A = \mu(X) + \varepsilon$$

并假设：

$$\varepsilon|X \sim N(0, \sigma^2)$$

等价地说：

$$A|X \sim N(\mu, \sigma^2)$$

在这个假设下：

$$f_{A|X}(a|X) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(a - \mu(X))^2}{2\sigma^2}\right)$$



谢谢

欢迎参加郑老师团队的“因果推断与机器学习”训练营，请联系助教aq566665，一步一步学会R语言因果推断方法